

引用意図を利用した学術論文閲覧支援情報生成の一手法

西海 真祥[†] 金澤 輝一^{††} 高須 淳宏^{††} 上野 史^{†††} 太田 学^{†††}

[†] 岡山大学工学部情報系学科 〒700-8530 岡山市北区津島中 3-1-1

^{††} 国立情報学研究所 〒101-8430 東京都千代田区一ツ橋 2-1-2

^{†††} 岡山大学大学院自然科学研究科 〒700-8530 岡山市北区津島中 3-1-1

E-mail: [†]p3ng4cj3@s.okayama-u.ac.jp, ^{††}{tkana,takasu}@nii.ac.jp, ^{†††}{uwano,ohta}@okayama-u.ac.jp

あらまし 引用論文は学術論文の位置づけや内容の理解に重要である一方、引用論文を全て読む労力は大きい。本稿では、引用意図を利用して閲覧している論文の引用箇所を理解を助ける情報を生成する手法を提案する。そのため、まず論文の引用箇所の引用意図を 10 クラスに分類する。次に引用箇所の引用意図に基づいて論文閲覧支援のための情報源を選び、情報源の各文と閲覧論文中の引用文との類似度を文の分散表現で求め、類似度の高い文を組み合わせる論文閲覧者に提供する。評価実験では、まず引用箇所の引用意図の自動分類結果について考察した。また、提案手法が各引用箇所について論文閲覧者に提供するために生成した文の有用性を被験者実験により示した。

キーワード 引用意図, 論文閲覧支援, 情報生成

1 はじめに

学術論文において引用論文は、先行研究の手法を導入したり実験結果を比較したりするために用いられる。そのため、引用論文は手法を提案する根拠を示すだけでなく手法の位置づけを示すこともある。したがって引用論文を読むことは閲覧論文の理解に重要な意味をもつ。

学術論文において、引用論文の文章を原文のまま引用することは少なく、論文の著者が自身の論文の趣旨に沿うようにまとめた形で引用することが多い。よって、論文閲覧者が引用している内容を正確に理解するには引用論文全文を読まなければならないこともある。しかし、論文は一般に多数の論文を引用するため、引用意図を理解するためだけに引用論文を読む労力は大きい。そのため、論文閲覧者に引用箇所ごとにその理解を助けとなる情報を効果的に提供することができれば、論文閲覧者が引用論文を読む労力を減らし、効率的に論文が読めるようになる。このような論文閲覧支援では、引用箇所に関連する情報を閲覧論文の文脈に沿って要約することが望ましいが、そのためには適切な要約の分量や要約に用いる適切な情報源についての知見を得る必要がある。そこで本稿ではまず、論文の引用箇所を含む引用文の分散表現を用いて引用意図を推定する。次に引用意図に応じた論文閲覧支援情報を生成するために、その情報源の特定と引用意図に合った引用箇所の説明文を文の分散表現を利用して生成する。

本稿の構成を示す。2 節で論文閲覧支援と引用意図に関連する研究を紹介し、3 節で引用意図の定義と分類、4 節で引用意図に応じた論文閲覧支援情報の生成、5 節で引用意図の分類実験、6 節で生成された学術論文閲覧支援情報の評価実験について述べる。

2 関連研究

2.1 論文閲覧支援

学術論文の閲覧を支援するシステムは既に多数提案されている。鉢木ら [1], [2] は電子図書館と Web を連携させた論文閲覧支援システムを提案した。学術論文画像を OCR 処理して得たテキスト中の専門用語に対して、Web 上の有用な情報源への適切なリンクを提供した [1]。さらに各専門用語で検索した論文集合とその論文集合に出現する専門用語集合を求め、その両者間にリンクを張った二部グラフに HITS アルゴリズムを適用して求めた関連論文を推薦した [2]。

阿辺川ら [3], [4] は論文の本文を解析し、ページの補足情報をページの左右に表示する論文閲覧システム Sidenoter を提案した。論文の内部リソースである本文だけでなく、外部リソースである Wikipedia の情報を補足情報として表示する機能がある。このシステムは言語処理学会の年次大会の予稿集の閲覧用に開発された [3]。さらに連続ページめくり、書き込み、参考文献リンク等の効果的な論文閲覧を実現するための機能が追加されている [4]。

これらの論文閲覧支援ではあらましや本文の用語に対して Web を利用して情報提供している。一方、本稿では、引用論文の引用箇所に対して Web を利用して閲覧支援用法を生成し、論文閲覧者に提供する。

2.2 引用意図

学術論文中の引用箇所の引用意図を利用する研究もいくつか提案されている。

石井ら [5] は引用意図を利用し引用論文から適切な引用箇所を特定した。そのためにまず NTCIR-9 [6] の GeoTime タスクの論文を分析して、引用意図を Group, Method, Result, Data, Equation の 5 クラスと定めた。手掛かり語を利用し、引用箇

所の引用意図の分類と引用箇所の補足情報にふさわしい引用論文の箇所を特定した。特定した引用論文の箇所とその前後の文を含む3文から1段落を論文閲覧者に提供した。

Jurgens ら [7] は計算言語学会の論文で構成された ACL Anthology Reference Corpus (ACL ARC) 等のデータセットに含まれる引用箇所の引用意図を分類した。引用意図を Background, Extends, Uses, Motivation, Compare/Contrast, Future work の6クラスと定めた。このデータセットは 8th International Workshop on Mining Scientific Publications (WOSP 2020) ¹ の ‘3C’ Citation Context Classification Task でも利用された。Allenai Institute for AI² が提供しているデータセット SciCite [8] は、計算機科学と薬学の論文で構築されており、引用意図を Background, Method, Result の3クラスと定めた。

2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020)³ の CL-SciSumm タスクは、計算言語学の論文の引用箇所に対応する引用論文を要約するタスクであるが、サブタスクにおいて引用意図を推定する。このサブタスクでは引用意図は Aim, Hypothesis, Method, Result, Implication の5つの facet で表現された。

このように研究によって引用意図の定義が異なっており、Method と Result は多くの研究で引用意図として定義されるが、Hypothesis や Future work 等の引用意図については扱いが異なる。本稿では Method, Result に加え、Basis と Data を定義する。

3 引用意図の分類

ここでは、まず 3.1 節で論文 PDF において引用箇所と引用文を特定する方法を説明する。3.2 節で引用意図の定義を示し、3.3 節で引用箇所の引用意図を分類する方法を説明する。

3.1 引用箇所と引用文の特定

本稿では、論文中の引用箇所を以下の方法で特定する。まず、pdftotext⁴ を用い、論文 PDF ファイルをテキストファイルに変換する。次に Neural-Parscit を内包するフレームワークである SciWING⁵ を利用して、テキストに変換した論文の各文に対して section タグを付与する。この Neural-Parscit [9] は XML ファイルやテキストファイルに変換された論文から自動で書誌情報を抽出するプログラムである。最後に論文本文を示す bodyText タグ等を含むテキストから、“[1]” のような引用を示す文字列パターンを利用し引用箇所を特定する。

本稿で**引用箇所**は、引用番号等の引用を示す文字列の直前の名詞とその限定詞と前位修飾語あるいは引用文全体と定める。なお引用箇所を含む文が**引用文**である。

3.2 引用意図クラス

本稿では論文 [10] の引用箇所の分析に基づいて、引用意図クラスを表 1 に示す対象クラス、抽象度クラス、関係性クラスの3種類のクラスを組み合わせた計 10 クラスと定める。学術論文閲覧支援の観点では、引用箇所の補足に役に立つ情報源には引用論文だけでなく Wikipedia 等の Web の情報源もある。そのため引用意図の定義は学術論文閲覧支援の観点から検討した。各クラスの特徴を以下で述べる。

対象クラスは、引用の対象を表すクラスで、以下の5つを定義する。

(1) Method

研究で採用されたモデル、アルゴリズム、方法を引用の対象とする。

(2) Result

研究で得られた主要な結果を引用の対象とする。

(3) Basis

研究の考察や議論または利用したパラメータ等を引用の対象とする。

(4) Data

実験等に用いたデータを引用の対象とする。

(5) Other

上記4つのクラスに該当しない内容を引用の対象とする。

抽象度クラスは、引用内容の具体性を表す。引用内容の抽象度が高ければ、引用論文以外の情報源の情報を論文閲覧者に提供可能と考える。抽象度クラスとして、以下の2つを定義する。

(1) Instance/Experiment

具体的な手順や数値が引用されている。

(2) Concept/Conclusion

抽象度の高い概念やアイデアが引用されている。

関係性クラスは、引用の理由を表すために導入するクラスである。その論文が引用論文と異なる点、または同じ点を明確にすることは論文閲覧支援に有用であると考え、関係性クラスとして、以下の2つを定義する。

(1) Comparison

引用論文とそれを引用する論文の内容を対比するために引用されている。

(2) Introduction

引用論文の研究をそれを引用する論文に導入するために引用されている。

3.3 提案する引用意図の分類法

Huggingface Bert⁶ の pretrained model である bert-base-uncased [11] を fine-tuning して引用箇所の引用意図を分類する。分類器の構成法は2つあり、1つは対象クラス、抽象度クラス、関係性クラスそれぞれに対応する3つの分類器で構成する方法と、もう1つは表1の10の引用意図クラスに分類する分類器を1つ構成する方法である。分類器3つで構成する場合は、対象クラス、抽象度クラス、関係性クラスの順に分類結果

1 : <https://wosp.core.ac.uk/jcdl2020/index.html>

2 : <https://allenai.org/>

3 : <https://2020.emnlp.org/>

4 : <http://www.foolabs.com/xpdf>

5 : <https://github.com/abhinavkashyap/sciwing>

6 : <https://huggingface.co/>

表 1: 引用意図クラス

対象クラス	抽象度クラス	関係性クラス
Method	Instance	Comparison
		Introduction
	Concept	Comparison
		Introduction
Result	Experiment	C/I ^{*1}
	Conclusion	C/I
Basis	Instance	C/I
	Concept	C/I
Data	I/C ^{*2}	C/I
Other	I/C	C/I

^{*1} Comparison/Introduction

^{*2} Instance/Concept

を参照し、引用意図の組み合わせが一つに絞られた時点で、その引用意図に分類する。分類に用いる入力引用文のうち引用を示す文字列、例えば “[1]” を分類する引用意図以外では取り除き、分類する引用意図では数字のみを取り除いた “[]” とした文とする。

4 学術論文閲覧支援のための情報生成

本稿では、引用意図クラスごとに異なるルールで情報源から文を抽出する。学術論文閲覧支援情報は情報源から抽出した文を組み合わせて構成する。ここでは、まず 4.1 節で閲覧支援情報に利用する情報源からの文の抽出法を説明し、4.2 節で学術論文閲覧支援情報の生成とその提示インタフェースを示す。

4.1 情報源からの文の抽出

情報源からの文の抽出では、Sentence-Bert [14] により文の分散表現を求め、引用文とのコサイン類似度が大きい文を情報源から抽出する。また抽象度の高い引用箇所は引用論文以外の情報源も有用と考え、外部情報源を利用する。外部情報源は英語版 Wikipedia⁷ とする。情報源とする記事は、Wikipedia が提供する検索エンジンを利用し、引用箇所を検索して得られた最初の記事とする。

以下では引用意図ごとに引用論文から文を抽出する方法を説明する。なお、引用論文の“詳細節”をアブストラクト、背景、関連研究、結論以外の節と定める。

• Method-Instance-Comparison クラスと Method-Instance-Introduction クラス

具体性な手法を引用する場合であり、引用論文のアブストラクトから 1 文抽出し、加えて詳細節から 5 文抽出する。また関係性クラスが Comparison の場合、引用論文の結論の節からさらに 1 文抽出し、Introduction の場合、引用論文のアブストラクトからさらに 1 文抽出する。

• Method-Concept-Comparison クラスと Method-Concept-Introduction クラス

一般化された手法等を引用する場合はコンセプト自体の重要度が高いため、引用論文からの抽出する文を Method-Instance-Comparison や Method-Instance-Introduction より減らし、代わりに外部情報源を利用する。具体的には、引用論文のアブストラクトから 1 文抽出し、加えて詳細節から 3 文抽出する。また、英語版 Wikipedia の記事の要約から 1 文抽出する。関係性クラスが Comparison の場合、英語版 Wikipedia の記事の詳細からさらに 1 文抽出し、Introduction の場合は、英語版 Wikipedia の記事の要約からさらに 1 文抽出する。

• Result-Experiment クラス

実験結果は定量的な評価が示されている場合が多く、表や図にまとめられていることもあるため、引用論文の詳細節、結論の節から 1 文抽出する。また抽出した文と同一段落にある後方 2 文を含めた最大 3 文を抽出する。抽出した文中で “Table 1” のように表が参照されていると推定される場合は、その表も抽出する。図が参照されていると推定される場合は、図のキャプションも抽出する。

• Result-Conclusion クラス

実験結果から明確に導かれる結論を引用したい場合が多く、引用論文の詳細節、結論の節から 1 文を抽出する。抽出した文と同一段落にある後方 2 文を含めた最大 3 文を抽出する。引用箇所が人名を示す固有名詞でないなら、英語版 Wikipedia の記事の要約からも 1 文抽出する。

• Basis-Instance クラス

パラメータ等具体的な数値を引用したい場合が多いため、引用論文の詳細節と結論の節に含まれる文に対し、引用文との類似度が高い順に引用したい数値による部分一致検索を行い、最初に一致する 1 文を抽出する。部分一致検索に一致する文が存在しない場合は最も分散表現の類似度が大きい 1 文を抽出する。抽出した文と同一段落にある前後 1 文ずつを加えた最大 3 文を抽出する。

• Basis-Concept クラス

抽象度の高い根拠は論文の著者の言葉で表現されている可能性があり、その場合根拠を抽出することは難しいが、文の類似度比較によって言い換え表現が得られることに期待し、引用論文の詳細節、結論の節から 3 文抽出する。

• Data クラス

実験に利用されるデータに関する引用論文の記述は一箇所に固まっていることが多く、表や図にまとめられていることもある。そこで、引用論文の詳細節から 2 文選択し、抽出した文と同一段落にある前後 1 文ずつを加えた最大 3 文を抽出する。抽出した文中で “Table 1” のように表が参照されていると推定される場合は、その表も抽出する。図が参照されていると推定される場合は、図のキャプションも抽出する。

• Other クラス

引用論文のアブストラクトと詳細節から 1 文ずつ計 2 文抽出する。

4.2 学術論文閲覧支援情報の生成と提示インタフェース

4.1 節の方法で抽出した文を情報源ごとにまとめ論文閲覧者

⁷ : https://en.wikipedia.org/wiki/Main_Page

Method - Concept - Comparison

> Especially, we focus on more sophisticated units that implement a gating mechanism, such as a long short-term memory (LSTM) unit and a recently proposed gated recurrent unit (GRU).

> Intuitively, if the LSTM unit detects an important feature from an input sequence at early stage, it easily carries this information (the existence of the feature) over a long distance, hence, capturing potential long-distance dependencies.

> First, it is easy for each unit to remember the existence of a specific feature in the input stream for a long series of steps.

> In this paper, we are interested in evaluating the performance of those recently proposed recurrent units (LSTM unit and GRU) on sequence modeling.

Cite: Junyoung Chung, Çağlar Gülgeçre, Kyunghyun Cho, and Yoshua Bengio. Empirical evaluation of gated recurrent neural networks on sequence modeling. CoRR, abs/1412.3555, 2014.

> Gated recurrent units (GRUs) are a gating mechanism in recurrent neural networks, introduced in 2014 by Kyunghyun Cho et al.

> The operator \odot denotes the Hadamard product in the following.

Cite: https://en.wikipedia.org/wiki/Gated_recurrent_unit

図 1: 学術論文閲覧支援情報の提示インタフェース [10], [15]

に提供する。情報源を引用論文、英語版 Wikipedia の順に並べ、情報源ごとに引用文との類似度を利用して抽出した文を類似度が高い順に並べる。類似度を利用して抽出した文を基準として前後の文を抽出している場合、文の順番を維持してそれらの文を閲覧支援情報に加える。学術論文閲覧支援情報の提示インタフェースの例が図 1 である。この例では、引用論文から抽出した文が水色地、英語版 Wikipedia から抽出した文がピンク地の部分に表示されている。

5 引用意図の分類実験

5.1 実験内容

本実験では、引用箇所を含む引用文を入力し、3.2 節で提案した引用意図クラスに分類するための分類器を作成し、その性能を測る。対象クラス、抽象度クラス、関係性クラスを分類する 3 つの分類器による出力から引用意図クラスを分類する Three classifiers と引用意図クラスを 1 つの分類器で分類する Single classifier による実験を行う。

5.2 分類実験に用いるデータ

表 2 は、人手で判定した 4 本の論文、それぞれ論文 1 [10], 2 [11], 3 [12], 4 [13] に含まれる 222 の引用箇所の引用意図を示している。表の左側に示す計 10 の引用意図に分類した引用箇所の数を表の右側に論文ごとに示している。表 2 に示す論文 1 から、Other 以外の引用意図クラスごとに、引用箇所を 2 つ選び、その引用箇所を含む引用文をテストデータとする。選ばなかった残りの引用文と論文 2, 3 と 4 に存在する引用箇所を含む引用文を訓練データとする。

5.3 分類実験に用いる分類器

bert-base-uncased [11] を 5.2 節で説明した訓練データを用いて Huggingface Bert の pretrained model である fine-tuning する。クラス間の偏りが大きいため、オーバーサンプリングして最も多いデータ数に合わせるようにデータを複製する。learning rate を $5e-5$, weight decay を 0.01, adam beta1 を 0.9, adam beta2 を 0.999, adam expsilon を $1e-8$, epoch を

表 2: 分類実験に用いた引用箇所

引用意図クラス	引用数			
	論文 1	論文 2	論文 3	論文 4
Method-Instance-Comparison	9	9	1	1
Method-Instance-Introduction	3	8	2	3
Method-Concept-Comparison	6	14	7	8
Method-Concept-Introduction	11	11	10	29
Result-Experiment	18	2	3	1
Result-Conclusion	6	9	2	11
Basis-Instance	2	1	0	0
Basis-Concept	5	2	2	4
Data	3	2	3	2
Other	0	0	2	0

20, batch size を 32 に設定して学習する。

5.4 分類実験の評価方法

評価は、それぞれの手法で得られたモデルの再現率、適合率、F 値の平均 (F1-macro) を用いる。再現率は、あるクラスに属するデータのうち、正しく予測できた割合、適合率は、あるクラスと予測したデータのうち、実際に正しく予測した割合、F 値は再現率と適合率の調和平均である。

5.5 分類実験結果

引用意図クラスの Other を除いた 9 クラスに分類する。Three classifiers, ならびに単一の Single classifier, また Three classifiers に利用する対象クラス、抽象度クラス、関係性クラスの各分類器の F 値を表 3 に示す。それらを合わせた表 3 の左側が分類したクラス、その右が分類結果の再現率、適合率、F 値である。引用意図クラスの分類器の実験結果は、Three classifiers の F 値は 0.315 であり、Single classifier の F 値は 0.381 である。Three classifiers に用いる 3 つの分類器の実験結果は、対象クラスの F 値は 0.687 であり、抽象度クラスの F 値は 0.467 であり、関係性クラスの F 値は 0.564 である。また、それぞれの分類器がテストデータを分類したときの混合行列を図 3 の (a),(b),(c),(d),(e) に示す。混合行列の縦は正しいクラス、横は分類器が予測したクラスを表している。図 3 の (a),(b),(d),(e),(f) はそれぞれ Three classifiers, Single classifier, 対象クラス、抽象度クラス、引用意図クラスの混合行列である。対象クラスの分類器は Basis クラスを Method クラスに誤って分類することが多いが、それ以外はおおよそ正しく分類できた。抽象度クラスの分類器では Concept/Conclusion クラスに偏って分類され、関係性クラスの分類器では Introduction クラスに偏って分類された。これらの結果が Three classifiers の分類器の性能に影響した。Single classifier の分類器は Three classifiers と似た傾向を示すが、Method-Concept-Introduction に偏って分類され、Method-Instance-Introduction, Method-Concept-Comparison, Basis-Instance の計 3 クラスには 1 つも分類されない結果となった。

表 3 に示す通り、Three classifiers と Single classifier の F 値は 0.4 を下回っており、また、対象クラス、抽象度クラス、関係

表 3: 分類結果 (引用意図クラス)

分類したクラス	再現率	適合率	F 値
Three classifiers	0.333	0.306	0.315
Single classifier	0.444	0.395	0.381
対象クラス	0.688	0.713	0.687
抽象度クラス	0.500	0.500	0.467
関係性クラス	0.625	0.785	0.564

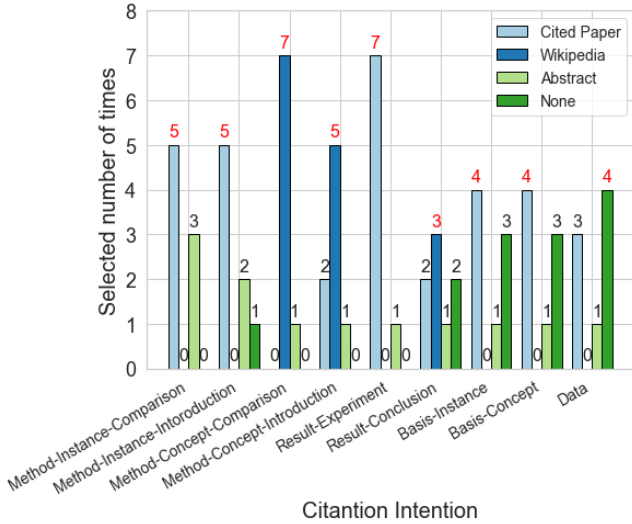


図 2: 総合的に役に立つと判断された情報源

性クラスの分類器の F 値は 0.7 を下回った。本稿の論文閲覧支援では引用箇所を推定した引用意図を利用するため、引用意図の分類精度を上げる必要がある。分類性能があまりよくなかったのは、訓練データの生成コストが高く、十分な量がなかったことも一因である。

6 学術論文閲覧支援情報の評価実験

6.1 実験内容

本実験では、人手で分類した正しい引用意図に基づき 4.1 節の方法で生成した閲覧支援情報が、引用箇所の内容理解に役に立つかを、被験者に引用論文のアブストラクト全文と比較させ判断させる。

情報系の岡山大学工学部生 1 名と同大学院生 3 名に 6.3 節に示す方法で被験者実験を行う。

6.2 閲覧支援情報の評価実験に用いたデータ

テストデータは、表 2 に示す論文 1 から Other 以外の引用クラスごとに引用箇所を 2 つずつ選んだ計 18 の引用箇所とする。計 10 の引用意図のうち、最下行の Other クラス以外について論文 1 は 2 箇所以上有している。この中から閲覧支援情報の評価実験に適した引用箇所を選ぶため、アブストラクトがない引用論文は避け、同じ引用文が訓練データに含まれないように選ぶ。そのため 5.2 節の分類実験のテストデータと数は同じであるが選び方が異なる。選んだ引用箇所の手で分類した正解の引用意図に従って、4.1 節で示した方法で情報源を選び、閲覧

支援情報を生成する。

6.3 閲覧支援情報の評価方法

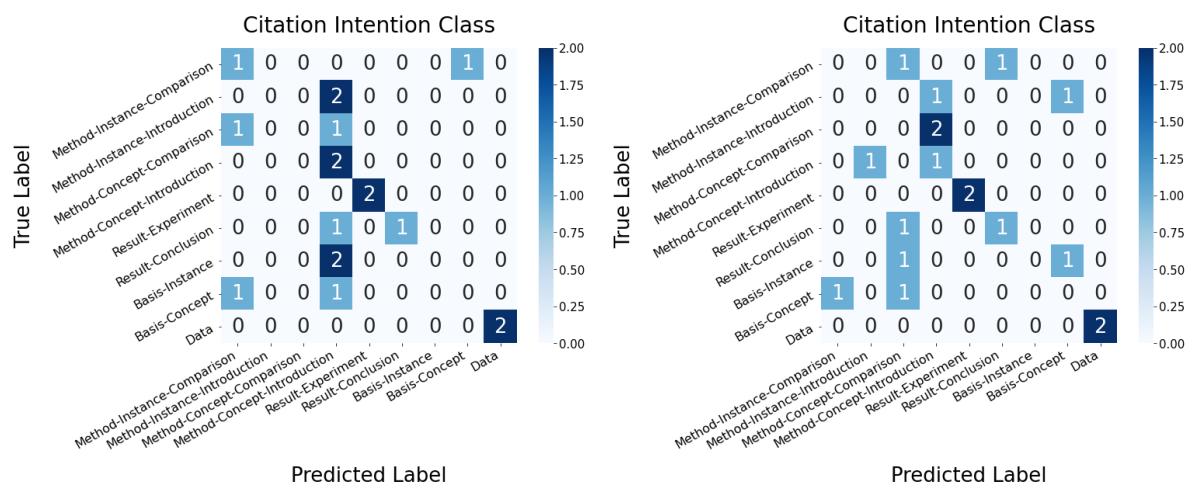
この実験では、被験者に引用箇所ごとに生成した閲覧支援情報と引用論文のアブストラクト全文を提示し、引用箇所の理解に総合的に役に立つと判断した情報源を、引用論文から生成した論文閲覧支援情報、引用論文のアブストラクト、引用意図クラスによっては英語版 Wikipedia、いずれも役に立たないの 4 つから 1 つ選ばせる。被験者がいずれも役に立たないと判断した場合は、自由記述欄にその理由を書かせる。また、最も役に立つと判断した文も 1 つ選ばせる。ただし、引用論文のアブストラクトは全文で 1 文扱いとし、総合的に役に立つと判断した情報源がない場合は、最も役に立つ文に該当する文もなしとする。

6.4 実験結果

引用箇所の理解に対して総合的に役に立つと判断した情報源、引用論文、英語版 Wikipedia、アブストラクト、いずれも役に立たないの 4 つの選択肢がそれぞれ選ばれた回数を引用意図クラスごとに図 2 にまとめる。図 2 の横軸が引用意図クラス、縦軸が選ばれた回数である。各クラスの選ばれた回数の合計は全て 8 回である。英語版 Wikipedia は 4.1 節の手法で説明した通り、Method-Concept-Comparison, Method-Concept-Introduction, Result-Conclusion の 3 クラスのみ情報源として利用する。図 2 に示す通り英語版 Wikipedia を情報源として利用したクラスにおいては、英語版 Wikipedia が総合的に役に立つと判断された割合は高かった。Method-Instance-Comparison, Method-Instance-Introduction, Method-Concept-Comparison, Method-Concept-Introduction, Result-Experiment の 5 クラスでは引用論文または英語版 Wikipedia の閲覧支援情報が最も役に立つと判断されることが多く、いずれも役に立たないと判断されることが少ない。しかし、他のクラスにおいてはいずれも役に立たないと判断される割合が増えるため、これらについては情報生成の方法を検討する必要がある。

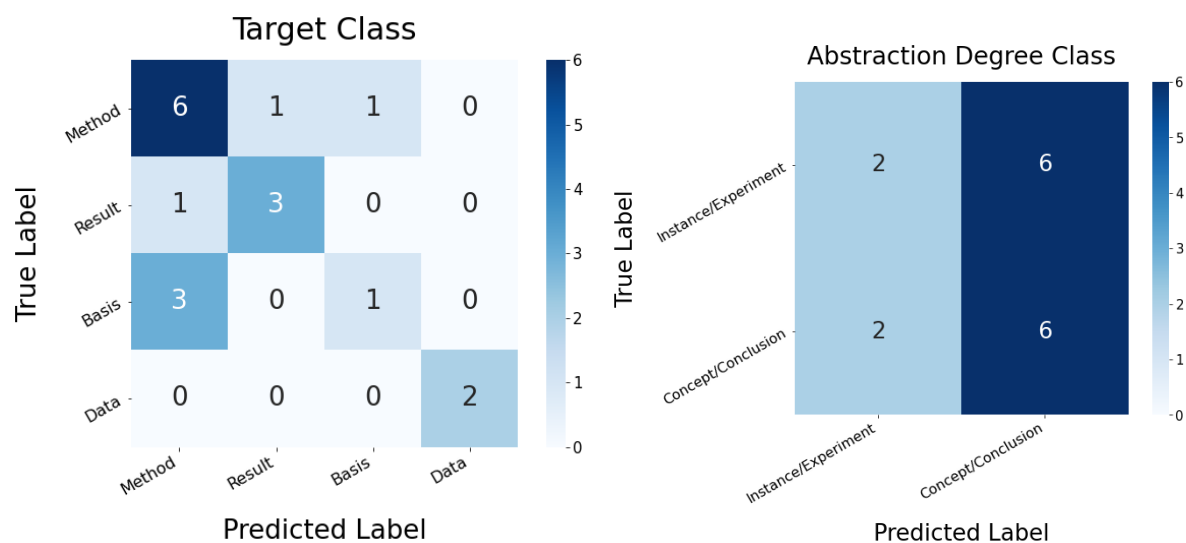
最も役に立つと判断された文は、全 72 の回答のうち 2 つを除いて、総合的に役に立つと判断された情報源から選ばれていた。図 1 は実際に被験者に提示された閲覧支援情報の一例であり、Method-Concept-Comparison クラスに属する引用箇所である。ピンク地の部分に英語版 Wikipedia から抽出した 2 文が提示されているが、被験者 4 人のうち、3 人がこの英語版 Wikipedia が総合的に役に立つ情報源と判断し、最も役に立つ文として英語版 Wikipedia の要約の最初の 1 文である上の文を選んだ。この傾向は、引用箇所に合致する記事が英語版 Wikipedia に存在する場合に見られた。

対象クラスの Method に属する引用箇所については本実験で生成した閲覧支援情報がアブストラクト全文よりも選ばれる傾向にあったが、特に対象クラス Basis や Data はいずれも役に立たないと選ばれる回数が半分近くになっており、これらの引用意図についてはさらなる検討が必要である。




(a) Three classifiers

(b) Single classifier



(c) 対象クラス

(d) 抽象度クラス



(e) 関係性クラス

図 3: 9 つのクラスによる引用意図分類

7 ま と め

本稿では、引用意図を利用して引用箇所に対する学術論文閲覧支援情報を生成して提供する手法を提案した。新たに引用意図を 10 クラスと定義し、対象クラス、抽象度クラス、関係性クラスの 3 種類のクラスによる組み合わせと定めた。定義した引用意図に応じて、引用論文および英語版 Wikipedia から論文閲覧支援のための情報源を選び、それらの情報源の各文と閲覧論文中の引用文との類似度を文の分散表現で求め、類似度の高い文を組み合わせで論文閲覧者に提供した。引用箇所の引用意図の分類実験では、3 種類の分類器を組み合わせた Three classifiers と 1 つの分類器で分類する Single classifier の再現率、適合率、F 値を求めた。その結果のいずれも F 値が 0.4 を下回り、分類精度を上げる必要性が示された。学術論文閲覧支援情報の評価実験では、定義した 10 クラスのうち 5 クラスの引用意図クラスにおける閲覧支援情報の有用性を確認した。引用意図の推定性能を向上させるため、対象クラス、抽象度クラス、関係性クラスにおいて、文の埋め込みベクトルのどの次元が分類に効いているかを分析する必要がある。

謝 辞

本研究の一部は、科学研究費補助金基盤研究 (C)(課題番号 18K11989)、新エネルギー・産業技術総合開発機構 (NEDO) の戦略的イノベーション創造プログラム (SIP) 第二期「ビッグデータ・AI を活用したサイバー空間基盤技術」および 2020 年度国立情報学研究所共同研究 (20FC07) の援助による。ここに記して深謝する。

文 献

- [1] 鉢木 稔浩, 太田 学, 高須 淳宏, “Web 資源を利用した学術論文閲覧支援システム,” 情報処理学会研究報告, Vol. 2009-DBS-149, No. 14, pp. 1-6, 2009.
- [2] 鉢木 稔浩, 太田 学, 高須 淳宏, “学術論文閲覧支援システムのための関連論文推薦,” 第 3 回データ工学と情報マネジメントに関するフォーラム (DEIM 2011), F9-4, 2011.
- [3] 阿辺川 武, 相澤 彰子, “脚注表示機能を備えた論文閲覧システム Sidenoter,” 第 20 回言語処理学会年次大会発表論文集, pp.796-799, 2014.
- [4] 阿辺川 武, 相澤 彰子, “内部構造解析機能と脚注表示機能を備えた論文閲覧システム,” 人工知能学会, 第 7 回インタラクティブ情報アクセスと可視化マイニング研究会, pp. 13-18, 2014.
- [5] 石井 仁子, 太田 学, 高須 淳宏, “引用意図を利用した学術論文閲覧支援のための適切な被引用箇所の特定,” 第 7 回データ工学と情報マネジメントに関するフォーラム (DEIM 2015), F3-5, 2015.
- [6] 情報検索システム評価用テストコレクション構築プロジェクト 第 9 回 NTCIR ワークショップ 成果報告会, <http://research.nii.ac.jp/ntcir/ntcir-9/index-ja.html>
- [7] David Jurgens, Srijan Kumar, Raine Hoover, Dan McFarland and Dan Jurafsky, “Measuring the evolution of a scientific field through citation frames,” Transactions of the Association for Computational Linguistics (TACL), Vol. 6 pp. 391-406, 2018.
- [8] Arman Cohan, Waleed Ammar, Madeleine Van Zuylen and Field Cady, “Structural Scaffolds for Citation Intent Classification in Scientific Publications,” In *NAACL*, pp. 3586-3596, 2019.

- [9] Prasad Animesh, Kaur Manpreet and Kan Min-Yen, “Neural ParsCit: A Deep Learning Based Reference String Parser,” International Journal on Digital Libraries, Vol. 19, pp. 327-337, 2018.
- [10] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser and Illia Polosukhin, “Attention Is All You Need,” In *Advances in Neural Information Processing Systems*, Vol. 30, pp. 5998-6008, 2017.
- [11] Jacob Devlin, Ming-Wei Chang, Kenton Lee and Kristina Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Vol. 1, pp. 4171-4186, 2019.
- [12] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville and Yoshua Bengio, “Generative Adversarial Nets,” In *Advances in Neural Information Processing Systems*, Vol. 27, pp. 2672-2680, 2014.
- [13] Ali Razavi, Aaron van den Oord and Oriol Vinyals, “Generating Diverse High-Fidelity Images with VQ-VAE-2,” In *Advances in Neural Information Processing Systems*, Vol.32, pp. 14866-14876, 2019.
- [14] Reimers Nils and Gurevych Iryna, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pp. 3982-3992, 2019.
- [15] Junyoung Chung, Caglar Gulcehre, KyungHyun Cho and Yoshua Bengio “Empirical evaluation of gated recurrent neural networks on sequence modeling,” In *NIPS 2014 Workshop on Deep Learning*, 2014.