

日常行動に沿った鑑賞曲の音響特徴量に関する検証

黒子 なるみ[†] 大矢 隼士[‡] 伊藤 貴之[†]

[†]お茶の水女子大学 〒112-0012 東京都文京区大塚 2-1-1

[‡]株式会社レコチョク 〒150-0002 東京都渋谷区渋谷 2-16-1

E-mail: [†] {gl520511, itot}@is.ocha.ac.jp, [‡] hayato.oya@recochoku.co.jp

あらまし 一般的にユーザが鑑賞する楽曲を選曲する際に、その時の行動が判断に影響を与えることはよく知られている。我々はこの考え方を応用して、日常生活の中で繰り返される習慣的動作において鑑賞したい楽曲の音響特徴量を音楽推薦に用いる手法を検討している。ここで、どのような行動中にどのような音響特徴量を有する楽曲が好まれるのかを深く検証することで、日常行動と楽曲の相関に対する理解を深め、音楽推薦の満足度向上につなげられると考えられる。そこで我々は、日常的な行動をシチュエーションごとに分けて、そのシチュエーションにおいて聴きたいと思う楽曲の相関を検証するための可視化を試みた。本報告では、日常的な各シチュエーションでの被験者群の選曲結果とその音響特徴量を検証するためのいくつかの可視化手法、およびその可視化結果について紹介する。

キーワード 音楽情報処理, 可視化, 行動ベース, 音響特徴量

1. はじめに

近年では主に海外主要国において、ストリーミングサービスが音楽鑑賞の主たるメディアとなってきた。これらの環境の変化により、人々はインターネット上で何百万もの楽曲を、場所に左右されずに聴くことができるようになった。しかし、このように視聴可能な楽曲の選択肢が増えるにつれて、ユーザは情報過負荷な状態となり、単純な決定方略が取られやすくなってしまった[1]。そこで我々は、ユーザの好みに合わせた楽曲を自動選曲する音楽推薦システムの研究に注力した。

Song らの音楽推薦に関する広範なサーベイによると、音楽推薦手法は大きく 6 種類に分類される[2]。メタデータ、音響データ、協調フィルタリング、文章、感情、ハイブリットの 6 種類である。最近では、日時や場所[3]、行動[4]などの複数の要因が選曲に影響する傾向が注目されており、音響データと他の要因を同時に考慮した推薦手法が多数発表されている。

ユーザの日常行動に基づく音楽推薦システムに関しても、これまでいくつか開発されてきた。Wang ら[4]の研究では、時間帯や位置情報からユーザの日常行動を推測し、その行動に適した楽曲を推薦するシステムを開発した。Åman ら[5]の研究では、スマートフォンに搭載されたセンサによって検出できる情報（ユーザの位置情報、移動のペース、マイクからの音声など）をもとに、ユーザがどんな日常行動をしているかを検出し、それに適した楽曲を推薦するシステムを開発した。しかし、これらの手法では、推薦理由を提示していない。

情報推薦システムにおいてアイテムの推薦時にそ

の推薦理由を提示することは、推薦アイテムに対して説明性を持たせることにつながり、システム全体に対する信頼度の向上を期待できることから、重要視されている[6]。

そこで我々も、根拠のある推薦理由を提示することで説明性の高い楽曲推薦システムを開発することを目標として音楽推薦の研究を進めている。その一環として本報告では、以下の 2 点を可視化によって検証した結果を示す。

- 日常行動と音響特徴量の関係性
- ユーザ間の選曲傾向の差異

第 2 章では、効果的な可視化システムの設計に関連する研究について紹介する。第 3 章では、提案する可視化手法の処理手順について紹介し、第 4 章では、実行結果について紹介する。最後に第 5 章では、今後の課題を提示し、本研究を締めくくる。

2. 関連研究

本章では、効果的な可視化システムの設計に関連する研究について紹介する。

2.1. 概要画面と詳細画面

音楽鑑賞のデータは楽曲自体の情報（音響特徴やメタデータ）と鑑賞者の情報（再生履歴や日常生活など）が絡んだ複合的なデータである。我々自身による先行研究[7]では、このような複合的なデータの分析には単一の可視化システムでは不十分であることを示唆した。そこで着目したのが、概要画面と詳細画面で構成される可視化システムを提案した Cockburn ら[8]のアプローチである。Cockburn らは、概要画面と詳細画面をわ

けることが分析過程において効果的であることを示している．一方で、それらを1つの可視化システムに配置するには2つの問題があるとしている．1点目は、可視化の画面空間に限りがあるという問題である．2点目は、大規模なデータにおいて2つの可視化間の連動に時間がかかり過ぎてしまう問題である．人間が同時に処理できる情報量は限られているため、その量を超えた大量の情報を同時に表現しても、分析の役に立たない可能性がある．そこで本研究では、複数の可視化画面を相互操作することを前提とした可視化システムを開発するのではなく、独立に開発した複数の可視化画面を組み合わせる形で分析を実施する．このように、可視化画面を独立させることによって、1つ1つの可視化を正確に知覚して、分析することができると期待している．

本研究では、概要画面によって日常行動と音響特徴量の関係性を解明し、詳細画面によってユーザ間の選曲傾向の差異を解明することを目指す．

2.2. Node-link と Matrix

ユーザと楽曲の視聴関係のような、データ間の関係性を表現する一般的な可視化手法として、Node-link と Matrix がある．図1に Node-link と Matrix の概略図を示す．これら2つの可視化手法は、同じ情報を表現する可視化手法である[9]が、以下のような特徴がある．Node-link は、可視化結果を直感的に理解することが可能であるが、ノードやエッジの重なりを解消することが難しいという問題がある．Matrix は、データ間の重なりが生じないため、全てのデータを均等に可視化することが可能であるが、データセットの規模が大きくなると横または縦に広がってしまうため、画面占有面積を抑えることが難しいという問題がある．このように、データセットの大きさや密度によって、視認性が大きく左右されるため、優位性については今なお議論に決着がついていない [10]．そこで本研究では、どちらか一方に限定するのではなく、両者の利点を活かした分析を実施する．




図1 Node-link と Matrix の概略図

本研究では、音楽鑑賞の全体的な特徴や傾向を把握するための近似曲線を概要画面として採用し、より局所的な特徴や傾向を発見するための詳細画面としてネットワーク可視化(Node-link)とヒートマップ(Matrix)を採用する．以上の3つの可視化システムを組み合わせることで、日常行動と音響特徴量の関係性とユーザ間の選曲傾向の差異を分析する．

3. 提案手法

本章では、3つの可視化システムを開発するための各処理について論じる．可視化システムの概要を図2に示す．3.1節では本研究で用いるデータ、3.2節では日常行動と楽曲に関するアンケート、3.3節では1つ目の可視化手法である近似曲線、3.4節では2つ目の可視化手法である Koala というネットワーク可視化手法、3.5節では3つ目の可視化手法であるヒートマップについて説明する．

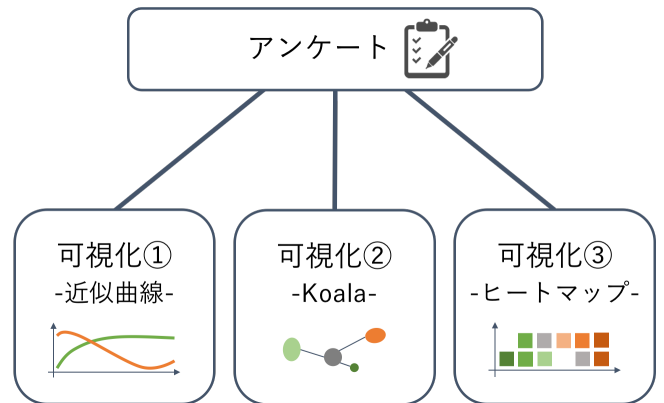


図2 可視化システムの概要

3.1. 使用データ

3.1.1. 日常行動

我々は自身の先行研究[7]から、楽曲の視聴場所と音響特徴量には相関があるという知見を得た．これに続く工程として本研究では、活動の場所を一箇所に限定し、日常行動の違いのみに着目して選曲の傾向を分析することとした．

NHK の調査[11]によると、日本人の在宅時間は、1995年から増加傾向にあった．さらに、昨今の新型コロナウイルス(COVID-19)が、在宅時間の増加に拍車をかけている．このように、1日の大半を家で過ごす機会が多くなった現状を鑑みて、本調査では、活動の場所を家に限定した．

我々が採用している日常行動と想定しているシチュエーションを表1に示す．これらの日常行動の選定に際して我々は、先行研究[12], [13]を参考にして、家で想定される全ての日常行動を採用した．

表 1 日常行動一覧

日常行動	シチュエーション
食事	1人でご飯を食べている
入浴	湯船に浸かっている
掃除	荷物を片付けている
料理	ご飯を作っている
音楽鑑賞	ゆったりとしている
勉強	レポートを書いている
運動	筋トレをしている

3.1.2. 音響特微量

本研究では、音響特微量解析ツール Librosa[14]を用いて各楽曲の音響特微量値を算出している。現段階で我々が採用している音響特微量は、「テンポ、音量、明るさ」の3値である。この3値の定義を以下に示す。

テンポ (beat_track) : 1分間の拍数を示す値。

音量 (rms) : 音の大きさを示す値。ある時間ウィンドウ幅における音量振幅の二乗平均平方根。

明るさ (spectral_centroid) : 音の明るさを示す値。

周波数成分をパワーによって重みつけた平均(スペクトル平均)。

これらの音響特微量の選出には、librosaによって得られる音響特微量間の相関係数値を適用している。2つの音響特微量間の相関係数が0に近いということはつまり、数学的にはそれぞれの変数が独立であることを示している。2つの音響特微量がそれぞれ異なる指標を表している組み合わせを模索した結果として、我々は上記の3値を選出した。ただし、テンポ(beat_track)の値は、4ビートや8ビート等の識別が難しく、算出結果に誤りが生じてしまったため、明らかに誤りとわかる算出結果については手動で修正した。また、音量(rms)と明るさ(spectral_centroid)は、単位時間ごとに特微量値を算出していて、1曲に対して一意に定まっていなかったため、本手法では算出された値の平均値を各楽曲の音響特微量とした。

3.2. アンケート

アンケートでは、各日常行動に対する選曲を調査した。アンケートに使用したフォームの概要を図3に示す。本アンケートでは、2012～2013年にCDの売り上げが高かった50曲と、3.1.1項で述べた7つの日常行動のマトリクス形式で実施した。マトリクス形式にすることによって、「聴きたい曲、聴きたくない曲、どちらでもない曲」の3段階で、日常行動と楽曲の全ての組み合わせに対して評価をしてもらった。想定する視聴環境の違いによって、アンケート結果に差が生じてしまう可能性がある。そのため、スピーカを用いて一人で聴いていることを想定してもらうことで視聴環境を統一した。

本アンケートを実施することで、18歳から30歳(平均年齢22歳)の男女44人の回答を得た。回答者のうち33人が女性、11人が男性であった。一方で、Geringerら[15][16]の研究によると、3年以上の楽器経験の有無が選曲に影響を与えるとされている。これを検証するために本アンケートにおいても、回答者が楽器を経験したことがあるかを調査した。その結果、今回の回答者のうち、30人が3年以上の楽器経験があり、14人が楽器を経験していなかった。

	行動1	行動2	行動3	...
楽曲1				
楽曲2				
楽曲3				
⋮				

○ : 聴きたい
- : どちらでもない
× : 聴きたくない

図 3 アンケートフォーム

3.3. 可視化① -近似曲線-

ユーザの選曲と音響特微量との全体的な傾向を把握するために、本研究では近似曲線を可視化手法として採用する。音響特微量をテンポとした可視化画面を図4に示す。

この可視化では、楽曲を横軸に沿って左右に並べている。音響特微量の値によって楽曲を左から右へ順にソートすることで、視認性の向上を図っている。図4の例では、テンポが遅い楽曲が左側、テンポが速い楽曲が右側に配置されている。また、横軸のプロット幅は楽曲の音響特微量を正規化することで調節している。縦軸は、それぞれの行動において、各楽曲に対してアンケートで「聴きたい」を選択した被験者の割合を表している。各曲に対する縦軸の割合 x は以下の式(1)によって算出される。

$$x = \frac{\text{「聴きたい」を選択したユーザ数}}{\text{評価したユーザ数}} \quad (1)$$

また、可視化画面の下に設置したスライダーを操作することによって、曲線の次数を1から10まで、10段階で調節することが可能である。




図 4 近似曲線可視化画面

3.4. 可視化② -Koala-

各ユーザの楽曲視聴に関する局所的な傾向を把握するために、本研究はネットワーク可視化手法である Koala[17]を拡張する形で採用する。Koala とは、ノードをクラスタリングして配置するグラフ可視化手法である。日常行動を入浴とした可視化画面を図 5 に示す。

この可視化では、ユーザと楽曲の両方がノードとして描画されている。エッジは、3.2 節で調査したアンケート項目（聴きたい曲、聴きたくない曲、どちらでもない曲）のうち、可視化したい関係にもとづいて生成している。例えば、ユーザが「聴きたい」とした楽曲との視聴関係を可視化したい場合は、ユーザが各日常行動中に「聴きたい」とした楽曲をエッジで結んでいる。図 5 ではユーザが入浴中に「聴きたい」とした楽曲をエッジで結んでいる。

Koala はクラスタを単位として各ノードを画面に配置する。それぞれのクラスタは 1) 選曲の共通性の高いユーザのノード、2) 鑑賞者の共通性の高い楽曲のノードで構成されている。ノードを配置するためのアルゴリズムを以下に記載する。

1. クラスタをノードに置き換えたグラフを生成し、これに対してグラフ配置アルゴリズムを適用する。
2. 各クラスタを構成するノード数から、各クラスタの半径を計算する。
3. エッジ長が両端のノードの半径の合計値にできるだけ近くようにスムージング処理を適用する。
4. クラスタ内にそのクラスタを構成するノードを配置する。

以上の手順によって、同じクラスタに分類されたノードを近くに配置する。

ノードはユーザの属性および楽曲の音響特徴量で配色されている。図 5 では、ユーザに対応するノードは性別で配色されており、楽曲に対応するノードは音量で配色されている。楽曲ノードとユーザノードを視覚的に判別するために、本研究では異なる色相を両者

に割り当てている。楽曲ノードでは、各音響特徴量の値を表している。音響特徴量の値が小さい値から大きい値へと順に、青から赤のレインボーカラーを割り当てている。ユーザノードの色は各ユーザの属性を表している。現時点の実装では、ユーザの性別と 3 年以上の楽器経験の有無の 2 種類の属性のいずれかを配色に用いている。ユーザの性別でユーザノードを配色する際には、女性にはピンク、男性には紫を割り当てている。ユーザの楽器経験でユーザノードを配色する際には、楽器経験があるユーザにはピンク、楽器経験のないユーザには紫を割り当てている。

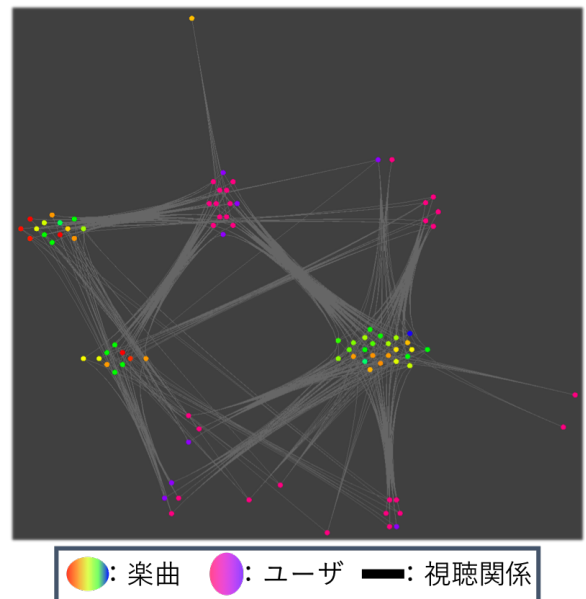


図 5 Koala 可視化画面

3.5. 可視化③ -ヒートマップ-

各ユーザの選曲傾向を詳細に把握するために、本研究ではヒートマップを採用する。これによって、ユーザ間の選曲傾向の違いがあるのかを 1 曲単位で観察できる。日常行動を音楽鑑賞、音響特徴量をテンポとした可視化画面を図 6 に示す。

楽曲は横軸に沿って並べられている。3.3 節の近似曲線と同様に、音響特徴量の値によるソートが適用されている。ユーザは縦軸に沿って並べられている。ユーザに階層クラスタリングを適用することによって、選曲傾向が類似しているユーザが近くに配置されるように並び順を決定し、選曲傾向の視認性を向上させる。

階層クラスタリングでは、要素間の類似度（距離）にもとづいて、最も類似度の高い要素から順に凝集することでクラスタを作る。本手法では、ユーザごとの「聴きたい」を選択した楽曲群にもとづいて、以下の手順によってクラスタリングを実施した。

1. 音響特徴量の値が低い楽曲から順に 5 曲ずつ区分する。

- 5 曲ごとに、ユーザごとに「聴きたい」を選択した楽曲の音響特微量平均値のリストを算出する。
- リスト間の距離を算出する。本手法では、距離算出にユークリッド距離を用いた。

以上の手順により、選曲傾向が類似しているユーザを近くに配置した。なお本研究では、クラスタ間の距離算出には完全連結法を採用した。これは、各々のクラスタの中で最も距離の大きいベクトル間距離をそのクラスタ間の距離とするものである。

また、プロットの色には、3.2 節のアンケートで分類した、「聴きたい曲、聴きたくない曲、どちらでもない曲」の3段階の色を割り当てている。ユーザが「聴きたい」とした楽曲には、音響特微量が小さい値から大きい値へ順々に、緑から赤の色を割り当てている。ユーザが「聴きたくない」とした楽曲、「どちらでもない」とした楽曲には、それぞれ灰色と白色を割り当てている。




図 6 ヒートマップ可視化画面

4. 実行例

本章では、3 つの可視化システムによる分析結果について論じる。4.1 節では 1 つ目の可視化手法である近似曲線、4.2 節では 2 つ目の可視化手法である Koala、4.3 節では 3 つ目の可視化手法であるヒートマップの分析結果について述べる。

4.1. 近似曲線

3.3 節の手順で算出した曲線上のいくつかの点を用いて、各行動間の選曲傾向の類似性を分析した。行動間の類似度算出にはコサイン類似度を用いた。

コサイン類似度とは、ベクトル空間モデルにおいて、ベクトルの内積を用いて類似度を算出する方法である。1 に近いほど類似しており、1 よりも小さいほど類似していないことを示す。本研究では、3 つの音響特微量ごとに、各日常行動のコサイン類似度を、以下の式(2)によって算出した。ただし、類似度を $\cos(A, B)$ 、曲線ベクトルを A, B とする。ここで、曲線を等間隔に分割した際の、分割点のリストを曲線ベクトルとした。なお本研究では、曲線を 4 等分に分割して得られた、5 つの

分割点による「聴きたいユーザの割合」を 5 次元ベクトルとして扱った。

$$\cos(A, B) = \frac{A \cdot B}{\|A\| \|B\|} \quad (2)$$

式(2)によって算出したコサイン類似度を、以下の表 2 に示す。表 2 では視認性向上のため、各日常行動において、最も類似度が高かった値を強調表示している。この結果によると、入浴と音楽鑑賞、食事と勉強と料理、掃除と運動はそれぞれ選曲傾向が類似していることが読み取れる。

表 2 コサイン類似度算出表

				運動	
				掃除	0.98119
				料理	0.93151
				勉強	0.89453
				食事	0.88191
				音楽鑑賞	0.82990
入浴		0.99786	0.98350	0.97638	0.95951
					0.89454
					0.93151

表 2 より分類した 3 種類の選曲傾向と音響特微量との相関を視認によって確認した。視認性向上のために、可視化画面下のスライダーを用いて、次数を 1 にした可視化画面を図 7 に示す。1 つ目の選曲傾向は、入浴と音楽鑑賞である。これらは、どちらも傾きが右下がりになっている。すなわち、音量が小さい楽曲が好まれるという点で選曲傾向が類似している。2 つ目の選曲傾向は、食事と勉強と料理である。これらは、いずれも傾きがなく、水平である。すなわち、選曲された楽曲は、音響特微量による差異がないという点で選曲傾向が類似している。3 つ目の選曲傾向は、掃除と運動である。これらは、どちらも傾きが右上がりになっている。すなわち、音量が大きい楽曲が好まれるという点で選曲傾向が類似している。




図 7 次数 1 の近似曲線可視化画面

以上の分析を 3 つの音響特微量の各々において施した結果を表 3 に示す。表 3 より、3.1.1 節に示した 7 項目の日常行動は、大きく 3 種類の選曲傾向に分類される。入浴と音楽鑑賞には、スローテンポ・小音量・暗い、バラードのような曲調の楽曲が好まれる傾向にある。食事と勉強と料理には、音響特微量による差異が

ほとんど見られない．掃除と運動は，アップテンポ・大音量・明るい，バンドやアイドルソングのような曲調の楽曲が好まれる傾向にある．

表 3 選曲傾向の分類

	入浴	音楽鑑賞	食事	勉強	料理	掃除	運動
テンポ	遅	遅	差異なし	差異なし	差異なし	速	速
音量	小	小	差異なし	差異なし	差異なし	大	大
明るさ	暗	暗	暗	差異なし	差異なし	明	明

4.2. Koala

Koala を適用して 3.4 節の手順によって形成されたユーザと楽曲のネットワークを観察し，ユーザと楽曲の関係性を分析した．

4.2.1. アーティスト分類

3.2 節で調査したアンケート項目のうち，ユーザが「聴きたい」とした楽曲をエッジで結んだ場合に，楽曲クラスタの中に同一アーティストが多く分類された．本研究で使用した 50 曲，合計 31 組のアーティストのうち，19 組のグループが以下の表 4 に示す 4 つのグループに分類された．4 つのグループのうち，グループ 4 に含まれるアーティストのほとんどは，洋楽を歌っていた．このことから，洋楽をよく聴くユーザが複数いたことが推測される．また，それぞれの日常行動間でのアーティスト分類には，あまり差異が見られず，全体を通して同じようなグループに分類された．以上の結果から，ユーザは日常行動を考慮した選曲とは別に，各ユーザが好きな固有のアーティストの楽曲を積極的に選曲していることが推測される．

表 4 アーティスト分類

グループ1 <13曲>	グループ3 <6曲>	グループ4 <12曲>
AKB48	サザンオールスターズ	サカナクション
きゃりーぱみゅぱみゅ	ナオトインティライミ	AI
ももいろクローバーZ	superfly	Maroon5
	ケラケラ	Carly Rae Jepsen
	Ms.OOJA	One Direction
		Lady Gaga
		Rihanna
		Nicki Minaj
		Zeed

グループ2 <3曲>
perfume
miwa

4.2.2. 視聴関係と音響特徴量

3.2 節で調査したアンケート項目のうち，ユーザが「聴きたくない」とした楽曲をエッジで結んだ場合に，顕著な特徴が見られた．日常行動を入浴と音楽鑑賞，音響特徴量をテンポとした可視化画面を図 8 に示す．図 8 に示す青丸の部分には，寒色系のプロットが集まっている．これらのプロットは，楽曲クラスタを表すノードであり，配色が寒色系であるということは，テンポが低いことを表している．つまり，入浴と音楽鑑

賞の可視化画面では，テンポが遅い楽曲がクラスタを形成していることを表している．さらに，このクラスタとエッジで結ばれているユーザ数は，他のクラスタと比較して少ないことが読み取れる．この可視化画面では，ユーザが「聴きたくない」とした楽曲をエッジで結んでいる．つまり，テンポが遅い楽曲を「聴きたくない」としているユーザ数は，他のクラスタと比較して少ないということが読み取れる．ここで，音響特徴量に明るさを選んだ場合でも，同様の可視化結果が得られた．以上を踏まえると，日常行動が入浴と音楽鑑賞の場合には，ユーザは特にテンポと明るさを選曲時に考慮していて，スローテンポで暗い曲調の楽曲が好まれることが読み取れる．

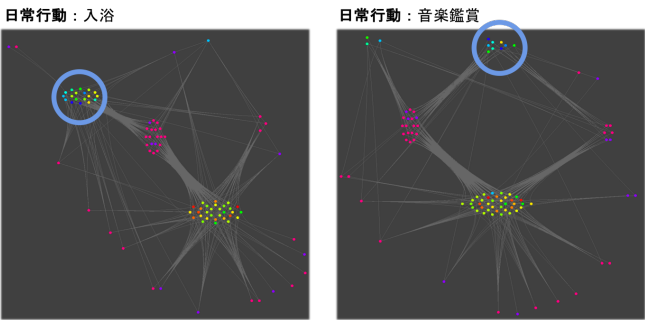


図 8 入浴・音楽鑑賞の Koala 可視化画面

一方，日常行動を掃除と運動，音響特徴量を音量とした可視化画面を図 9 に示す．図 9 に示す赤丸の部分には，暖色系のプロットが集まっている．つまり，掃除と運動の可視化画面では，音量が大きい楽曲のクラスタが形成されていることを表している．また図 9 でも，このクラスタとエッジで結ばれているユーザ数が，他のクラスタと比較して少ないことが読み取れる．以上のことから，日常行動が掃除と運動の場合には，ユーザは特に音量を考慮した選曲をしていて，音量が大きい楽曲が好まれることが読み取れる．

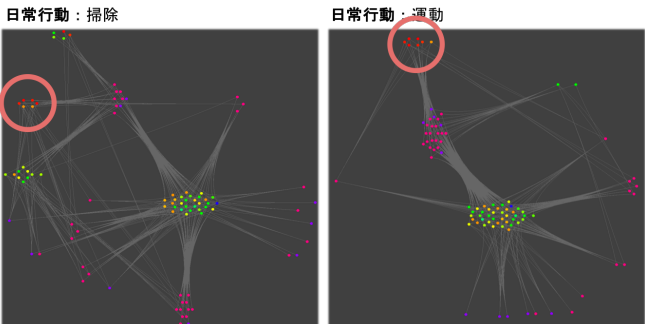


図 9 掃除・運動の Koala 可視化画面

図 8 と図 9 の分類は，4.1 節で分類された選曲傾向と一致している．このことから，表 3 の分類は適切であることが示唆される．また，Koala による分析結果から，7 項目の日常行動によって，重視されている音響特徴量に違いがあることがわかった．

4.3. ヒートマップ

3.5 節の手順で形成された階層クラスタリングとヒートマップをもとに、ユーザの選曲について分析した。日常行動を音楽鑑賞、音響特徴量を音量とし、階層クラスタリングを適用した可視化画面を図 10 に示す。図 10 の可視化画面右側に表示された階層クラスタリング結果に着目すると、ユーザが大きく 2 つのクラスタに分類されていることを読み取れる。ヒートマップからもユーザの選曲傾向が二分されていることがわかる。下側のクラスタは、ヒートマップ部分において、可視化画面の左から右まで均一に「聴きたい」楽曲が選択されている。このことから、これらのクラスタに含まれるユーザの選曲は音量に相関していないことがわかる。一方上側のクラスタは、ヒートマップの部分において、可視化画面右側の音量が大きい楽曲は、ユーザが「聴きたい」とした楽曲が選択されていなかった。このことから、これらのクラスタに含まれるユーザの選曲は音量に相関していることがわかる。このような、音響特徴量全般に相関した選曲傾向を有するユーザのクラスタは、3.1.1 項で示した 7 項目の日常行動のうち、入浴・音楽鑑賞・食事・勉強・料理の 5 つの日常行動において見られた。これら 5 つの日常行動は、4.1 節で分類された選曲傾向と一致している。




図 10 ヒートマップ可視化画面

続いて、音響特徴量全般に選曲が相関するユーザが多いクラスタを対象として、ユーザの特徴を調査した。その結果、楽器経験の有無と大きな関係があることがわかった。図 11 では、音響特徴量に選曲が相関するユーザが多いクラスタにおける、楽器を経験していたユーザの割合をグラフとして図示した。ただし、日常行動が料理、音響特徴量が音量の場合は、選曲傾向の違いを確認できなかったため、グラフを省略している。本アンケートに回答してくれたユーザのうち、楽器経験者の割合は 70%未満である。それに対して、図 11 に示す結果から、クラスタに含まれる楽器経験者の割合が全体的に高いことが読み取れる。特に、楽曲の明るさとテンポはどの日常行動を見ても楽器経験者の割合が非常に高い。以上により、楽器経験者の選曲には、テンポや明るさとの相関が高いことがわかった。




図 11 当該クラスタにおける楽器経験ユーザの割合

5. まとめと今後の課題

本報告では、3 つの可視化システムを用いて、日常行動と音響特徴量の関係を分析した事例を報告した。

3 つの可視化システムによる分析結果のまとめを図 12 に示す。ユーザはそれぞれの日常行動に適するような音響特徴量の楽曲を選曲していること、また選曲に相関する音響特徴量は日常行動によって異なることがわかった。また、ユーザごとに選曲傾向が異なる日常行動と、ユーザ全体にわたって同様な選曲傾向となる日常行動に分類されることもわかった。続いて各々の日常行動に着目すると、掃除と運動における楽曲推薦の優先度は、ユーザの好きなアーティストより、音響特徴量、特に音量を考慮すべきであることが示唆される。それに対して、その他の 5 つの日常行動における楽曲推薦の優先度は、ユーザによって個人差があることが見受けられた。これらの日常行動において、音響特徴量（特にテンポと明るさ）を優先して選曲するユーザ、ユーザが好きなアーティストを選ぶユーザ、これらの両方の傾向が現れるユーザ、といった 3 種類の選曲傾向に分類されることが示唆された。

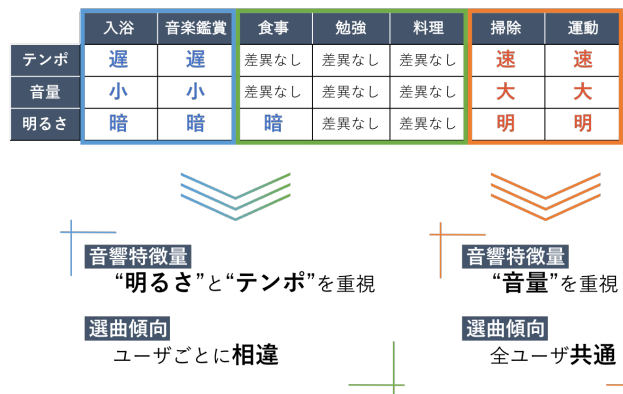


図 12 分析結果まとめ

このような結果を利用することで、楽曲推薦の説明性を高められると考えられる。言い換えれば、各ユーザがどのような選曲傾向を有するかを見極めて、楽曲推薦の優先度を定めることが重要となると考えられる。以上のように、ユーザ個人に適合した推薦理由である

ことを提示することで、推薦システムへの信頼度を向上させることができると考える。

今後の課題として、ユーザ属性を考慮した分析の充実、可視化システム間の連携強化の2点を目標としている。1点目のユーザ属性とは、現時点ではユーザの性別と楽器経験の有無といった情報を指す。これらの属性を考慮した分析については、現時点では3つ目の可視化システムであるヒートマップでしか傾向を発見できていない。そのため、他の可視化システムでも分析を進め、さらに新しい分析結果の解明に努めたい。2点目の可視化システム間の連携強化については、本報告における分析結果からも、3つの可視化システムを組み合わせることによって、解明された点が多いことがわかる。そこで、3つの可視化システム間の連携をより強化することによって、さらなる分析を実施したいと考えている。連携を強化するための一例として、ユーザが好きなアーティストの楽曲を除外したデータで再度可視化することを想定している。

参 考 文 献

- [1] Barry Schwartz, “The Paradox of Choice: Why More Is Less”, Harper Perennial, 2005.
- [2] Yading Song, Simon Dixon, “Marcus Pearce : A Survey of Music Recommendation Systems and Future Perspectives”, Conference paper, 2012.
- [3] Zhiyong Cheng, Jialie Shen, “On Effective Location-Aware Music Recommendation”, Submitted to ACM TOIS, pp. 13:1–13:32, 2016.
- [4] Xinxi Wang, David Rosenblum, Ye Wang, “Context-Aware Mobile Music Recommendation for Daily Activities”, In Proceedings of the ACM International Conference on Multimedia, 2012.
- [5] Pirkka Åman, Lassi A Liikkanen, “Interacting with Context Factors in Music Recommendation and Discovery”, International Journal of Human-Computer Interaction, 33(3), pp.165-179, 2017.
- [6] Nava Tintarev, Judith Masthoff, “A survey of explanations in recommender systems”, IEEE 23rd International Conference on Data Engineering Workshop, pp. 801-810, 2007.
- [7] Narumi Kuroko, Hayayo Ohya, Takayuki Itoh, Nicolas Grossmann, Hsiang-Yun Wu, “Visualization of Correlations between Places of Music Listening and Acoustic Features”, In Proceedings of the 24th International Conference on Information Visualisation (iV2020), pp. 22-27, 2020.
- [8] Andy Cockburn, Amy Karlson, Benjamin B. Bederson, “A review of overview+detail, zooming, and focus+context interfaces”, ACM Computing Surveys, vol. 41, pp. 2:1–2:31, 2009.
- [9] Donghao Ren, Laura R. Marusich, John O’Donovan, Jonathan Z. Bakdash, James A. Schaffer, Daniel N. Cassenti, Sue E. Kase, Heather E. Roy, Wan-yi (Sabrina) Lin, Tobias Höllerer, “Understanding Node-Link and Matrix Visualizations of Networks: A Large-scale Online Experiment”, Network Science, 7(2), pp. 242-264, 2019.
- [10] Mershack Okoe, Radu Jianu, Stephen Kobourov, “Revisited network representations,” in 25th Symposium on Graph Drawing (GD), 2017.
- [11] NHK 放送文化研究所, “2015 年国民生活時間調査報告書”, 2015.
- [12] Sergey Volokhin, Eugene Agichtein, “Understanding Music Listening Intents During Daily Activities with Implications for Contextual Music Recommendation”, In Proceedings of the 2018 Conference on Human Information Interaction & Retrieval (CHIIR ’18), pp. 313–316, 2018.
- [13] Adrian C. North, David J. Hargreaves, Jon J. Hargreaves, “Uses of music in everyday life. Music Perception”, 22(1), pp. 41–77, 2004.
- [14] Brian McFee, Colin Raffel, Dawen Liang, Daniel P.W. Ellis, Matt McVicar, Eric Battenberg, Oriol Nieto, “librosa: Audio and Music Signal Analysis in Python”, Proc. of the 14th Python in Science Conf. (SCIPY), pp. 18-24, 2015.
- [15] Clifford K. Madsen, John M. Geringer, “Differential patterns of music listening: Focus of attention of musicians versus Nonmusicians”, Bulletin of the council for Research in Music Education, 105, pp. 45-47, 1990.
- [16] John M. Geringer, Clifford K. Madsen, “Focus of attention to element: Listening patterns of musicians and Nonmusicians”, Bulletin of the Council for Research in Music Education, 127, pp. 80-87, 1995.
- [17] Takayuki Itoh, Karsten Klein, “Key-node-Separated Graph Clustering and Layout for Human Relationship Graph Visualization”, IEEE Computer Graphics and Applications, Vol. 35, No. 6, pp. 30-40, 2015.