

機械学習アプローチに基づく中古ファッションアイテムの価格保持期間の適正化モデルと実証的效果検証

桑田 和[†] 三川 健太^{††} 後藤 正幸^{†††} 佐々木北都^{††††}

[†] 早稲田大学大学院 〒169-8555 東京都新宿区大久保

^{††} 湘南工科大学 〒251-8511 神奈川県藤沢市

^{†††} 早稲田大学 〒169-8555 東京都新宿区大久保

^{††††} 株式会社 ZOZO 〒261-7116 千葉県千葉市美浜区

E-mail: [†]ikdsk14243150@toki.waseda.jp, ^{††}mikawa@info.shonan-it.ac.jp, ^{†††}masagoto@waseda.jp,

^{††††}hokuto.sasaki@zozo.com

キーワード 販売履歴データ, 機械学習, Natural Gradient Boosting, 確率分布推定, プロパー期間, 中古ファッションアイテム

1 研究背景と目的

本研究では、ファッション通販サイト ZOZOTOWN 内で古着を販売する ZOZOUSED における値下げのタイミングの適正化に関する問題を対象とする。ZOZOUSED は、ユーザから古着を買い取り、中古品として再販売する事業を展開する EC サイトである。このようなビジネスでは、ほぼ一品物に近い多様なアイテムの全てに対し需要を正確に予測することは大変難しいことから、確実に販売でき、かつ利益も上がるような完璧な価格を予め設定することは至難の業である。このような背景のもと、出品する商品（以下、アイテム）の売れ残りを防ぐため、出品から一定期間経過したアイテムの価格を段階的に下げる仕組みを採用している。アイテムを出品した際の初期価格は出品価格と呼ばれ、収益性の観点からは、値下げをせずに出品価格で販売することが望ましい。しかしながら、在庫コストや出品アイテムの鮮度といった観点からは、値下げを許容し、早く販売することも必要となる。そのため、出品価格を保持する期間の適切な設定は重要な課題の一つとなっており、本研究ではこの保持期間を「プロパー期間」と定義する。

一方、アイテムの購入はユーザの意思決定によるものであり、各アイテムの出品から誰かに購入されるまでの期間（以下、掲載期間）はアイテムの購入されやすさを表したものであると考えられる。そのため、プロパー期間の決定には予想される掲載期間を考慮する必要がある。しかし、各アイテムの掲載期間のばらつきは非常に大きく正確な一点予測は困難であるため、この点をどのようにモデル化してプロパー期間の決定に結び付けられるかを検討しなければならない。例えば、仁ノ平らは、中古ファッションアイテムの販売価格の予測モデルを提案しており、ある商品カテゴリに対しては現実的に有用な制度が得られるとしているが [1], 商品カテゴリによっては予測精度が大きくなってしまいうことも示しており、同様のことはプロパー期間に対しても言えることである。加えて、季節性のあるアイテムも存在

するために、たとえ同じ商品であっても常に同じプロパー期間を適用することが合理的とは限らない、という点にも考慮が必要である。例えば、同じコートであっても、秋や冬に出品する場合には購入者が現れやすいが、春や夏に出品する場合には購入者が現れにくいと、季節によって購入されやすさが異なる。これらに合わせたプロパー期間が必要であると考えられる。これらの解決のため、前者に対しては掲載期間のばらつき方を予測することを考え、後者に対してはアイテムの出品月ごとにプロパー期間を設定することを考える。

上記の議論のもと、本研究では、各出品月におけるアイテムの適切なプロパー期間の決定方法を提案する。提案手法ではまず、各アイテムの掲載期間を確率分布で予測するモデルを構築する。予測モデルには、勾配ブースティングの 1 つである Natural Gradient Boosting (NGBoost) [2] を用いる。さらに、アイテムの特徴量のうち、出品月のみを変化させて予測を繰り返すことで、適切なプロパー期間を決定する。本研究では、提案手法の有効性を検証するため、ZOZOUSED の販売履歴データに提案手法を適用し、分析結果に対する考察を行う。加えて、提案手法の実運用における有効性を検証するため、新規出品アイテムに対して決定したプロパー期間を適用し、販売結果に対する分析と考察を行う。

2 関連研究

2.1 ファッション EC サイトを対象とした研究

ファッション業界を対象としたアイテムの売上予測や需要予測の研究はこれまでも報告されており、予測精度や計算速度といった観点から様々な手法が用いられている [3]。Thomassey et al. [4] は、クラスタリング手法と決定木を用いて、販売履歴データに基づく中期的な売上予測について研究している。Ni et al. [5] は、トレンド傾向、季節性といった要因を考慮した販売履歴データと外部要因に基づく長期売上予測と短期売上予測を組合せた 2 段階予測を行っている。一方、Au et al. [6] は、モデ

ルの計算コストの観点から研究を行い、遺伝的アルゴリズムを用いたニューラルネットワークによる短期的な売上予測を行っている。さらに、Choi et al. [7] は SARIMA とウェーブレット変換を組合せた手法による販売時系列データに基づく売上予測を提案している。

このように売上予測に関する研究が多くある一方、中古ファッションアイテムの販売価格を予測するモデルとして仁ノ平ら [1] の研究がある。仁ノ平らは、設定した出品価格のもとでアイテムを販売した場合の最終的な販売価格を予測するモデルを構築し、実販売データに対する予測精度の面からその有効性を示している。

以上のように、ファッション業界では顧客の購買行動分析や、アイテムの需要や価格の予測に関する研究が多くなされている。しかし、機械学習を用いた値下げの仕組み、特にプロパー期間の決定に焦点を当てた研究はこれまでに少なく、議論の余地があると言える。

2.2 Natural Gradient Boosting

Natural Gradient Boosting (NGBoost) は勾配ブースティングに自然勾配法 [8] を用いた手法である。

NGBoost は、弱学習器、任意の次元数のパラメータ θ を持つパラメトリックな確率分布、スコア関数の 3 つの構成要素を持つ。これらに対し、弱学習器を用いて確率分布のパラメータを学習し、推定された確率分布と観測値を用いてスコア関数を計算する。そして、スコア関数を最適化するようにして自然勾配を学習する。

いま、 $l-1$ 個目の弱学習器の学習で得られた条件付確率分布のパラメータを $\theta^{(l-1)}$ 、予測されたパラメータによる確率分布と観測値 v から算出されるスコア関数を $S(\theta^{(l-1)}, v)$ とする。このとき、 l 個目の弱学習器において、自然勾配 $g^{(l)}$ は式 (1) を用いて学習される。ただし、 \mathcal{I}_S はリーマン計量であり、スコア関数 S によって変化する。また、 $\nabla_{\theta} S$ は θ における S の通常の勾配である。

$$g^{(l)} = \mathcal{I}_S(\theta^{(l-1)})^{-1} \nabla_{\theta} S(\theta^{(l-1)}, v) \quad (1)$$

この自然勾配 $g^{(l)}$ を用いて学習された弱学習器によってパラメータ $\theta^{(l)}$ を更新し、確率分布を推定する。これにより、正確な一点予測が難しい問題に対しても、確率分布による予測や区間予測が可能となり、予測の不確実性を考慮した意思決定に結び付けられると期待できる。そのため、本研究で対象とする掲載期間の予測といった、一点予測が難しい問題に対して有用であると考えられる。

3 対象問題

3.1 問題設定

上述のように、ZOZOUSUED では、出品から一定期間経過したアイテムの価格を段階的に下げているが、収益性の観点からは出品価格のまま購入されることが望ましい。一方、ZOZOUSUED における従来のプロパー期間は経験的な方法によって決定されている。そのため、これまで値下げされて販売されたアイテム

は、プロパー期間をより長く設定していれば値下げされずに出品価格のまま販売できた可能性がある。そこで、適切なアイテムのプロパー期間を設定することが望まれる。

ZOZOUSUED では多数のブランドの幅広いアイテムを扱っているため、アイテムによって適切なプロパー期間が異なると考えられる。また、同じアイテムでも出品時期や使用状態によって販売傾向が異なるため、常に同じプロパー期間で値下げをすることは合理的ではない。そこで過去の販売履歴データを用いた機械学習により、掲載期間の予測モデルを構築することで適切なプロパー期間を決定することを考える。しかし、以下の 2 つの問題点が存在する。

- アイテムの多様性が非常に高く、掲載期間も様々な値を取るため、単純な回帰モデルを用いてこれらを点予測することは困難である。
- 季節性のあるアイテムも存在するため、全てのアイテムに対して常に同じプロパー期間で値下げをすることは適切でない。

そのため、この 2 つの問題点を考慮したプロパー期間の決定方法が必要である。本研究では、前者に対しては、その確率分布を予測することを考え、後者に対しては、出品月ごとにプロパー期間を設定することを考える。これにより、従来の仕組みによる値下げと比較して、アイテムの値下がり回避や、売上・粗利額の増加が期待できる。

3.2 事前分析

本章では、掲載期間の特徴を把握するため、過去に販売されたアイテムの掲載期間に関する基礎分析の結果を示す。以下は ZOZOUSUED において 2018 年 1 月 1 日から 2018 年 12 月 31 日に販売された購買履歴データの掲載期間に着目した分析結果である。

掲載期間におけるアイテム数を図 1 に示す。ただし、分布の特徴を捉えやすくするため、アイテム数が少ない 200 日以降は除いて分析を行った。




図 1 各掲載期間におけるアイテム数

図 1 から、掲載期間は 0 日が最も多くなっており、急速に減少してから 10~50 日程度で平坦となり、また減少するような形状となっていることが分かる。つまり、本サイトで扱われるアイテム多くは出品初日に販売されており、その一方で、販売まで 1 年近くかかるアイテムも存在していることが読み取れる。このことから、出品初日以外で販売されたアイテムの掲載期間はばらつきが大きいことが言える。

4 提案手法

4.1 着想

前述の通り、ZOZOUSSED で扱われるアイテムは多様性が高いため、掲載期間に寄与する特徴量はアイテムによって異なることが考えられる。そのため、多くのアイテムの掲載期間に寄与する特徴量を個々に把握することは膨大な時間を要し、合理的ではない。そこで、類似したアイテムごとにその特徴量を把握するため、アイテムをグルーピングすることを考える。本研究では、アイテム管理のために現場で導入されている管理単位である「ブランドクラス」を用いてアイテムをグルーピングする。ブランドクラスとは、ブランドクラス 1 の平均販売単価が高く、ブランドクラス 8 の平均販売単価が低くなるように分類されたアイテムの 8 つのクラスである。販売単価はアイテムの類似性に大きく寄与する特徴量であると考えられる。そのため、ブランドクラスを用いることで各アイテムの掲載期間に寄与する特徴量を把握しやすくなると期待できる。

前述のように、各アイテムの掲載期間はばらつきが大きく、掲載期間そのものを正確に予測することは困難である。また、事前分析より、掲載期間の分布は全体的な概形では指数分布に近いことが明らかとなっている。そのため提案手法では、各アイテムの掲載期間に指数分布を仮定し、3 章で述べた NGBoost を用いて掲載期間を予測する。これにより、掲載期間を確率分布の形で予測できるため、この分布をプロパー期間の決定に活用できると考えられる。

また、出品月によって掲載期間は変化すると考えられるため、出品月がアイテムの販売結果を大きく左右する特徴量であると考えられる。そこで、出品月を掲載期間に強く寄与する特徴量とみなし、各アイテムの出品月のみを変化させたときの販売確率の変動を用いて適切なプロパー期間の決定を考える。

4.2 概要

提案手法ではまず、ブランドクラスを用いてアイテムのグルーピングを行う。ブランドクラスごとに、学習データに対して NGBoost を適用し、各アイテムを出品した際の掲載期間の分布予測モデルを構築する。このとき、予測確率分布には指数分布を仮定する。

次に、アイテムの特徴量のうち、出品月のみをある月に固定したテストデータに、構築したモデルを適用する。予測の際に得られた各アイテムの確率分布から、 α 点の掲載期間を算出する。ただし、 α は値下げをせずに販売したいアイテムの割合として、実応用上の観点から現場レベルで決定される値である。そして、ブランドクラスごとに得られた各アイテムの掲載期間の平均値を算出し、適切なプロパー期間とする。固定する出品月を 1 月から 12 月まで変化させることで、各ブランドクラスにおける出品月ごとのプロパー期間を決定する。

4.3 アルゴリズム

いま、予測モデルの構築に用いる N 個の学習用アイテムと、プロパー期間を決定したい M 個のアイテムについて考える。 N

個のアイテムのうち、 n 番目のアイテムの特徴量を $\mathbf{x}_n \in \mathbb{R}^D$ 、掲載期間を $y_n \in \mathbb{R}$ とする。ここで、 D は特徴量数とする。ブランドクラスは前述の通り 8 クラスとし、 M 個のアイテムのうち、各ブランドクラスに属するアイテム数を $M_i (i = 1, \dots, 8)$ とする。すなわち、 $\sum_i M_i = M$ である。また、出品月は 1 月から 12 月までとする。このとき、詳細なアルゴリズムは以下の通りである。

Step1) 掲載期間の確率分布を推定各アイテムの特徴量 \mathbf{x}_n を説明変数、掲載期間 y_n を目的変数として、NGBoost により、ブランドクラスごとの予測確率分布を推定する。

Step2) プロパー期間の決定

Step2-1) ブランドクラスを $i = 1$ とする。

Step2-2) ブランドクラスが i であるアイテムを抽出し、出品月を $j = 1$ とする。

Step2-3) 抽出された $M_i (M_i \leq M)$ 個のアイテムに、Step1 で構築したブランドクラス i のモデルを適用する。

Step2-4) M_i 個のアイテムと出品月 j に対して、得られた分布の α 点の掲載期間 $s_m^{ij} (1 \leq m \leq M_i)$ を算出する。

Step2-5) M_i 個のアイテムの s_m^{ij} の平均値を算出し、プロパー期間 t_{ij} とする。

Step2-6) $j = 12$ のとき、Step2-7 へ。 $j < 12$ のとき、 $j = j + 1$ として Step2-3 へ。

Step2-7) $i = 8$ のとき終了する。 $i < 8$ のとき、 $i = i + 1$ として Step2-2 へ。

5 実データ分析

本章では、ZOZOUSSED において過去の販売履歴データに提案手法を適用して、提案手法の有用性について検証するとともに、適切なプロパー期間を決定する。

本分析では、ZOZOUSSED で 2018 年 1 月 1 日から 2019 年 11 月 17 日に出品された 301,129 件のアイテムの販売履歴データを用いる。モデル構築に用いる学習データは 2018 年に出品されたアイテム (72,007 件)、プロパー期間の決定に用いるテストデータは 2019 年に出品されたアイテム (229,122 件) とした。ただし本分析では、プロパー期間の決定によって値下げされずに販売される可能性の高い、オフ率 0% と 10% で販売されたアイテムを分析対象とした。また、アイテムは買取・販売実績が 2 回以上あるアイテムを対象とした。

掲載期間の予測モデルの構築においては、出品価格、定価、買取価格、性別、使用状態、出品月、使用日数等の特徴量 ($D = 28$) を用いた。

5.1 分析 1：予測モデルの有用性の検証

本節では、提案手法において掲載期間の予測モデルとして用いる NGBoost の有用性を検証するために、他の予測モデルとの比較を行う。

5.1.1 分析条件

予測モデルの比較手法には NGBoost と同じ勾配ブースティング手法の一つである、LightGBM [9] を用いる。この手法は、

決定木のアルゴリズムを利用しているため、区間予測はできない。そこで、評価指標は比較手法に合わせて平均平方二乗誤差 (RMSE) を用いる。ただし、データ数を N 、観測値を y_n 、予測値を \hat{y}_n とする。

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - \hat{y}_n)^2} \quad (2)$$

5.1.2 分析結果

予測モデルによる予測掲載期間の RMSE を表 1 に示す。

表 1 予測モデルに対する RMSE

ブランド クラス	学習データ		テストデータ	
	NGBoost	LightGBM	NGBoost	LightGBM
1	22.73	23.77	26.76	27.53
2	29.01	30.40	29.12	30.46
3	23.38	23.98	24.57	25.75
4	21.14	21.50	13.85	14.74
5	16.03	16.03	12.94	13.98
6	15.92	15.95	12.87	13.82
7	10.20	12.44	14.43	14.39
8	14.59	15.20	12.16	12.91

(太字は RMSE が小さい方を示す。)

表 1 より、ほとんどのクラスにおいて、学習データ、テストデータともに提案手法で用いた NGBoost の方が予測精度が高いことが分かる。これにより、掲載期間の予測においては、モデル構築の際に確率分布を推定する NGBoost を適用することが有用であると考えられる。

5.2 分析 2：ブランドクラスの有用性の検証

本節では、提案手法においてアイテムのグルーピングを行う際に用いるブランドクラスの有用性を検証するために、ZOZOUSSED で現在適用されているグルーピング方法との比較を行う。

5.2.1 分析条件

ZOZOUSSED では現行のシステムにおいて、提案手法と同様にアイテムのグルーピングを行い、グループごとにプロパー期間を決定している。そこで、現行のグルーピング方法¹を比較手法とする。NGBoost により推定された確率分布を用いて評価を行うため、評価指標には式 (3) に示す対数損失を用いる。ただし、データ数を N 、観測値を y_n 、特徴量ベクトルを \mathbf{x}_n とし、 $\hat{P}(y_n|\mathbf{x}_n)$ は \mathbf{x}_n のもとでの y_n の推定出現確率である。

$$L = \frac{1}{N} \sum_{n=1}^N \{-\log \hat{P}(y_n|\mathbf{x}_n)\} \quad (3)$$

5.2.2 分析結果

提案手法における、ブランドクラスによるグルーピング方法と ZOZOUSSED で採用されている現行のグルーピング方法を用いて予測モデルを構築した際のテストデータに対する対数損失を表に示す。

表 2 各グルーピング方法による対数損失

グルーピング方法	対数損失
ブランドクラス	3.75
現行のルール	3.89

表 2 より、本研究で与えたブランドクラスごとに予測モデルを構築することで高い予測精度を得られることが分かる。このことから、ユーザの意思決定が反映されている掲載期間は、アイテムの価格帯を考慮したグループごとに予測することが有用であると考えられる。

分析 1, 2 より、ブランドクラスを用いてアイテムをグルーピングし、NGBoost を適用してモデルを構築する提案手法は、アイテムの掲載期間の予測に有用であると言える。

5.3 分析 3：プロパー期間の決定

次に、提案手法を用いてアイテムの適切なプロパー期間の決定を行う。

5.3.1 分析条件

前節までの通り、アイテムのグルーピング方法にはブランドクラスを用い、掲載日数の予測モデルである NGBoost の弱学習器の数は事前分析より 500 と設定した。また、予測確率分布には指数分布を仮定した。

さらに、プロパー期間の決定の際にあらかじめ設定する α は、現行のプロパー期間内での販売実績を基に「プロパー期間内に販売したいアイテム割合」としてブランドクラスごとに設定した。設定した α の値を表 3 に示す。

表 3 ブランドクラスごとに設定した α [%]

ブランドクラス							
1	2	3	4	5	6	7	8
68	59	49	45	46	43	35	61

5.3.2 分析結果

構築した NGBoost を用いて、出品月を 1 月から 12 月に変化させて予測を繰り返すことで決定したプロパー期間を表 4 に示す。

表 4 決定したプロパー期間 [日]

出品月	ブランドクラス							
	1	2	3	4	5	6	7	8
1 月	39	58	34	22	19	18	15	24
2 月	39	63	42	29	32	32	15	26
3 月	39	71	37	23	19	18	15	25
4 月	39	64	32	22	19	18	15	25
5 月	39	57	30	22	19	16	15	24
6 月	38	59	34	22	19	18	15	24
7 月	38	59	34	22	19	18	15	24
8 月	41	58	34	22	19	18	15	24
9 月	41	57	34	22	19	18	15	24
10 月	38	58	41	24	22	19	16	24
11 月	39	58	35	22	21	20	15	24
12 月	39	58	34	22	19	18	15	24

1：非公開情報のため、詳細は掲載できない。

表4より、ブランドクラス1や2はプロパー期間が比較的長く、ブランドクラス7は比較的短いことが分かる。前述の通り、ブランドクラスは主に平均販売単価が高い順にグルーピングしている。ZOZOUSUEDでは、価格帯が高いアイテムほど、長くサイトに掲載することでサイトの魅力度が向上すると考えている。そのため、ブランドクラス1や2のアイテムは、掲載期間が長くなっても値下げせずに購入されることが望ましい。したがって、この結果はサイトの魅力度の観点からも適切であると考えられる。

以上のことから、実運用可能なプロパー期間決定モデルが構築できたとと言える。

6 提案手法を用いた実運用における実証実験

本章では、提案手法の実運用における有効性を示すため、ZOZOUSUEDで新たに出品されるアイテムに対して、前章で決定したプロパー期間を実際に適用した実証実験の結果を示す。また、販売結果の分析と考察を行い、提案手法の有効性を検証する。

6.1 実験条件

本実験ではZOZOUSUEDの255,350件のアイテムを対象とし、2020年2月26日から2020年3月15日までを出品日として実証実験を行った。全出品アイテムをランダムに2つのグループに分割し、それぞれ「現行のプロパー期間を適用するアイテム群」（以下、現行）と「新しいプロパー期間を適用するアイテム群」（以下、提案）とした。ただし、出品したアイテム数がそれぞれ均等になるように分割した。

現行と提案の各アイテムに適用したプロパー期間を表5に示す。なお、現行は出品月によらず一定である。

表5 現行のプロパー期間と提案のプロパー期間 [日]

	ブランドクラス							
	1	2	3	4	5	6	7	8
現行	60	60	30	15	15	15	15	15
提案(2月)	39	63	42	29	32	32	15	26
提案(3月)	39	71	37	23	19	18	15	25

本実験では、ブランドクラスごとに設定した α %点、収益性、管理コストの3項目について評価を行う。

ブランドクラスごとに設定した α %点の評価指標には、式(4)に示す α との乖離度を用いる。この評価によって、出品者が決定した α %点がプロパー期間内に販売されたアイテムの割合に近づいているか、つまり、出品者が意図した販売結果に近づいているかを評価することができる。また、式(4)におけるプロパー消化率は式(5)を用いて算出する。ただし、 α との乖離度は現行のプロパー期間を適用したアイテムで計算した値から新しいプロパー期間を適用したアイテムで計算した値を減算し算出する。つまり、この値が大きければ、現行のプロパー期間に比べて新しいプロパー期間の方が出品者が意図した販売結果に近づいていると解釈することができる。

$$\alpha \text{からの乖離度} = |\alpha - \text{プロパー消化率}| \quad (4)$$

$$\text{プロパー消化率} = \frac{\text{プロパー期間内に売れたアイテム数}}{\text{販売されたアイテム数}} \times 100 \quad (5)$$

収益性における評価指標には、式(6)に示す粗利率を用いる。この指標によって、利益増加の見込みがあるかどうかを評価することができる。ただし、新しいプロパー期間を適用したアイテムで計算した粗利率から現行のプロパー期間を適用したアイテムで計算した粗利率を減算しその差分を算出する。つまり、この値が大きければ、現行のプロパー期間に比べて新しいプロパー期間の方が利益増加の見込みがあると解釈することができる。

$$\text{粗利率} = \frac{\text{合計販売価格} - \text{合計買取価格}}{\text{合計販売価格}} \times 100 \quad (6)$$

管理コストにおける評価指標には、式(7)に示す消化率、式(5)に示すプロパー消化率を用いる。ここで、管理コストとは、在庫の管理にかかる全般的な費用を指し、アイテムが長い期間売れ残るほど大きくなると考えられる。言い換えれば、管理コストはアイテムが早く販売（消化）されれば、小さくなると考えられる。そのため、これらの指標によって、管理コストが現行に比べて増加しているか否かを評価することができる。ただし、消化率及びプロパー消化率は提案のアイテムにおける値から現行のアイテムにおける値を減算しその差分を算出する。つまり、これらの値が大きいくほど、現行のプロパー期間に比べて提案のプロパー期間の方が出品数に対してより多くのアイテムを販売できていると解釈できる。言い換えれば、より管理コストがかかっていないということになる。

$$\text{消化率} = \frac{\text{販売されたアイテム数}}{\text{出品されたアイテム数}} \times 100 \quad (7)$$

6.2 実験結果と考察

得られた販売結果に対する分析と評価を行う。分析対象とするアイテムは、前節で述べた出品アイテムのうち、2020年2月26日から2020年10月9日までに販売された237,296件を用いる。

6.2.1 ブランドクラスごとに設定した α の評価

5章で述べたプロパー期間の決定において、事前に設定した α の評価を行う。この α はプロパー期間内で販売したいアイテム割合として手動で決定する値であるため、評価には上述した α からの乖離度を用いる。求めた、各ブランドクラスにおける α からの乖離度を表6に示す。

表6 ブランドクラスごとの α からの乖離度(現行 - 提案)[%]

ブランドクラス							
1	2	3	4	5	6	7	8
-0.14	-1.91	3.86	6.57	4.97	3.96	0.03	7.38

表6より、ブランドクラス1, 2は現行の方が α からの乖離

度が小さく、ブランドクラス 3~8 は提案の方が α からの乖離度が小さいことが分かる。また、9 割以上のアイテムがブランドクラス 4~8 に所属することが事前分析より明らかとなっている。 α はプロパー期間内で販売したいアイテム割合として出品者の意思決定により設定される値であることから、アイテム全体としては、プロパー期間を変更したことにより、出品者の意図に沿った販売結果を得ることができたと言える。

6.2.2 収益性における評価

収益性において販売結果の分析・評価を行う。ここでは、ブランドクラスごとの収益性について分析する。表 7 に、粗利率についてブランドクラスごとの現行における値と提案における値の差（提案－現行）を示す。

表 7 ブランドクラスごとの粗利率（提案－現行）[%]

ブランドクラス							
1	2	3	4	5	6	7	8
-1.26	-0.11	1.35	0.85	0.59	0.40	0.21	0.74

表 7 より、ほとんどのブランドクラスで提案の利益率が現行の利益率を上回っていることが分かる。約 9 割のアイテムがブランド 4~8 に所属することから、アイテム全体では、新しいプロパー期間を適用することで利益率が増加したと考えられる。

一方で、平均販売単価が高いブランドクラス（特にブランドクラス 1）においては、提案の方が粗利率が低くなっていることが分かる。これは、アイテムを現行と提案に分割する際、アイテムの買取単価及び出品単価を均等に分けることが出来なかったことが原因であると考えられる。

次に、出品月ごとの収益性について分析する。表 8 に、粗利率について出品月ごとの現行における値と提案における値の差（提案－現行）を示す。

表 8 出品月ごとの粗利率（提案－現行）[%]

2 月	3 月
1.19	0.40

表 8 より、2 月・3 月ともに新の利益率が現行の利益率を上回っていることが分かる。したがって、2 月と 3 月においては新しいプロパー期間を適用する方が従来に比べて利益率が増加することが考えられる。

以上のことから、提案手法を実運用に適用することで、利益増加の見込みがあると言える。

6.2.3 管理コストにおける評価

最後に管理コストにおける販売結果の分析・評価を行う。まず、ブランドクラスごとの消化率、プロパー消化率を表 9 に示す²。表 9 より、ほとんどのクラスで提案の消化率が現行の消化率を下回っていることが分かる。しかしながら、それらの差はブランドクラス 1 を除いて 1%未満の値であるため、管理コストにおける大きな差はないと考えられる。一方、プロパー消

化率に注目すると、ほとんどのクラスで提案のプロパー消化率が現行のプロパー消化率を上回っていることが分かる。さらに、ブランドクラス 3, 4, 5, 6, 8 はブランドクラス 7 を除いて 3%以上差があることが分かる。約 9 割のアイテムがブランドクラス 4~8 に所属することから、アイテム全体では、提案プロパー期間を適用することでプロパー消化率が増加したと考えられる。

表 9 ブランドクラスごとの消化率・プロパー消化率（提案－現行）[%]

	ブランドクラス							
	1	2	3	4	5	6	7	8
消化率	-1.62	-0.08	1.08	-0.66	-0.52	-0.11	-0.57	-0.15
プロパー消化率	-0.14	-1.91	3.86	6.57	4.97	3.96	0.03	4.31

次に、出品月ごとの消化率、プロパー消化率を表 10 に示す。表 10 より、2 月、3 月ともに、提案の消化率が現行の消化率を下回っており、提案のプロパー消化率が現行のプロパー消化率を上回っていることが分かる。消化率の差は 0.5%未満であるため、管理コストにおける大きな差はないと考えられる。一方、プロパー消化率は 3%以上であるため、2 月と 3 月においては提案プロパー期間を適用することで、現行に比べてプロパー消化率が改善することが期待できる。

表 10 出品月ごとの消化率・プロパー消化率（提案－現行）[%]

	2 月	3 月
消化率	-0.45	-0.24
プロパー消化率	8.42	3.02

以上のことから、提案のプロパー期間を用いてアイテムを出品することで、全体としての管理コストは従来と大きな変化はないものの、値下げをせずに販売されるアイテムの割合が大きくなると言える。したがって、提案手法の適用により、管理コスト大きく増加させずに出品価格のままアイテムを販売することができると考えられる。

7 まとめと今後の課題

本研究では、ZOZOUSUED にいて、新規出品アイテムの出品月に応じた適切なプロパー期間の決定を目的とした。価格帯の類似性を考慮したブランドクラスごとに掲載期間の確率分布を推定するモデルを構築し、出品月を変化させながら推定を繰り返すことで適切なプロパー期間を決定する手法を提案した。また、実際に ZOZOUSUED の販売履歴データに適用し、分析結果を通じて提案手法の有用性を示した。加えて、新規出品アイテムに決定したプロパー期間を適用した実証実験を設計・実施し、実証的に提案手法の有用性を検証した。これにより、当該サイトにおいて、より合理的なプロパー期間の決定を可能とするモデルを構築することができた。提案手法により、多様なアイテムを扱う EC サイトにおける、より合理的な値下げの仕組みの構築が期待できる。

2：ここでの消化率は、最終消化率ではなく、2020 年 10 月 9 日時点での消化率である

今後の課題として、提案手法における確率分布の推定モデルの検討が挙げられる。本研究では、NGBoost を用いて掲載期間の予測確率分布を推定したが、ベイズ推定を用いた方法なども考えられる。精度の高い予測分布推定方法を検討することで、より適切なプロパー期間の決定が期待できる。加えて、予測確率分布に仮定する分布の検討も挙げられる。提案手法において、掲載期間の予測確率分布には、シンプルでパラメータ数が少ないという観点から指数分布を仮定したが、ワイブル分布を適用することも考えられる。指数分布に比べてパラメータ数は多いが、掲載期間の予測精度の向上が期待でき、今後の課題とする。

文 献

- [1] 仁ノ平将人, 三川健太, 後藤正幸, “販売履歴データに基づく中古ファッションアイテムの販売価格予測モデルに関する一考察,” 情報処理学会論文誌, Vol. 60, No. 4, pp. 1151-1161, 2019.
- [2] Duan, T., Avati, A., Ding, D. Y., Basu, S., Ng, A. Y., Schuler, A., “NGBoost: Natural Gradient Boosting for Probabilistic Prediction,” <https://arxiv.org/abs/1910.03225>, 2019.
- [3] Liu, N., Ren, S., Choi, T. M., Hui, C. L. and Ng, S. F., “Sales Forecasting for Fashion Retailing Service Industry: A Review,” *Mathematical Problems in Engineering*, Vol. 2013, No. 738675, 2013.
- [4] Thomassey S. and Fiordaliso, A., “A Hybrid Sales Forecasting System Based on Clustering and Decision Trees,” *Decision Support Systems*, Vol. 42, No. 1, pp. 408–421, 2006.
- [5] Ni Y. and Fan, F., “A Two-Stage Dynamic Sales Forecasting Model for the Fashion Retail,” *Expert Systems with Applications*, Vol. 38, No. 3, pp. 1529–1536, 2011.
- [6] Au, K.-F., Choi, T.-M. and Yu, Y., “Fashion Retail Forecasting by Evolutionary Neural Networks,” *International Journal of Production Economics*, Vol. 114, No. 2, pp. 615–630, 2008.
- [7] Choi, T.-M., Yu, Y. and Au, K.-F., “A Hybrid SARIMA Wavelet Transform Method for Sales Forecasting,” *Decision Support Systems*, Vol. 51, No. 1, pp. 130–140, 2011.
- [8] Amari, S., “Natural Gradient Works Efficiently in Learning,” *Neural Computation*, pp.251–276, 1998.
- [9] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T. Y., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” *In Advances in Neural Information Processing Systems*, 2017.