

ユーザ行動分析のための Knowledge Graph Attention Network の拡張に関する一考察

伊藤 史世[†] 張 志穎[†] 雲居 玄道[†] 後藤 正幸[†]

[†] 早稲田大学院創造理工学部経営システム工学専攻

〒169-8555 東京都新宿区大久保3-4-1 51号館15階

E-mail: fumiyo0607@fuji.waseda.jp

キーワード 知識グラフ, ディープラーニング, Graph Attention Network, Graph Convolutional Network, Knowledge Graph, 顧客分析手法

1 研究背景・目的

近年, ユーザの行動に関する様々な情報を取得可能になってきている。マーケティング分析に活用するユーザの購買行動に関するデータには, 単なる購買履歴のみでなく, 購買アイテムのカテゴリや店舗情報, ユーザの属性など様々な種類の補助情報を含めることが可能である。そのため, これらのデータを統合的に分析する手法の重要性が高まっている。機械学習の分野においては, このような様々なデータを統合的に扱いユーザの購買行動を予測するためのモデルが多く提案されている。そのようなモデルの1つに, ユーザと購買アイテム, 並びに補助情報との関係性をモデル化することでユーザの嗜好を学習する Knowledge Graph Attention Network (以下, KGAT) [6] が提案されている。このモデルは, ユーザと購買アイテム, さらにアイテムの補助情報の関係性をグラフで表現することによって, それらの複雑な関係性を学習することが出来る。また, モデルの学習によってグラフ上の「ユーザと購買アイテム」「アイテムと販売店舗」といった関係性の重要度をエッジの重みとして定量化することが可能である。このモデルでは, ユーザの購買行動を説明する上で重要な関係のエッジの重みが大きくなるように学習され, この重みの大きさを用いて「過去に購入した店舗と同じアイテムであるから」「過去に同じカテゴリのアイテムを購入しているから」といったように, なぜそのアイテムをユーザに推薦するのか理由を示すことができ, この解釈性は顧客の購買行動を理解するためにも有用となり得る。

そこで, 本研究では推薦システムで用いられていた KGAT モデルのエッジの重みに着目し, 顧客分析モデルとして再構築したモデルを提案する。提案手法では, KGAT では推薦アイテムの解釈として用いられていたグラフ上のエッジの重みを, 顧客の購買行動の解釈性として捉え直す。ここで, マーケティングの分野において, 顧客の購買行動を理解するためには, ユーザの属性情報は重要な観点である。しかしながら, 従来手法においてはユーザの属性情報については考慮されておらず, ユーザの購買行動をユーザ属性の観点から分析することが不可能であった。そこで, KGAT をユーザの属性情報も考慮したモデル

へと拡張することで, ユーザの嗜好を購買アイテムと属性の観点からモデル化する。これにより, ユーザの購買行動について, ユーザ属性, 購買アイテム, アイテムの補助情報を用いて多角的に分析を行うことが可能となる。最後に, 実際の EC サイトの評価履歴データに提案手法を適用し, 提案手法の有用性を示す。

2 準備

2.1 知識グラフ

知識グラフ (Knowledge Graph) とは, 現実世界に定義されている関係性をグラフ構造で表現したモデルである。知識グラフでは, エンティティ集合を Q , リレーション集合を R とし, それぞれのノードがエンティティ $q \in Q$, 2つのエッジの間に付与された辺ラベルがリレーション $r \in R$ (関係性) を表し, 有向グラフの形で表現される。また, 知識グラフは, 「先頭エンティティ (head entity)」, 「リレーション (relation)」, 「末尾エンティティ (tail entity)」の3つ組であるトリプルの集合 $G = \{(h, r, t) | h, t \in Q, r \in R\}$ として定義される。このトリプルによって, エンティティ間の関係性を表現する。

2.2 従来手法

KGAT [6] は, ユーザと購買アイテム, 購買アイテムの補助情報からなるグラフを入力として, ユーザの各アイテムに対する購買確率を出力する推薦モデルである。このモデルでは, グラフ上の高次の関係性を捉えながら, 推薦において重要である関係を学習し, ユーザやアイテム, アイテムの補助情報をベクトルで表現する。




図1 入力とするグラフのイメージ

KGAT を学習させることによって重み付き有向グラフを得ることができ、このグラフを用いることによって各ユーザーに対する各アイテムの推薦理由について解釈することができる。具体的には、ユーザーから推薦アイテムまで接続されているエッジのうち、エッジの重みが最大なものを選択し、これを推薦パスとする。この推薦パスに含まれている補助情報を分析することによって、推薦理由に対して考察を与えることが可能となる。




図2 学習済み有向グラフを用いた推薦理由の解釈

図2の場合、User1 に Item3 が推薦された理由は、推薦パスより、「過去に購入した Item1 と同じ店舗 Store1 で販売されているアイテムであるから」という解釈が可能である。

3 提案手法

3.1 概要

提案手法では、従来の KGAT をユーザーの属性情報を考慮したモデルへと拡張する。ここでは、ユーザー、ユーザーの属性、アイテム、そしてアイテムの補助情報からなるグラフを構築し、これをモデルの入力とし学習を行い、これにより得られたエッジの重みを用いた分析方法を提案する。提案手法により、ユーザーとその属性、アイテムとその補助情報間の関係性の強さを定量化することができ、それらの関係性について分析を行うことが可能となる。

3.2 グラフの構築

従来研究においては、FreeBase や YOGO といった膨大な知識を含んだ知識グラフをモデルの入力に用いることもある [5], [6] が、この知識グラフには分析者にとって有用でない情報も含まれていることが考えられる。そのため、本研究においては分析の効率性の観点から独自に知識グラフを構築し、これをモデルの入力に用いることとする。ここで、グラフ上のエンティティを $q \in Q$ 、リレーションを $r \in R$ とする。このエンティティとして提案手法では、ユーザー集合 \mathcal{U} 、アイテム集合 \mathcal{I} 、アイテムの補助情報として店舗集合 \mathcal{A}_1 、カテゴリ集合 \mathcal{A}_2 に加えてユーザーの属性集合 \mathcal{A}_3 も考慮する。すると、エンティティ集合は、式 (1) として定義される。

$$Q = \mathcal{U} \cup \mathcal{I} \cup \mathcal{A}_1 \cup \mathcal{A}_2 \cup \mathcal{A}_3 \quad (1)$$

また、グラフ \mathcal{G} は、「先頭エンティティ」、「リレーション」、「末尾エンティティ」の3つの組であるトリプル (h, r, t) の集合として、式 (2) のように定義される。

$$\mathcal{G} = \{(h, r, t) | h \in Q, r \in R, t \in Q\} \quad (2)$$

ここで、最終的に構築されるグラフのイメージを図3に示す。




図3 提案手法により構築されるグラフ

3.3 モデル式

提案モデルではエンティティとリレーションをベクトルで表現する。 $p \in Q \cup R$ のベクトル表現を $e_p \in \mathbb{R}^d$ とし、TransR [3] に基づき、知識グラフ上のエンティティのベクトル表現 e_h, e_t を、リレーションごとに異なる意味空間上に写像する。ここで、リレーション $r \in R$ による写像行列を $W_r \in \mathbb{R}^{d \times d}$ とする。グラフのスコア関数 g は、 $g(h, r, t) = \|W_r e_h + e_r - W_r e_t\|_2$ として定義され、グラフ構造に対する損失は、式 (3) で表される。

$$Loss_{KG} = \sum_{(h, r, t, t') \in \mathcal{T}} -\ln \sigma(g(h, r, t') - g(h, r, t)) \quad (3)$$

ただし、 \mathcal{T}_r をリレーション r について定義されている末尾エンティティの集合として、 $\mathcal{T} = \{(h, r, t, t') | t, t' \in \mathcal{T}_r, (h, r, t) \in \mathcal{G}, (h, r, t') \notin \mathcal{G}\}$ である。ここで、 (h, r, t') は、グラフ上のトリプル $(h, r, t) \in \mathcal{G}$ について $t' \in \mathcal{T}_r$ を t 以外のエンティティからランダムにサンプリングすることによって作られるトリプルである。さらに、グラフに存在するトリプル (h, r, t) のエッジの重み $\pi(h, r, t)$ を以下の式で求める。

$$\tilde{\pi}(h, r, t) = (W_r e_t)^\top \tanh(W_r e_h + e_r) \quad (4)$$

$$\pi(h, r, t) = \frac{\exp(\tilde{\pi}(h, r, t))}{\sum_{(h, r, t') \in \mathcal{N}_h} \exp(\tilde{\pi}(h, r, t'))} \quad (5)$$

ただし、 \mathcal{N}_h は先頭エンティティ h に対してグラフ上で定義されているトリプルの集合である。また、 $\tanh(x)$ を $x = (x_1, x_2, \dots, x_d)$ に対して $\tanh(x) = (\tanh(x_1), \tanh(x_2), \dots, \tanh(x_d))$ と定義する。

続いて、 $\pi(h, r, t)$ により、 e_h に対する周辺のエンティティのベクトル表現の重み付け和を計算し、その表現を自身に取り入れることを L 回繰り返すことにより、グラフ上の L 次近傍の関係性を考慮したベクトル表現を獲得する。

$$e_{\mathcal{N}_h} = \sum_{(h, r, t) \in \mathcal{N}_h} \pi(h, r, t) e_t \quad (6)$$

この繰り返し操作は、 l 回目の畳み込み演算を終えた後のノード h のベクトル表現を $e_h^{(l)}$ として、以下のように定式化される。

$$e_{\mathcal{N}_h}^{(l-1)} = \sum_{(h, r, t) \in \mathcal{N}_h} \pi(h, r, t) e_t^{(l-1)} \quad (7)$$

$$e_h^{(l)} = f_{GA}^{(l)}(e_h^{(l-1)}, e_{\mathcal{N}_h}^{(l-1)}) \quad (8)$$

ただし、

$$f_{GA}(e_h, e_{\mathcal{N}_h}) = \text{LeakyReLU}(W_1(e_h + e_{\mathcal{N}_h})) + \text{LeakyReLU}(W_2(e_h \odot e_{\mathcal{N}_h})) \quad (9)$$

ここで、 $\mathbf{W}_1, \mathbf{W}_2 \in \mathbb{R}^{d \times d}$ は、学習によって求めるパラメータ、 \odot は要素積 (Hadamard product) である。

また、 $\text{LeakyReLU}(\mathbf{x})$ は、 d 次元のベクトル $\mathbf{x} = (x_1, x_2, \dots, x_d)$ に対して、 α を任意の正の数として以下のように定義される [7]。

$$\mathbf{h} = \text{LeakyReLU}(\mathbf{x}) \quad (10)$$

ただし、 $\mathbf{h} = (h_1, h_2, \dots, h_d)$ であり、

$$h_i = \begin{cases} x_i & (x_i \geq 0) \\ \alpha x_i & (x_i < 0) \end{cases} \quad (11)$$

式 (7), (9) の処理を L 回繰り返すことで、 L 次元近傍までの周辺ノードの接続情報を考慮することができる。このとき、 \mathbf{e}_h は $\pi(h, r, t)$ の大きい \mathbf{e}_i に依存した表現となる。そのため、知識グラフで関係性が定義されている2つのエンティティの関係性の強さをエッジの重みとして定量化することが可能となる。

最後に、ユーザ $u \in \mathcal{U}$ とアイテム $i \in \mathcal{I}$ の推薦スコア $\hat{y}(u, i)$ を、更新した L 個のベクトル表現を用いて以下のように求める。このスコアが高いほど、ユーザ u とアイテム i の共起関係が強いことを表す。ここで、 $\mathbf{a} \parallel \mathbf{b}$ は、ベクトル \mathbf{a}, \mathbf{b} の連結を表す。

$$\mathbf{e}_u^* = \mathbf{e}_u^0 \parallel \mathbf{e}_u^1 \parallel \dots \parallel \mathbf{e}_u^L, \quad \mathbf{e}_i^* = \mathbf{e}_i^0 \parallel \mathbf{e}_i^1 \parallel \dots \parallel \mathbf{e}_i^L \quad (12)$$

$$\hat{y}(u, i) = \mathbf{e}_u^{*\top} \mathbf{e}_i^* \quad (13)$$

ユーザとアイテムの共起に関する損失は、式 (14) で表される。

$$Loss_{CF} = \sum_{(u,i,j) \in O} -\ln \sigma(\hat{y}(u, i) - \hat{y}(u, j)) \quad (14)$$

ここで、 σ はシグモイド関数、 \mathcal{D}^+ を実際にデータ中に観測されたユーザとアイテムのペア集合、 \mathcal{D}^- を観測されていないのペア集合とし、 $O = \{(u, i, j) | (u, i) \in \mathcal{D}^+, (u, j) \in \mathcal{D}^-\}$ である。

3.4 モデルの最適化

モデルの全体の損失 $Loss$ は知識グラフの損失 $Loss_{KG}$ と推薦の損失 $Loss_{CF}$ を用いて以下のように定義される。

$$Loss = Loss_{KG} + Loss_{CF} + \lambda \|\Theta\|_2^2 \quad (15)$$

ここで、 $\Theta = \{\mathbf{e}_p, \mathbf{W}_r, \mathbf{W}_1, \mathbf{W}_2, \forall p \in \mathcal{Q} \cup \mathcal{R}, \forall r \in \mathcal{R}, \forall l \in \{1 \dots L\}\}$ とし、 $\mathbf{W}_1, \mathbf{W}_2$ は非線形関数 f_{GA} におけるパラメータ、 λ は正則化の強度を決定する正則化パラメータである。提案手法では、Adam [1] に基づいて、式 (15) を最小化するように各パラメータを更新する。

3.5 提案モデルを用いた分析方法

提案手法では、グラフ上に定義されている関係性を正確に表現しているかを表す知識グラフの損失 $Loss_{KG}$ とユーザの購買行動をどの程度正確に表現できているのかを表す損失 $Loss_{CF}$ を同時に最適化を行うことにより、モデルの学習を行う。これにより、実際にグラフで定義されている関係のうち、ユーザの購買行動を表現する上で重要である関係が式 (5) によって算出される正規化後のエッジの重み π により強調される。この値を用いることで、ユーザの購買行動に関する分析が可能となる。提案手法で構築されるグラフにおいては、ユーザは「購買アイ

テム」と「属性」に接続されており、アイテムは、「アイテムを購買したユーザ」、「販売店舗」および「アイテムカテゴリ」に接続されている。これを用いて、グラフとして表現されたユーザの購買行動において重要な関係性を検出することが可能となる。さらに、年代・性別からなるユーザ属性、アイテム、また店舗について分析を行うために、ある末尾エンティティに対して定義されている先頭エンティティのエッジの重みの平均値を算出することによって、末尾エンティティの「性質」について分析する方法を提案する。具体的には、末尾エンティティ t に対して定義されている先頭エンティティの集合を \mathcal{H}_t 、ある任意のエンティティ集合を \mathcal{A} とし、以下のように平均値を算出する。

$$\mu(\mathcal{A}, r, t) = \frac{\sum_{h' \in \mathcal{A} \cap \mathcal{H}_t} \pi(h', r, t)}{|\mathcal{A} \cap \mathcal{H}_t|} \quad (16)$$

ここで、 $\pi(h', r, t)$ が大きいエンティティ h' は末尾エンティティ t に依存した表現になっている。そのため、この依存度が末尾エンティティに対して平均的に大きいということは、末尾エンティティ t は、 $h' \in \mathcal{H}_t$ にとって重要な関係にあると解釈することができる。この値を用いることによって、顧客にとって重要であるアイテムや、販売アイテムとの関連度が高い店舗を分析することが可能となる。

4 実データを用いた分析

提案手法の有用性を示すため、2012 年の楽天市場の評価履歴データ [4] に対して提案手法を適用し、分析を行う。

4.1 分析条件

データ期間は、2012 年の1年間であり、デモグラフィック属性は、年代が10代から70代の7段階、性別が男女の2属性の計 $7 \times 2 = 14$ カテゴリを使用した。グラフの埋め込み表現の次元数は $d = 64$ 、正則化の強度を調節する正則化パラメータは $\lambda = 0.0001$ 、LeakyReLU のハイパーパラメータは $\alpha = 0.2$ とし、グラフの更新回数は $L = 3$ とした。

表1 処理後のデータセット統計

ユーザ数	27,641
アイテム数	123,751
店舗数	13,123
カテゴリ数	13,658
定義されているトリプル数	275,143

4.2 分析結果と考察

4.2.1 提案モデルの予測精度

提案モデルの妥当性を検証するため、同様のデータを取り扱いユーザの購買予測を行うことのできるモデルとの予測精度の比較を行う。ここでは、ベースラインとして、ニューラルネットワークの下で FM を包含する最新の因子分解モデルである Neural Factorization Machines (以下、Neural FM) [2] を用いた。本研究では、評価指標として NDCG@20, NDCG@100 を使用

した．ここで、各手法における予測精度の比較を以下表 2 に示す．この結果より、提案手法は補助情報を用いた従来のモデルよりも良い予測精度を示しており、データをグラフとして表現することによって、ユーザの嗜好をより正確に捉えていることがわかる．

表 2 モデルの予測精度の比較

	NDCG@20	NDCG@100
Neural FM	0.0340	0.04241
提案手法	0.0375	0.0562

4.2.2 ユーザの嗜好に関する分析

まず、各属性の嗜好の傾向に関する分析を行うために、ユーザ $u \in \mathcal{U}$ と属性 $a \in \mathcal{A}_3$ のエッジの重み $\pi(u, r, a)$ に対して式 (16) を適用し、比較・考察を行う．ここで、 $\pi(u, r, a)$ が大きいことは、ユーザ u のベクトル表現が属性 a に依存した表現となっていることを意味し、属性 a について $\pi(u, r, a)$ が平均的に高いことは、属性 a を持つユーザの表現がある程度類似していることを意味する．よって、 $\mu(\mathcal{U}, r, a)$ を比較することによって、属性毎にどの程度共通の嗜好が存在しているのかを比較することができる．まず性別で比較すると、男性の方が全体的にこの数値が低い傾向がある．このことから、男性はユーザ固有の嗜好が強く、女性は属性ごとに似た購買を行う傾向があるといえる．また、同一の性別における年代間の比較をすると、男性においては、30 代、40 代で大きくなり、年代が上昇するにつれて小さくなる傾向がある．このことから、男性は 50 代以降に、ユーザ固有の嗜好が強くなり、趣味などの個人の嗜好に基づく購買をするようになることが推測される．女性は、年代が上昇するにつれ属性との関連度が大きくなることから、その嗜好は共通化していく傾向にあると言える．




図 4 属性ごとの $\mu(\mathcal{U}, r, a)$

さらに、 π の有用性について検討するため、 $\pi(u, r, a)$ と $\pi(u, r, i)$ について分析する．そこで、評価件数が 5 件のユーザのうち、 $\pi(u, r, a)$ が最も高かったユーザ u_1 、および最も低かったユーザ u_2 を抽出し、その購買傾向について考察する．該当するユーザの π の値を表 3 に示す．

表 3 該当ユーザの購買履歴

u_1		u_2	
エンティティ名	π	エンティティ名	π
a:40 代男性	9.43×10^{-1}	ペット用パーカー	9.99×10^{-1}
生パスタセット	2.67×10^{-2}	ペット用ポロシャツ	2.35×10^{-8}
座いす	1.09×10^{-2}	ブランケット	7.40×10^{-9}
腕時計	8.01×10^{-3}	犬用サプリメント	2.42×10^{-9}
懐中電灯	6.82×10^{-3}	犬用デンタルケア	2.06×10^{-9}
DVD プレーヤー	5.03×10^{-3}	a:40 代女性	1.64×10^{-13}

表 3 より、ユーザ u_1 は日用品や食品などの複数のジャンルの商品を購入しており、偏った購買傾向はみられず、40 代男性の標準的な購買行動をしているといえる．一方、ユーザ u_2 はペットに関する商品を多く購入しており、一貫したユーザ固有の嗜好に基づいた購買行動が確認できる．このように、 $\pi(u, r, a)$ の値が小さいユーザ u は、ユーザ特有の嗜好を有するとみなすことができる．

また、アイテムの特徴を明らかにするため、ユーザ集合 \mathcal{U} とアイテム $i \in \mathcal{I}$ に対して式 (16) を適用し分析を行う． $\pi(u, r, i)$ が高いアイテムは、ユーザとアイテム間の関係性が強く、ユーザの嗜好を表現する上で重要なアイテムであることを意味する．すなわち、 $\pi(u, r, \hat{i})$ が平均的に大きくなっているアイテム \hat{i} は多くの購買ユーザとの関係性が強く、ユーザの嗜好がよく表現されているアイテムであると言える．一方で、 $\pi(u, r, \hat{i})$ が平均的に小さいアイテム \hat{i} は、購買ユーザに嗜好を表現する上で重要なアイテムではないと解釈することができる．ここで、被購買件数が 16 件以上、25 件未満のアイテムのうち $\mu(\mathcal{U}, r, i)$ の上位 6 件と下位 6 件のアイテムを表 4 に示す．

表 4 該当アイテムの $\mu(\mathcal{U}, r, i)$

商品名	$\mu(\mathcal{U}, r, i)$
子供ドレス 用 ボリュームアップ パニエ	0.9632405
1 day カラーコンタクト	0.9479262
女性用 下着	0.9391152
カラーコンタクト用 ケース	0.9270242
K-POP グループポスター	0.9213551
メンズ チノパン	0.9092795
⋮	⋮
ひじき ふりかけ	0.0033970
コットンチノパンツ	0.0021839
ドライマンゴー	0.0012587
芳香剤	0.0011505
グルコサミン サブリ	0.0010820
靴下 6 枚 (3 足) + ようかん 2 個	0.0009755

表 4 より、 $\mu(\mathcal{U}, r, i)$ が高くなっているアイテムは、ファッション系のアイテムが多く、人による嗜好の差異が出やすいアイテムであることがわかる．一方で、この値が低いアイテムは食品や日用品などの消耗品が多く、どのようなユーザにも購買されるようなアイテムである．このように同程度の購買件数で同程度の人気を誇るアイテムについても、 π の値によって、アイテムの特徴を定量化することができていると考えられる．

4.2.3 アイテムと店舗に関する分析

アイテム集合 \mathcal{I} と店舗 $s \in \mathcal{A}_1$ に対して、式 (16) を適用し、分析を行う．ここでは、取り扱いアイテムの被購買件数の合計が 500 以上 1000 未満の店舗を抽出した． $\mu(\mathcal{I}, r, s)$ が高く、販売アイテム同士の表現が近くなっている店舗では、その店舗で販売されているアイテムを購入したユーザは、同じ店舗で販売されている他のアイテムも嗜好に合致する可能性が高く、反対に $\mu(\mathcal{I}, r, s)$ が低い店舗では、同じ店舗で販売されているアイテムでもユーザによって好むアイテムが異なること解釈すること

ができる。ここで該当店舗について、縦軸に、 $\mu(I, r, s)$ 、横軸に
取り扱いアイテム数をとった散布図を図5に示す。ここで、散




図5 該当店舗の $\mu(I, r, s)$ と取り扱いアイテム数

布図中のバブルの大きさは各店舗における購買件数の合計値で表現した。図5より、 $\mu(I, r, s)$ の大きい店舗は、取り扱いアイテム数が少なく、特定の食材やカテゴリのアイテムを販売する店舗であり、 $\mu(I, r, s)$ の小さい店舗にはファッション系のアイテムを販売する店舗である。このことから、ファッション系のアイテムは、ユーザによって、同一店舗でも好みのアイテムが異なることがわかる。また、日用品専門店A、家電・家具専門店Aについては、取り扱いアイテム数が多いものの、 $\mu(I, r, s)$ の値が比較的大きくなっている。ここで、日用品専門店Aは、日用品を比較的安い価格で販売しており、「価格の安さ」を理由にユーザがアイテムを購入するため、この店舗で販売されているアイテムを購入するユーザはこの店舗で販売されている他のアイテムも購入しやすいと解釈することができる。また、家電・家具専門店Bについては販売されているアイテムのデザインに統一感があり、その「デザイン」を理由にユーザがアイテムを購入するため、同一店舗の他のアイテムもユーザが好む傾向にあると考察することができる。このように、 $\mu(I, r, s)$ が大きく顧客が同一店舗内で購買を起こしやすいと考えられる店舗を抽出し、その店舗の取り扱い商品を分析することにより、商品ラインナップの提案に繋がれると考えられる。

5 考察

本稿では、ユーザの属性として「年代・性別」を用いたが、提案手法の入力とするグラフは分析者によって任意に変更が可能であり、ユーザの属性として、ソーシャルネットワーク上の繋がりを考慮することも可能である。実際にソーシャルネットワーク上で繋がれているユーザ同士はその嗜好が類似している場合が多く、実際にこの繋がりを考慮した推薦モデルも提案されている。多くのユーザとの繋がりがあり、かつそれらの関係性が強いユーザは、多くのユーザの嗜好に影響を与えているユーザである。このようなユーザを検出し、この購買行動を分析することで、各ユーザの嗜好の特性を把握することが可能と考えられる。また、アイテムに関しても同様に任意の補助情報

を考慮することができる。例えば、提案モデルを映画の視聴履歴に適用した場合、映画とその補助情報との関係性の強さを分析することによって、映画の視聴理由に対する考察が可能であると考えられる。具体的には、多くの視聴映画と関係性の強い役者は、ユーザがその役者に注目して視聴に至っている可能性が高いといった解釈を行うことができる。また、この結果を用いて、役者や制作会社など様々な属性に焦点を当てた施策立案に繋げることが可能である。このように、提案手法はモデルの入力とするグラフを分析の目的によって変更させることができ、非常に拡張性の高い実用的なモデルであると言える。

6 結論と今後の課題

本研究では、様々なデータを統合的に扱い、多角的な分析を可能とするために、KGATをユーザの属性情報を考慮したモデルへと拡張し、顧客購買行動分析モデルを構築した。実データを用いた分析より、グラフ上のエッジの重みを用いて様々な観点から分析を行い顧客の嗜好を理解するために、提案モデルは有用な分析モデルであることを示した。提案モデルで用いるグラフは分析の目的によって自由に構築することが可能であるため、様々な分野への応用が期待される。

今後の課題として、購買件数に基づく π の正則化アルゴリズムの考案や、購買順序の考慮といったモデルの改良が挙げられる。

謝辞

本研究では、国立情報学研究所のIDRデータセット提供サービスにより楽天株式会社から提供を受けた「楽天データセット」を使用致しました。貴重なデータの提供に深く感謝致します。

文献

- [1] D. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” *In The International Conference on Learning Representations* 2014.
- [2] X. He and T. Chua, “Neural Factorization Machines for Sparse Predictive Analytics,” *In SIGIR. ACM*, pp.355–364, 2017.
- [3] Y. Lin, Z. Liu, M. Sun, Y. Liu and X. Zhu, “Learning Entity and Relation Embeddings for Knowledge Graph Completion,” *Proc. Twenty-ninth AAAI conference on artificial intelligence*, pp.2181–2187, 2015.
- [4] 楽天株式会社, “楽天市場データ,” 国立情報学研究所情報学研究データリポジトリ. (データセット), <https://doi.org/10.32130/idr.2.1>, 2014.
- [5] H. Wang, F. Zhang, J. Wang, M. Zhao, W. Li and X. Xie, “Ripplenet: Propagating User Preferences on the Knowledge Graph for Recommender Systems,” *Proc. of the 27th ACM International Conference on Information and Knowledge Management*, pp.417–426, 2018.
- [6] X. Wang, X. He, Y. Cao, M. Liu and T. S. Chua, “KGAT: Knowledge Graph Attention Network for Recommendation,” *Proc. the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp.950–958, 2019.
- [7] A. L. Maas, A. Y. Hannun and A. Y. Ng, “Rectifier Nonlinearities improve Neural Network Acoustic Models,” *Proc. ICML*, Vol.30, No.1, pp.3, 2013.