

機械学習による弾性波初動点の自動解析

諏訪 雄二[†] 顧 志明[†] 小幡 拓也[†] 中川 慎二[†] 森下 諒一^{††}
 澤山 和貴^{†††} 辻 健^{†††}

[†] 日立製作所 Lumada Data Science Lab. 〒185-8601 東京都国分寺市東恋ヶ窪1-280

^{††} 石油天然ガス・金属鉱物資源機構 (JOGMEC) 〒261-0025 千葉県千葉市美浜区浜田1-2-2

^{†††} 九州大学大学院工学研究院地球資源システム工学部門 〒819-0395 福岡県福岡市西区元岡744

E-mail: [†]{yuji.suwa.uq, shimei.ko.yt, takuya.obata.wx, shinji.nakagawa.tj}@hitachi.com,

^{††} morishita-ryoichi@jogmec.go.jp, ^{†††}{k.sawayama0926, tsuji}@mine.kyushu-u.ac.jp

あらまし 岩石に与えた弾性波の応答を測定して岩石物性を推定するため、その波形データから振動の到達時刻(初動点)を判定するという作業があるが、各種ノイズの中から信号を見分け信号の立ち上がりを精密に特定する必要があり、専門家の目視以外には難しい。我々はセグメンテーション用のU-netを1次元データ向けにカスタマイズして用い、学習を効率化する処理を追加し、境界部分の特定に工夫を加えることで、高精度に初動点を自動解析する技術を開発した。

キーワード セマンティックセグメンテーション、アテンション機構、岩石、機械学習、弾性波、初動点

1 はじめに

石油や天然ガスの地下資源開発では、地震探査によって広域的な地下構造の推定を行う。また地下の三次元的な物性値の分布を推定する目的で、掘削により取得した岩石試料(コア)に対して孔隙率や弾性波速度などの物性値の測定も実施される。

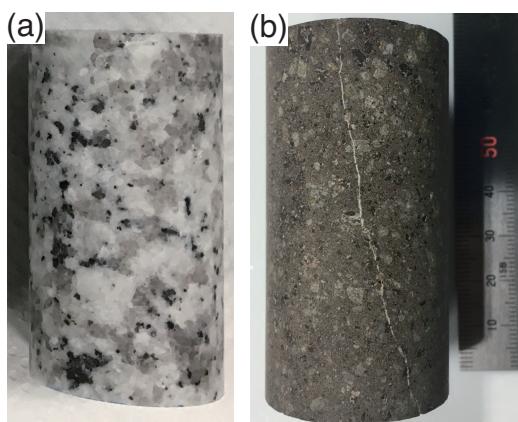


図1 弾性波速度の測定のために形状を加工した岩石サンプル。

弾性波速度の測定では、岩石サンプルを図1の様な円柱状に加工して実験装置にセットし、起振点から圧電素子による振動(逆圧電効果)を加え、岩石内を伝った波動を受振点の圧電素子で検出する。速度は起振点から受振点までの距離を波動伝播の時間で割ることにより得られる。このとき、振動の周期が0.5~1.0μsのオーダーであるのに対して計測したい振動の到達時間は数μsなので、十分な精度で到達時間を特定するためには、観測した振動波形が0から立ち上がる時刻(初動点)を見極める必要がある。つまり、単純に大きな振幅を観測した時刻を

初動点とすると1周期分の誤差が入るので精度が十分でない。

この初動点の解析を自動化する技術はいくつか提唱されていたが、観測した振動波形データには様々なノイズが含まれるため、専門家が波形データを1件ずつ目視で解析する方が、精度が高いとされていた。我々はセマンティックセグメンテーションの手法を1次元の波動データに適用し、手動による解析結果を教師データとして学習を行うことで、高精度な初動点解析の自動化を可能にした。ここではその方法の詳細について報告する。

2 振動付与実験の波形データ

解析の対象は、岩石に対する振動付与実験によって得られた振動の波形データである。これらに対して手動で初動点の解析を行い、得られた結果を教師データとして機械学習を行う。ここではまず手動解析の考え方を説明し、それを実際のデータに適用した例を示す。

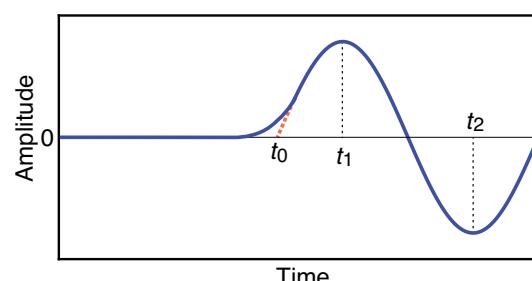


図2 ノイズがない理想的な場合の信号の例。実際の信号は必ず滑らかに立ち上がるが、理想的な正弦波の立ち上がり地点を初動点と定義する。

図2にノイズの無い理想的な波形データの例を示す。波動が

理想的なサイン波であれば、ある地点 t_0 から有限の傾きで信号が 0 から立ち上ることがになるが、それでは t_0 での加速度が無限大になってしまうので物理的にはあり得ない。実際には図 2 の青い実線の様に必ず傾き 0 から滑らかに立ち上ることがなる。このとき、滑らかに立ち上がり始めた地点を初動点とするのか、理想的サイン波なら立ち上がり時刻となっていた点を初動点とするのか、2 つの定義が考えられるが、後者の定義を採用する。滑らかな立ち上がり地点の特定には数値的な誤差が入り易いし、実際にはノイズの影響で 0 でない地点から立ち上る場合が多いのである。

この定義の下で初動点を決定するには 2 通りの方法がある。1 つは最初のピークの時刻 t_1 及び (逆符号の)2 番目のピークの時刻 t_2 を求め、初動時刻を $t_0 = t_1 - (t_2 - t_1)/2$ という計算式で求める方法である。この方法はサイン波の周期で考えて t_0 から t_1 までが $1/4$ 周期、そこから t_2 までが $1/2$ 周期であることを利用している。この方法はピークの時刻を特定するだけで良いのでノイズの影響を比較的受けにくいと言う点で優れているが、波形データの中にはセンサーからの信号が飽和してしまい、ピークの時刻が正確に特定できないものもあり、その様な場合には適用できない。もう 1 つの方法は、最初のピークの手前の勾配最大の地点から接線を引き、振幅 0 の線との交点を求める方法である。理想のサイン波であれば立ち上がり地点と最大勾配地点は一致するが、実際のデータではそれより勾配が緩やかな地点から接線を引くため、得られる初動点が早い時刻側にずれ易いという問題があるが、初動点に近いデータだけから決定できるので扱い易いという利点がある。ここでは主に後者の方で初動点を決定し、勾配が緩すぎて誤差が大きいと考えられる場合だけ前者の方法を用いた。

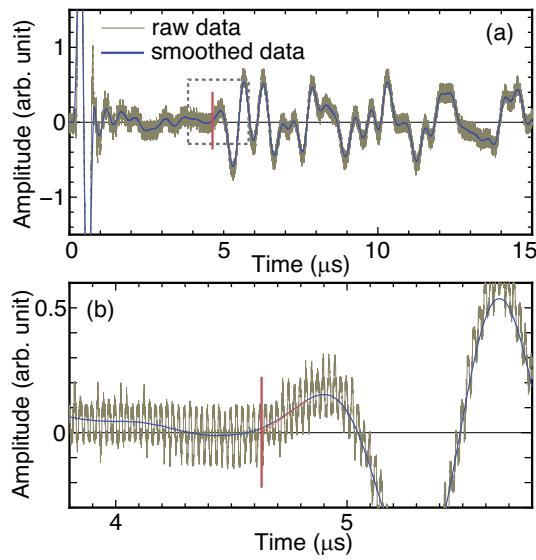


図 3 P 波の弾性波データの例。赤い縦線は傾き最大の地点から接線を引いて決定した初動点を表す。

本研究では解析対象の波形データとして、我々自身が実験を行って得たデータ及び Zaima ら [1] が公開している同種実験データの 2 種類を用いている。図 3-6 には実際の波形データとそれに対して接線を引く方法で初動点を解析した例を示す。ノ

イズが少なく初動点の解析がこれより容易な例もあるが、ここでは比較的難しい例を挙げている。波形データに入っているノイズには、データ点毎に揺らぐ信号数値化時の誤差ノイズ、数十 ns 毎に階段状に揺らぐセンサー検出精度ノイズ、振動を発生する打撃時に混入してしまう打撃時電気ノイズなどが存在する。またその他に、S 波/P 波ノイズと呼んでいるノイズもある。振動には、地震の P 波と S 波で知られている様に、波の進行方向に揺れる縦波 (P 波) と、進行方向とは垂直な方向に揺れる横波 (S 波) があり、P 波の方が伝播速度が速い。振動を検出するセンサーは 3 方向の変位をそれぞれ検知して方向毎に波形を出力するが、P 波と S 波を完全に分離することは困難で、どちらのデータにもそれぞれもう一方の成分が混入してしまう。P 波の信号に混入してしまう S 波の成分を S 波ノイズ、S 波の信号に混入してしまう P 波の成分を P 波ノイズとここでは呼ぶ。

図 3 には P 波の信号例を示す。縦軸にはセンサーの読み出した電圧 (V) をプロットしているが、振幅 (変位) の大きさはこの電圧に比例する。観測したままの生データは茶色の細線で示す様に細かく振動しているため、移動平均でスムージングを行って青い実線に変換し、これを基に初動点の解析を行っている。この時、スムージングが強すぎると初動点の解析に使う勾配が緩やかになりすぎて解析値に影響するので、細かい振動を抑えつつ勾配を変化させない程度の、適切なスムージング強度をデータ毎に見出す必要がある。図 3(a) のデータの場合、打撃ノイズが尾を引いて P 波の信号を見分けづらくしている。比較的振幅が大きくて綺麗な正弦波に近い部分を信号と見なし、その立ち上がりとみられる部分 (点線で表した長方形の部分) を図 3(b) に拡大して表示している。拡大図において、P 波信号の最初のピークの手前の、勾配最大の地点から接線を引き、振幅 0 の横線との交点を初動点と見なして赤い縦線を引いている。ちなみに、初動点からある程度の時間 (振動 1 周期 ~ 2 周期程度) が経った後の信号には、S 波ノイズやサンプルの側面で反射した後にセンサーに到達した P 波などが混入するので、綺麗な正弦波は長く続かない。

図 4-6 には S 波の信号例を示す。S 波の解析では、P 波ノイズが常に先行して到達するので、そのノイズと信号を見分ける必要があり、P 波の解析より難しい。P 波ノイズの振幅は小さめだが無視できない大きさはあるので、S 波の一部なのか見分けるのは必ずしも容易でない。振幅の最も大きい部分を S 波信号と考え、その立ち上がりと見做せる部分を探して行くことになる。図 4 と 5 の様に立ち上がり部分の波形にショルダーがある場合、2 つの波 (S 波信号と P 波ノイズ) が混合していることが明らかなので比較的わかり易い。

図 6 は珍しい例で、打撃ノイズが大きく尾を引いている上に、P 波ノイズと S 波信号が混合する部分の位相がたまたま揃っているらしく、1 つの波が連続している様に見えるため、どのピークが S 波信号の最初のピークなのかわかりにくい。ここでは最大振幅のピークからあまり離れていない範囲にあって、最初のピークは正の振幅のはずだという 2 つの条件から、初動点を決定している。サンプルへのセンサーの取り付け方と回路

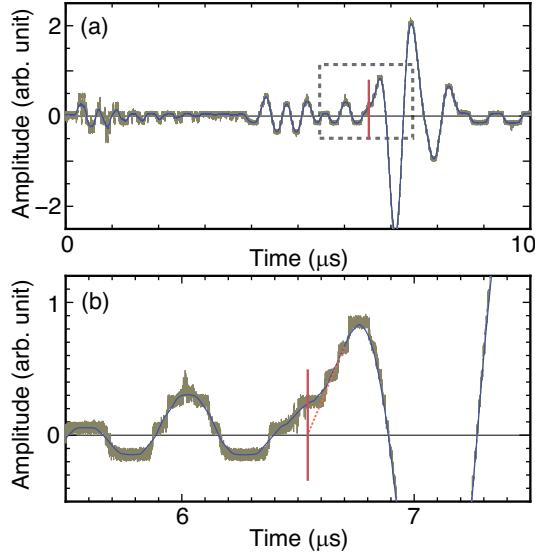


図 4 S 波の弾性波データの例

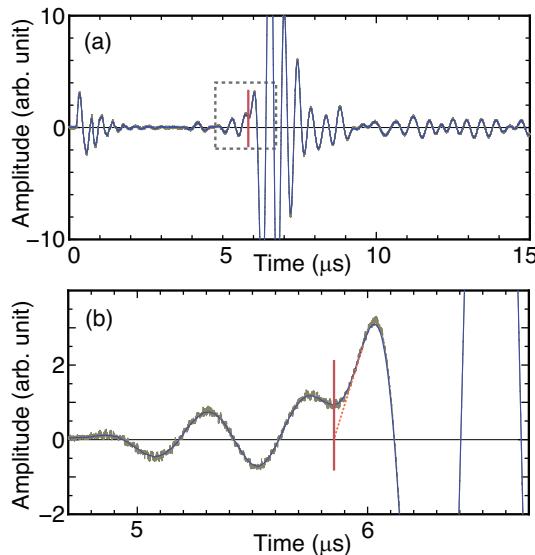


図 5 S 波の弾性波データの例

への接続法によって、最初の振動が正の符号を持つか負の符号を持つかが決まるが、センサーを付けたまま圧力などを変えて連続的にデータをとった場合や、同じ人物がサンプルを変えながら多数のデータを取った場合にはそれらの条件が同一だと期待できる。そのため同時に取得したデータでもっと解析しやすいデータがある場合、信号の最初の符号はそれらを参考にして推定することができる。

図 7 は S 波の解析例だが、1 番目のピーク時刻と 2 番目のピーク時刻から初動点を決定した場合の例である。波形データは図 5 に似ているが、最初のピークの手前のショルダーが大きすぎて勾配最大の地点の勾配が緩やか過ぎる。このため図 7(b) の様に接線を引いて初動点を求めると、かなり早めの時刻になってしまふ。この様な場合は図 7(c) の様に最初のピークの時刻 t_1 と 2 番目のピークの時刻 t_2 を求め、 $t_0 = t_1 - (t_2 - t_1)/2$ により初動点を決定する。

これらの例でわかる様に、手動解析では大きく分けて 3 つの

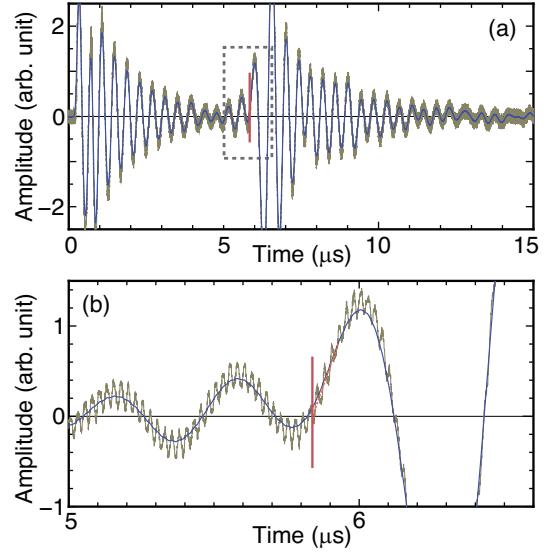


図 6 S 波の弾性波データの例

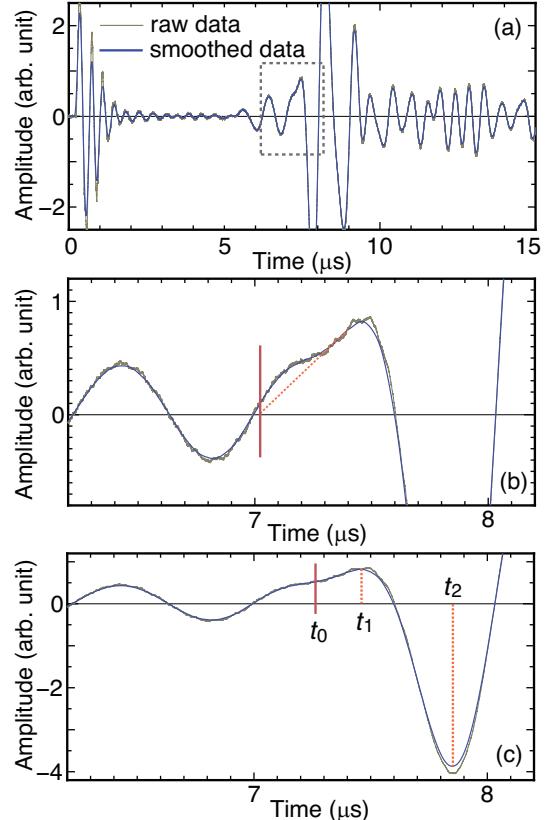


図 7 S 波の弾性波データの例。(b) では勾配最大の地点から接線を引いて初動点を求め、(c) では第 1 のピークと第 2 のピークの時刻から計算して初動点を求めている。

判断を常に行う。すなわち (1) 短周期のノイズを除去して十分な平滑化をしつつ勾配が生データと乖離し過ぎない様、データ毎に最適なスムージング強度を決定する必要があり、(2) 各種ノイズ (特に P 波ノイズ) と信号を様々な観点から判断して見分ける必要があり、(3) データの内容によって 2 種類の初動点決定法を使い分ける必要がある。これらの判断の複雑さのため、単純なプログラムでは解析の自動化が難しい。

3 機械学習による解析方法

ディープラーニングは画像認識をはじめ自然言語処理や囲碁・将棋など様々な分野で発展が著しい。1次元のデータに対する応用でも音声認識などの需要があり、多くの研究がなされている。画像認識では更に、セマンティックセグメンテーションと呼ばれる手法により画像内の複数の物体を分離しそのそれぞれを識別する技術が、自動運転などに必要な技術として発展している。医療分野でもこのセグメンテーション技術は活用され、レントゲン画像の解析などでは識別した領域の形と範囲が重要なため、その輪郭を精密に決定する方法としてアテンション機構などが考案されている。1次元データへの応用では、信号の種類の識別自体は良く議論されていても、このセグメンテーションに相当する境界点の精密な特定に注意を払った例は我々の知る限りまだほとんどない。振動のP波やS波の検出という意味では、地震を検出する目的で機械学習を利用する例[2-5]が報告されており本研究に近い面があるが、これらの研究は地震の発生を認識するのが目的なので、初動点を精密に決定する事には注力していない。

本研究の目的は岩石に対する振動付与実験により得られた波形データを自動的に解析し、信号部分を識別してその境界点、すなわち初動点を精密に特定する技術を開発することである。そのため、画像のセグメーテーション技術を1次元データ向けにカスタマイズし、特にその境界点を精密に特定する方法を検討した。

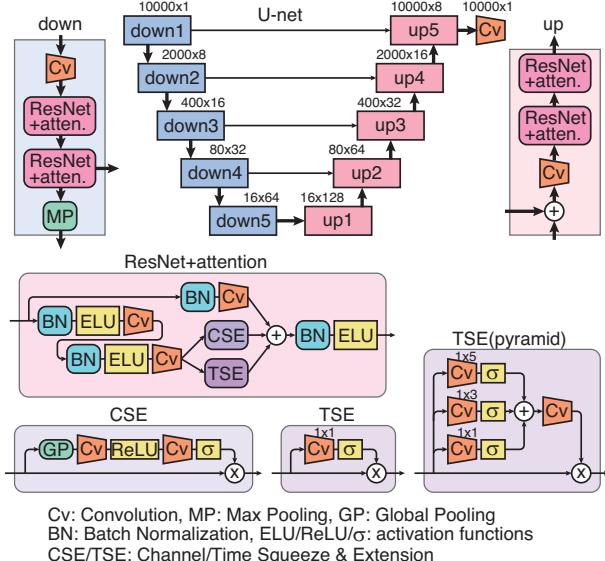


図 8 初動点解析法のネットワーク構造の概略

図8に最終的に得られた解析方法の大まかな流れを示す。ベースとしてU-net[6]と呼ばれるネットワーク構造を使用している。1万点の時刻-振幅データを入力として4回のダウンサンプリングを行い、識別を行った後にアップサンプリングを繰り返し、元と同じ1万点の解像度で識別範囲を精密に出力する。ダウンサンプリング時の途中のデータをアップサンプリング時に混合させることにより、一度圧縮した情報を復元して精

密な輪郭を再現する、セグメンテーション特有の方法が使われている。

我々が開発した手法はこのダウンサンプリングやアップサンプリングの各処理において、ResNet[7]と呼ばれる残差学習することで効率的に学習を行うしくみと、アテンション機構[8]という領域境界の学習を特に厚くするしくみを組み込んでいることが特色である。図の中でCSE(Channel Squeeze & Extension)とTSE(Time Squeeze & Extension)と表記している部分がこのアテンション機構に相当する部分で、CSEはチャネル方向(複数の異なるフィルターをかけて分岐させたデータ列)のアテンション、TSEは時間方向のアテンションを担当する。TSEは 1×1 のカーネル1種類を用いた処理を基本とするが、その他に 1×3 及び 1×5 のカーネルを同時に用いたピラミッド型TSE処理も試している。これは狭い範囲と広い範囲のカーネルで同時に処理することにより広い視野で波形の特徴をとらえようとする試みで、画像(2次元データ)に対し複数のカーネルサイズを用いて行われる手法[9]を1次元に応用したものである。

4 結 果

実験データの手動解析により合計777個の教師データを用意し、これを用いて機械学習による解析精度の評価を行った。なお、ここではP波のデータとS波のデータを混合して学習し、どちらのデータでも区別なく自動解析できることを目指している。

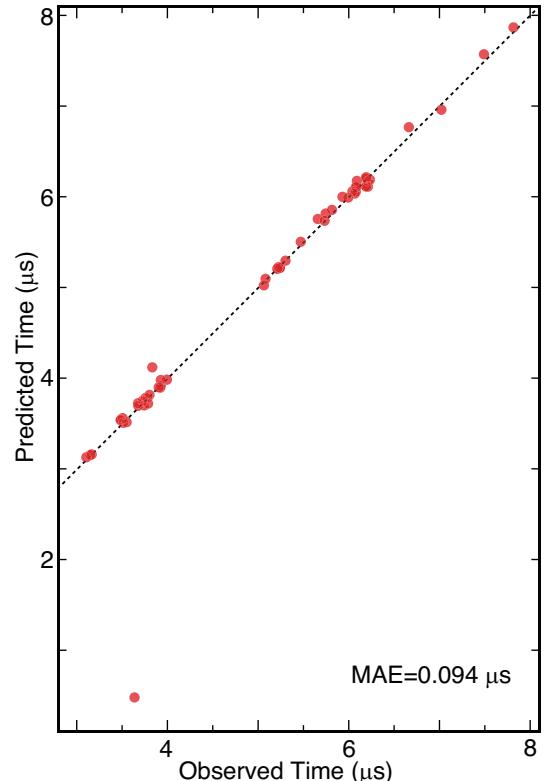


図9 466個の教師データで学習した後の解析結果の散布図。

図9は手動解析したデータの一部、576個だけを使い、その

うち 466 個を学習用、52 個をバリデーション用、58 個を評価用に使用して学習及び評価を行った結果である。過学習に陥らないよう、学習の打ち切り点を決定するためにバリデーション用のデータを使用している。また、TSE 处理では 1×1 カーネルのみを使用している。グラフは横軸が手動で解析した初動点(正解)で、縦軸がここで開発した手法により求めた(予測した)初動点である。 $y = x$ の線に点が近いほど精度が高い。ここでは 1 点だけ正解から大きく外れて低い予測値を出してしまった点がある。これは打撃ノイズと信号を間違えて全く違う地点を初動点と判定してしまった結果である。この様な誤りがあるため MAE(Mean Absolute Error) は $0.094\mu\text{s}$ と、この後の結果と比較して大きめの数値になっている。ただし、岩石の組織構造解析のために必要な精度は、 $\text{MAE}=0.1\mu\text{s}$ と見積もることができるので、この精度でも既に最低限の条件を満たしている。

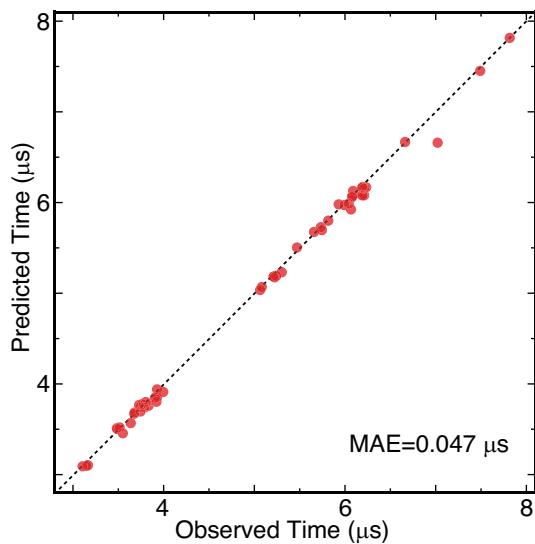


図 10 201 個のデータを追加し合計 667 個の教師データ学習した後の解析結果の散布図。

図 10 は使用する正解データを増やし、667 個を学習用、52 個をバリデーション用、58 個を評価用とした結果である。TSE 处理では 1×1 カーネルのみを使用している。図 9 にあった大幅に予測値が低い点は無くなり、 $\text{MAE}=0.047\mu\text{s}$ と大きく向上している。学習用データが 4 割増えた事により、精度が向上したと考えられる。

図 11 は図 10 と同じデータを用い、TSE 处理に 3 種類のサイズのカーネルを使うピラミッド型処理を採用することにより、時間方向のアテンション機構を改良した結果である。図 10 と比べて $y = x$ からのずれが小さくなっていることが確認でき、 $\text{MAE}=0.039\mu\text{s}$ と更に精度が向上している。

5 まとめ

我々は地下の物性値分布推定に活用される、弾性波速度測定実験データの自動初動点解析技術を開発した。ディープラーニングの U-net と呼ばれるネットワーク構造をベースにして、ResNet と呼ばれる残差学習機構とアテンションと呼ばれる重

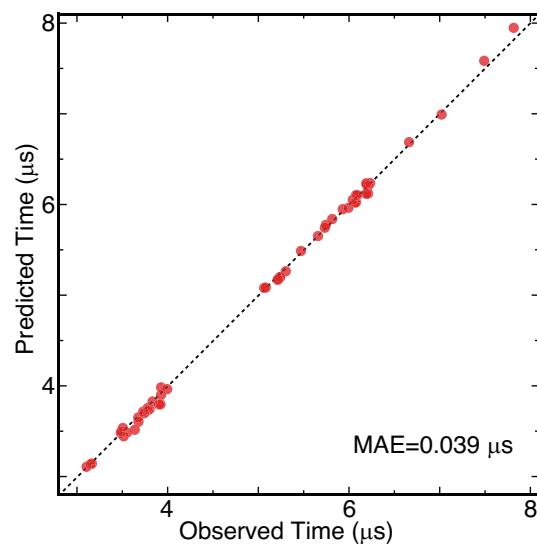


図 11 667 個の教師データを用い、アテンション機構にピラミッド型処理を採用した場合の解析結果の散布図。

み付け学習機構を組み合わせることにより、 $\text{MAE}=0.039\mu\text{s}$ という精度を達成した。これは目視で要求される精度 $0.1\mu\text{s}$ を遙かに上回る。

従来、専門家の目視による判定以外には困難であった高精度な初動点解析の自動化が可能となったことにより、大量の実験データ解析を効率化すると同時に、解析担当者毎のバイアスを排除し、全体的な精度も高まるものと考えられる。その結果、この技術により地下資源探査技術が向上するものと期待している。

文 献

- [1] K. Zaima and I. Katayama, "Evolution of elastic wave velocities and amplitudes during triaxial deformation of Aji granite under dry and water-saturated conditions", Journal of Geophysical Research: Solid Earth, vol. 123, 9601–9614 (2018).
- [2] D. Kirschner, N. Howes, C. Daly, J. Mukherjee, and J. Li, "Detecting P- and S-wave arrivals with a recurrent neural network", Society of Exploration Geophysicists, (2019).
- [3] S. M. Mousavi, W. Zhu, Y. Sheng *et al.*, "CRED: A Deep Residual Network of Convolutional and Recurrent Units for Earthquake Signal Detection", Sci. Rep. vol. 9, 10267 (2019).
- [4] 菊池栄 *et al.*, "深発月震源分類に適した機械学習法の研究. 宇宙航空研究開発機構研究開発報告", 宇宙科学情報解析論文誌: 第 6 号, 51–62, (2017).
- [5] 後藤康路 *et al.*, "波形の類似性を考慮した大規模月地震データの SOM による可視化システム", 宇宙航空研究開発機構研究開発報告: 宇宙科学情報解析論文誌: 第 3 号, 137–146, (2014).
- [6] Olaf Ronneberger, Philipp Fischer, Thomas Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation", Medical Image Computing and Computer-Assisted Intervention (MICCAI), Springer, LNCS, Vol.9351: 234–241, (2015)
- [7] K. He, X. Zhang, S. Ren and J. Sun, "Deep Residual Learning for Image Recognition", 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, 770–778, (2016).
- [8] A. G. Roy, N. Navab, C. Wachinger, "Concurrent Spatial

- and Channel 'Squeeze & Excitation' in Fully Convolutional Networks" in Medical Image Computing and Computer Assisted Intervention MICCAI 2018, Lecture Notes in Computer Science, vol. 11070. Springer, Cham, (2018).
- [9] Yu, Fisher, and Vladlen Koltun, "Multi-Scale Context Aggregation by Dilated Convolutions", arXiv:1511.07122 (2016).