

知見の再利用を推進するコミュニティ型分析プロセス支援システムの開発と初期評価

高田 実佳[†] 福原 聖人[†] 田尻 力也[†] 徳永 竜也[†] 玉山尚太郎[†]
直野 健[†]

† (株) 日立製作所 研究開発グループ 〒185-8601 東京都国分寺市東恋ヶ窪一丁目 280 番地
E-mail: †{mika.takata.nc,kiyohito.fukuhara.xj,rikiya.tajiri.kc}@hitachi.com,
†{tatsuya.tokunaga.ek,shotaro.tamayama.wq,ken.naono.aw}@hitachi.com

あらまし 近年、様々な分野でビッグデータを分析し、新たな価値を創出することによる業務向上への期待が高まっている。例えば自治体では高齢化が進む社会で、よりよい医療・介護施策に向けて、自治体の保有する医療と介護のデータを掛け合わせ、市民に対して適切なサービスを提供する施策の立案が求められている。しかし、多くの分野で新たな価値を創出する為には、各分析対象に対し高度な知識と経験を用いたデータ理解、データ準備、モデリング、評価、といった試行錯誤を伴う一連の分析処理の工程の実施が必要であった。本論文では、分析専門家が知識と経験を用いて実施する分析の試行錯誤工程の数を削減するコミュニティ型分析プロセス支援システムを提案し、分析処理の工程を削減できることを示す。

キーワード 医療・介護, 試行錯誤, 分析プロセス支援

1 はじめに

社会問題が複雑化する中、実世界とサイバー空間を融合させ、実世界の様々な情報を IoT によってサイバー空間に収集・蓄積し、AI を活用して分析・判断することで実世界にフィードバックさせる Cyber Physical System(CPS) で実現する超スマート社会「Society 5.0」への期待が高まっている [1]。特にヘルスケア分野では、超高齢化社会の到来により、医療費・介護費など社会保障費の高騰、医療ミス、介護士不足、など、日本のみならず全世界で一般市民の生活に大きく関わる問題となっており、一刻も早い課題の解決が必要とされている [2]。しかしながら、AI の判断結果を病院や保健士、監査などミッションクリティカルな業務へフィードバックするには AI の信頼性が未だ乏しい。信頼性にはセキュリティ、プライバシー、公平性、など様々な観点があるが、その中でも AI の判断根拠や成り立ちを明らかにする AI の透明性の確保が必須である。

これに対し XAI(eXplainable AI) 技術や MLflow などモデル管理技術 [3] などの既存技術は、あくまで AI の入出力値を管理し、入力値の要素である特徴量のどれが AI の結果に対する寄与度を示すかに留まっている。加えて、Pentaho や Tableau などデータリネージを向上する既存ツールにおいても、AI の入力値の導出を示すデータリネージと AI の出力結果結果の関連付けができず、データソースから AI の出力結果までの End-to-End AI 分析プロセスに透明性を与える事ができていない。その為、AI 分析プロセスを再現するに十分な情報が保証されておらず、AI の判断の信頼性を保証することが困難である。

本論文では、AI の透明性を向上させることで、AI の判断への信頼度を向上させる End-to-End AI 分析プロセス管理システ

ムについて述べる。2 章で関連研究、3 章ではヘルスケア・公共分野でのユースケースと課題、4 章にて我々が提案する多くの分析者に AI 分析プロセス管理の提供を目指す技術の詳細、5 章にて評価結果、6 章でまとめを述べる。

2 関連研究

AI の信頼性・透明性向上の為、AI のデータ・モデル管理技術に関して近年発表数が増加している。その中には大きく分けて 3 種類あり、(1) AI を従来データ管理システムに適用するもの、(2) 従来データ管理システムの理論を応用した AI、(3) AI のライフサイクル、である [4]。特に本研究に係る (3) の分野では、Feature Engineering, Machine Learning (ML) および Hyper Tuning Parameter の組み合わせである AI 分析プロセスに対して OSS の MLflow [3] では不十分なデータソースから AI 分析結果までの End-to-End AI 分析プロセスの管理を必要性を論じ概念的に最適な組み合わせを探索するアプローチの提案 [5] や、複数の分析を行うユースケースを元に、データ間の関連性を用いて再利用や共有する必要性について述べるものなど概念的な提案を論ずる論文 [6] など、End-to-End AI 分析プロセスの透明性に関するものが増えている [7] [8]。また、分析用のデータの公平性をマテリアライズビューを用いて担保できる事を証明といった AI に限らないデータ分析の倫理に関する論文への注目が増えている [9]。

また、解決すべき課題が複雑化、IoT による分析に取り扱うデータの多様化が進むにつれ、AI 分析プロセスが複雑化している。このため、学習モデルとその生成に用いた入出力およびパラメタの管理 [3]、学習モデルの共有 [13] [14] [15]、自動生成 [16] [17] [18] [19] の機能をもつ OSS や製品が増えている。

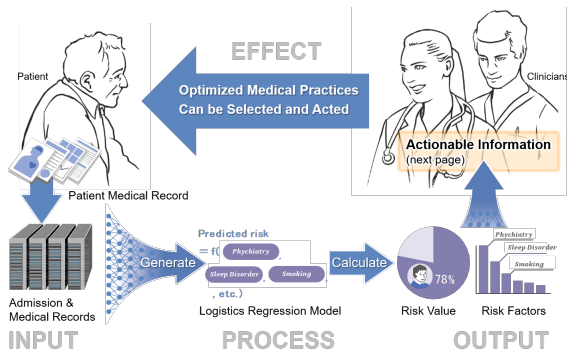


図 1 AI Transparency Requirement in Clinical Decision Support

AI 活用を容易にする AI framework も多く増えてきており、Kuberflow [20], Acumos [21] などが容易な ML 環境構築手段として注目されている。ただし、これらはあくまで ML を容易に利用しやすくするものであり、ML ワークフローをトレースや再現するにとどまる。一方で、Tableau, Talend 等データ処理・管理ベンダは分析アジリティ向上を推進し、セルフ BI のクオリティを向上する為データリネージの可視化を推進している [22] [23]。

3 AI 分析ユースケースにおける課題抽出

本章は、社会問題に対して、IoT によって実世界の様々なデータをサイバー空間に収集・蓄積し、AI を活用して分析、結果を実世界へフィードバックし、ドメインエキスパートが判断する為の意思決定に利用する実ユースケースを紹介し、従来技術での共通課題を抽出する。

3.1 AI 分析ユースケースとその課題

3.1.1 病院向け再入院予測

心疾患は腎臓・肝臓など多機能障害を経て心臓負荷が重なることで生じる病であり、多数の病気を併発している患者が多い。その為重症患者が多く、入院しても再入院を繰り返す事が米国で深刻な問題となっている。その為米国では病院に対し、一定の再入院率を超過した病院に多額のペナルティを要求する法案を設立し、実施している。こうした背景から、病院経営者は心疾患患者の再入院を事前に予測することで無駄な退院を避ける必要がある。

しかし、退院前カンファレンスにおいてただ患者ごとに再入院予測を実施してもミッションクリティカルな臨床の場では AI の予測根拠に納得がいけない。退院を決定する医療従事者に AI の説明性・根拠データなど透明性を示す事が必要不可欠である。その様子を図 1 に示す。

こうしたユースケースから、報告者らは XAI のみでは不十分であり、AI 分析プロセスをメタデータ管理を行う事によって一元的に管理し、データソースから予測結果までトレース可能な管理方式を提案した [10]。これにより、米国の電子カルテを用いた AI の透明性の検証、再学習プロセスを高速に実行可能である事、および、予測結果に貢献度が高いデータを選択する

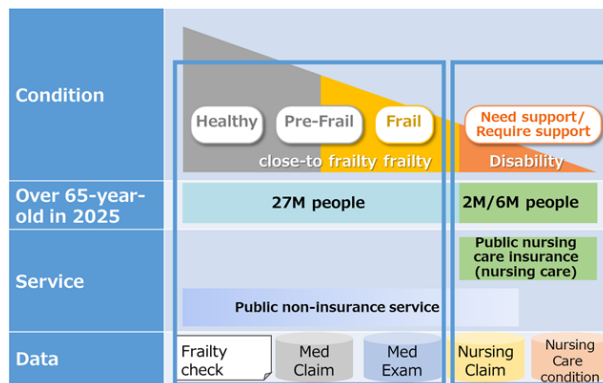


図 2 Frailty and Disability

事で再学習の精度向上する事を明らかにした。

しかし、本件では透明性を検証する為にはメタデータ管理 DBMS が SQL インターフェースしか持たない為、高度な DBMS の知識をもって根拠検索クエリを SQL で記述して問い合わせをする必要があった。例えば、AI の根拠として AI の予測を説明するリスク特徴量からその生成プロセスをトレースバックするといった場合に、分析プロセスを実行毎に、複雑な副問い合わせクエリの記述をメタデータ DB に対して行う必要があった。また、AI 分析プロセスの共有性に関してもメタデータ管理へのアクセス権を付与し、再利用できる End-to-End AI 分析プロセスを検索する SQL を再帰的に記述する必要があった。

このため、特定の DBMS および分析両方の有識者のみしか AI モデルの生成過程を確認し透明性を確認することができず、DBMS 知識のない分析者が容易に他病院や日本など他国への適用を行う事できなかった。これより、汎用的なデータに適用した場合の容易なユーザビリティが課題である。

3.1.2 自治体向け介護支援

介護の必要がなく、制限することなく日常生活を過ごせる期間を健康寿命と言い、健康寿命の延長は Society 5.0 の重要課題の一つである。厚労省は 2020 年度までにデータヘルス改革の基盤を構築した上で、2021 年度以降に 1) ゲノム医療・AI 活用の推進、2) 自身のデータを基に健康改善につなげる Personal Health Record (PHR) の推進、3) 医療・介護現場の情報利活用の推進、4) データベースの効果的な利活用の推進を目指している [11]。

図 2 に、2025 年の 65 歳以上の健康あるいはフレイル状態と要支援/要介護認定の推定人数を示す。フレイルとは加齢による心身機能の低下により生活機能障害、要介護状態、死亡などの転記に陥りやすい虚弱状態を指し、介護予防にはこのフレイルで状態を留めることが重要とされている [11]。

一方で、現在フレイル状態の人を対象としたサービスは基本的に保険対象外であり、フレイル状態者に対する予防が不足している。こうした状態に対し、我々は元気高齢社会を目指す域包括ケアに向けた政策提言を行っているが、そのうちの 1 つが地方自治体で実施する介護計画を担う保健士向けの要介護支援である。一般的に保健士は AI やデータサイエンスの知識はなく、知識や経験に基づいて対象者の介護サービスを決定してい

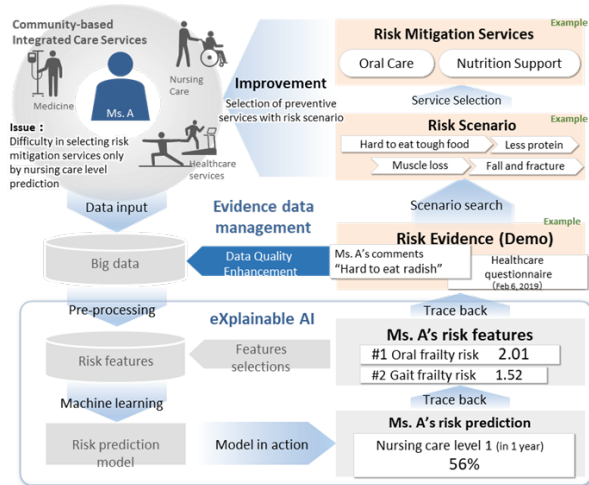


図 3 Nursing care use-case




図 4 Workflow of Medical Researcher using NDB

る。しかし個人ごとに既往歴や状態が異なり、どの介護サービス提供事業者のどのサービスが適しているかを決めるのは容易ではない。

この問題に対し、図 3 に示す通り、我々は保健士向けのサービスを提案している [10]。医療レセプト、介護レセプト、PHR などの医療データを収集し、特徴量を生成、そこから学習モデルを構築し、対象となるフレイル・要支援予備軍の市民に対し約 3 年後の要介護度確率を予測する。その際に予測値と共にその根拠データおよびリスクを低減する介護サービスを保健士に推薦する仕組みである。

しかし、[10] は米国の電子カルテ特有のデータ処理方式を採用しており、日本の医療レセプト・介護レセプトといった形式もコンテンツも違うデータの利用も可能にする必要がある。さらに、医療・介護の情報利活用の推進により、PHR や健診データなどが活用範囲として拡張がありえる事を考慮する必要がある為、利用するデータ拡張に対応できる汎用性が課題である。

3.1.3 ナショナルデータベースを用いた分析結果の論文化

図 4 は、厚生労働省のナショナルデータベースのプライマリーユーザである医療研究者の主なタスクである論文を書くまでの一般的なステップである [12]。計画、データ抽出、整形・変換、クレンジング、分析、そして最後に論文の執筆というステップからなる。医療研究者はデータ準備に関してはデータエンジニア、データサイエンティストに依頼し、分析に十分なデータを入手してデータを用いての分析・評価・発表が主な業務である。これと [10] とのフローを照らし合わせる事ができる。

3.2 課題の抽出と整理

図 5 に示した [10] の各関係者とタスクと、図 4 で示した一般的ステップと照会することで、主要な課題を抽出する。各関係

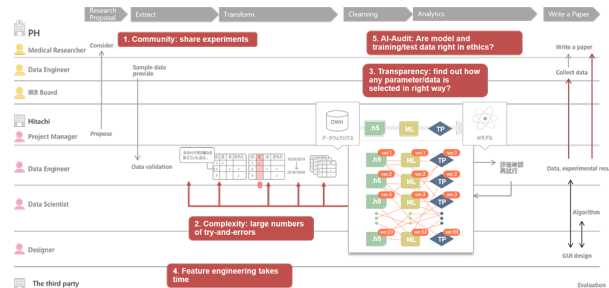


図 5 Operational Workflow of Medical Researcher

者のタスクは、まず医療機関の医療研究者とベンダのプロジェクトマネージャが研究内容について合意する事から始まる。その後、医療機関のデータエンジニアが医療研究者と相談しベンダにデータを提供する。続いて、ベンダのデータエンジニア・データサイエンティストが様々なデータ処理・特徴量を選択を繰り返し Tyr-and-Error を実行し予測精度を検証する。結果を医療機関に送付し、医療研究者を筆頭に論文化する、という流れである。この共同研究を通じ、明らかになった課題が以下である。

- (1) 共有性：検討の経緯・経験を第三者に伝える為の情報等を容易に共有可能
- (2) Try-and-Error の回数削減：知識・経験によらず正解に辿り着くまでの試行錯誤の回数を削減
- (3) 透明性：データ処理一連のプロセスが複雑な状況下でも、分析プロセスを追跡・再現可能
- (4) 分析時間の高速化：分析プロセス中のデータ準備時間を高速化
- (5) 正当性の証明：倫理上正しいデータアクセス・処理をしている事を明示可能

これらのうち、課題に対し、従来技術で解決していない課題は「汎用的なデータを用いた AI 分析に対する透明性の確保 (3)」、および、「AI 分析プロセスの共有性 (1)」である。これらを解決する技術について次章で述べる。

4 End-to-End AI 分析プロセス管理システムの提案

4.1 End-to-End AI 分析プロセスの可視化

汎用的なデータを用いた AI 分析に対する透明性を確保する為、2 種類の End-to-End AI 分析プロセスの可視化を実現する GUI を提案する。

1 つは、多数の試行錯誤プロセスの概要をつかみ、何の KPI に対しどの AI モデルを作成し、そのモデルをどう変更し試行錯誤を実行したか、といった AI 分析プロセスの履歴をユーザが GUI 操作で容易に把握できる第 1 の GUI 画面である。2 つ目は、1 つの AI 分析プロセスにおけるデータソースから特徴量生成、モデリングといった AI 分析プロセスのカテゴリーと各カテゴリーの詳細情報を簡単な操作で入手できる第 2 の GUI 画面である。

提案する第 1 の GUI 画面を図 6 に示す。図 6 左方に時系列でモデルとテストの履歴をツリー的に記載し、End-to-End AI




図 6 Modeling and Test time-series trace

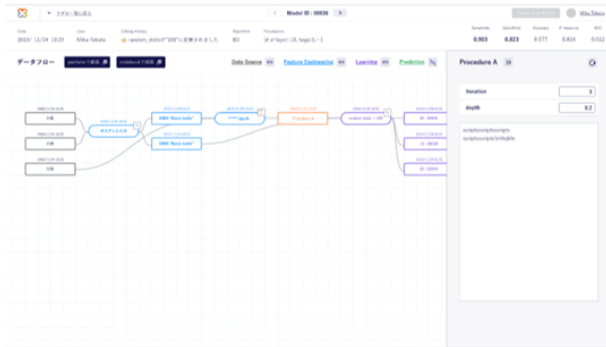


図 7 End-to-End AI analytics process GUI

分析プロセスの変更履歴をコメントとして残す様子を示す。一番新しいモデルまたはテストが上位であり、再実行や新規実行を繰り返す毎にツリーで、モデルとテストの関係性を示す事とした。これによって、モデルの継承関係と、どの AI モデルを用いてテストに利用したのかが容易に明示できる事に着目した。画面右方に AI モデルに関するパラメータ群を示し、変更点や他モデルとの相違が色で明示されることでユーザが利用したいモデルの選択に効果的であると考えた。

次に、第 2 の GUI 画面を図 7 に示す。図 7 はデータソースから、ETL (Extract, Transfer and Loading), DWH (Data Warehouse) 作成、特徴量生成、学習、パラメータ設定、予測、予測結果のリスク特徴量までの End-to-End AI 分析プロセスの表示を示している。中央に分析プロセスを詳細に可視化でき、Data source, Feature Engineering, Modeling, Prediction のカテゴリ分類ごとに表示・非表示や、詳細を右側パネルで表示・編集可能とした。これにより、再実行が容易になる。

4.2 コミュニティ機能

AI 分析プロセスの共有性という課題に対し、複数人で End-to-End 分析プロセスを許諾次第で知見として共有し、閲覧および再目的化 (Repurpose) 可能が容易に実行できる機能を提案する。この概念を図 8 に示す。User A が蓄積した分析プロセスは User A がトレースできるだけでなく、コミュニティを通じて User B に共有可能、他分野への共有可能である。この概念を実現する為、AI 分析プロセスの共有を実現するコミュニティ機能およびそれを利用した MyLibrary 機能を提案する。

図 9 にコミュニティ機能の GUI を示す。複数ユーザが分析プロセスを共有し、コミュニケーション可能な GUI の様子を示す。1 つの AI 分析ユースケースをプロジェクトと呼び、1 プロジェクトに対して多数の試行錯誤の AI 分析プロセスを遂行

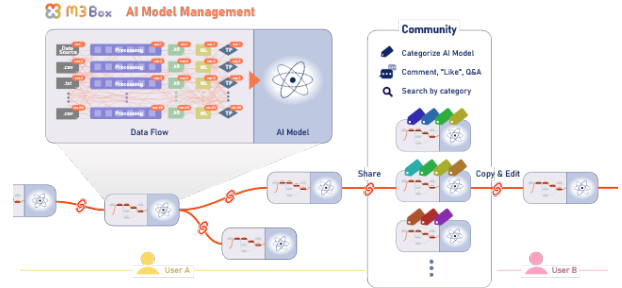


図 8 Community Image



図 9 Community GUI

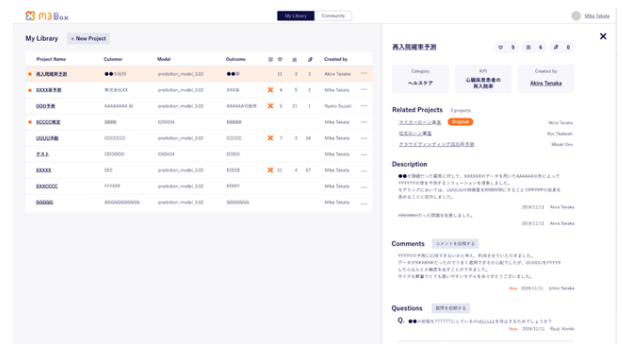


図 10 My Library GUI

し、本コミュニティで公開可能とした。コミュニティ画面では、ヘルスケアやエネルギーなど業種や、予測や最適化探索等の AI の問題、再入院予測や要介護度予測といった KPI, Logistic Regression や Support Vector Machine 等アルゴリズムなどで絞り込みが可能で、Reuse, Repurpose 可能なプロジェクトを検索・選択し、お気に入りプロジェクトを選択できる事を提案する。

次に、MyLibrary 機能をもつ GUI を図 10 に示す。本 GUI 上で 1 ユーザのプロジェクト一覧画面を確認する事ができ、このうちの一部を図 9 で公開できる事とする。1 プロジェクトの分析対象やアルゴリズムや概要を右方で確認でき、コミュニティを通じてダウンロードまたは再利用された場合には、関係するプロジェクトとしてその情報を確認可能とした

5 End-to-End AI 分析プロセス管理システムの評価

我々は、End-to-End AI 分析プロセス管理システムのプロト

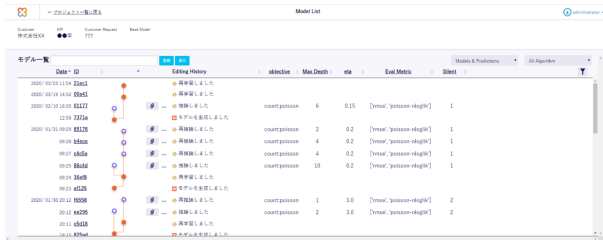


図 11 GUI of Modeling and Test trace

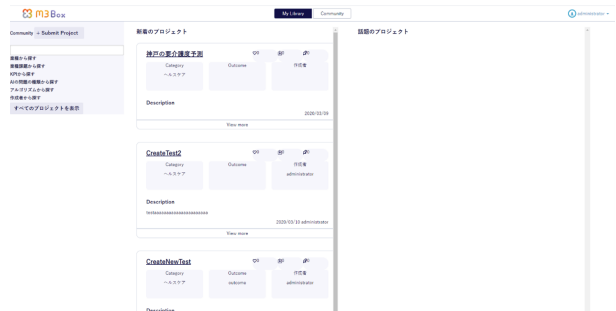


図 13 GUI of Community

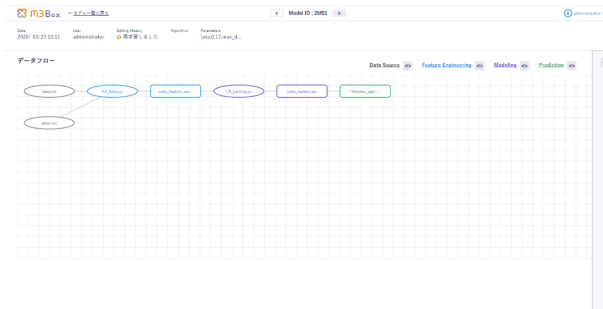


図 12 GUI of End-to-End AI data process




図 14 GUI of My Library

タイプを作成し、3.1 節で述べたユースケースにおける分析を対象に提案手法の評価を行った。利用したデータは、介護レセプトのサンプルデータである。本データを用いて、分析プロセスを実施した。サンプルデータは、「基本」、「明細」、「コード表」、「サービス点数マスク」シートから構成されるエクセルファイルである。本データには、3000 人の介護サービス需給対象者の 2 か月分の各サービス需給回数が 1 月分毎に記載されている。

5.1 End-to-End AI 分析プロセスの透明性の確保の評価

前述したサンプルデータを用いてデータ分析プロセスを実施した。本データ分析プロセスでは、介護ケアサービス受給者の 1 か月後～3 年後の要介護度を予測する為の特徴量生成、を実行し、Logistic Regssion (LR) によって所定月の要介護度レベルとその事象確率、およびその説明ファクターを出力行い、実際に要介護度が悪化した人、好転した人と説明ファクターを比較する。

まず、Pentaho PDI [24] を用いて上でサンプルデータを ETL 処理し、正規化を行い、DWH を構築した。次に、特徴量生成、Logistic Regression (LR)、予測、にはそれぞれ python スクリプトを実行した。その結果表示される画面が図 11、図 12 である。図 11 の一回のモデル生成結果の詳細が図 12 である。これにより、分析者は DBMS の知識なく図 11、図 12 で確認でき、AI 分析プロセスの透明性を確認した。

5.2 コミュニティ機能の評価

本実験では、自治体向け介護支援のユースケースとサンプルケースをプロジェクトとして登録する。ユースケースの一覧が図 13 にあり、それらが公開され共有される様子を図 14 に示す。画面左手には業種、業務課題、KPI、AI アルゴリズム、作成者での検索機能があり、コミュニティ内から分析者が利用したい

プロジェクトを容易に選択できる事が確認できた。

これらの結果より、「自治体向け介護支援」ユースケースにおける分析において、分析者が容易に DBMS の知識を使わずとも「汎用的なデータを用いた AI 分析に対する透明性の確保」と「AI 分析プロセスの共有性」の効果を確認した。これにより、本結果と 3.1 節で述べたユースケースにおける AI モデル管理の課題から、今回と同等に今回実証したユースケース以外のデータ分析においても、End-to-End AI 分析プロセス全体の追跡と再現、およびそうした分析プロセスを他者と共有が可能である見通しを得た。

さらに、AI の透明性を検証する為に、従来技術がのメタデータ管理 DB に対し副問い合わせやビューを用いた複雑なクエリを用いていたのに対し、本開発によって、SQL を記載することなく予測のリスク特徴量やモデル自体がどういう処理を行って生成されたのかを容易にトレースバックできる事が明らかになった。これは提案手法を利用するユーザであるデータサイエンティスト・データエンジニアにとって容易に自身の分析プロセスの検証効果があると確認できた。

6 おわりに

本報告では、「病院向け再入院予測」「自治体向け介護支援」「データ利活用サービス」の各分析ユースケース検討を通して、AI の透明性を確保する為に課題であった高度な DBMS の知識なく End-to-End AI 分析プロセスの追跡と再現、およびコミュニティでの共有・再目的利用を実現する End-to-End AI 分析プロセス管理システムを開発し、1 ユースケースにおいて評価し効果を確認した。これにより、他ユースケースでも AI の透明性確保が容易に実現できる見通しを得た。

文 献

- [1] 内閣府, Society 5.0, <https://www8.cao.go.jp/cstp/society5.0/>.
- [2] 日本経済団体連合会, Society 5.0 時代のヘルスケア, https://www.keidanren.or.jp/policy/2018/021_honbun.pdf, 2018.
- [3] MLFlow, <https://mlflow.org>, 2020.
- [4] Neoklis Polyzotis, et.al., Data lifecycle Challenges in Production Machine Learning: A Survey, SIGMOD Record, 2018.
- [5] Kumar, Arun and McCann, Robert and Naughton, Jeffrey and Patel, Jignesh M. Model Selection Management Systems: The Next Frontier of Advanced Analytics. ACM SIGMOD Record. 2016.
- [6] Zachary G. Ives, et.al., dataset Relationship Management, CIDR, 2019.
- [7] Ce Zhang, Arun Kumar, Christopher Re, “Materialization optimizations for feature selection workloads”, SIGMOD Best paper award, 2014.
- [8] Neoklis Polyzotis, et.al., Data lifecycle Challenges in Production Machine Learning: A Survey, SIGMOD Record, 2018.
- [9] Babak Salimi, Luke Rodriguez, Bill Howe, and Dan Suciu, Interventional Fairness : Causal Database Repair for Algorithmic Fairness, SIGMOD Best paper award, 2019.
- [10] AI を用いた患者の再入院リスクの予測値とその根拠データを提示することができる情報ダッシュボードを開発. 研究トピックス. <https://www.hitachi.co.jp/rd/news/topics/2018/1212.html>, 2018.
- [11] 厚生労働省, 今後のデータヘルス改革 (概要), <https://www.mhlw.go.jp/content/12601000/000545973.pdf>, 2019.
- [12] 松居 宏樹. 医療ビッグデータ利用の現状と課題. <https://biostatistics.m.u-tokyo.ac.jp/wp-content/uploads/2019/09/pdf/20181127symp01.pdf>, 2019.
- [13] ModelDB, ISTC Big Data, <http://istc-bigdata.org/index.php/tag/modeldb/>.
- [14] Hui Miao, Ang Li, Larry S. Davis, Amol Deshpande, Towards Unified Data and Lifecycle Management for Deep Learning, <https://arxiv.org/pdf/1611.06224.pdf>.
- [15] AzureML, Microsoft, <https://studio.azureml.net/>.
- [16] Apache MAHOUT, <https://mahout.apache.org/>.
- [17] Scikit-learn, <http://scikit-learn.org/stable/>.
- [18] DataRobot, <https://www.datarobot.com/platform/mlops/>, 2020.
- [19] CloudML, <https://cloud.google.com/vision/automl/docs>, 2020.
- [20] KubeFlow, <https://www.kubeflow.org/docs/>, 2020.
- [21] Acumos, <https://www.acumos.org/>, 2020.
- [22] Tableau, https://help.tableau.com/current/server/en-us/manage_data_section.htm, 2020.
- [23] Talend, <https://www.talend.com/resources/what-is-data-lineage-and-how-to-get-started/>, 2020.
- [24] Pentaho, <https://sourceforge.net/projects/pentaho/>, 2021.