

# SNSにおけるグラフの時間変化を考慮したユーザ推薦手法

山田 瑛平<sup>†</sup> 田島 敬史<sup>††</sup>

<sup>†</sup> 京都大学大学院情報学研究科 〒606-8317 京都府京都市左京区吉田本町

<sup>††</sup> 京都大学大学院情報学研究科 〒606-8317 京都府京都市左京区吉田本町

E-mail: <sup>†</sup>yamada@dl.soc.i.kyoto-u.ac.jp, <sup>††</sup>tajima@i.kyoto-u.ac.jp

あらまし ソーシャルネットワークサービスの人気の高まりにより、高性能なユーザ推薦システムの需要が高まっている。従来の推薦システムは、推薦するユーザを決定するために、ネットワークの構造やコンテンツの類似度を利用している。しかし、それ以外の情報を推薦システムに与えることによって、性能の向上が期待できる。SNSにおけるフォロログラフは、ユーザの働きかけにより刻一刻と変化している。そのため、SNSにおけるユーザ推薦では、時間情報を用いることが性能の向上に繋がるのではないかと考えられる。類似した問題において時間情報を付加する手法はいくつか知られているものの、ユーザ推薦においてそれぞれの手法がどれだけ性能の向上に寄与するかの比較検討は行われていない。本研究では、推薦に時間情報を組み込む手法を二つ提案するとともに、Twitterのフォロログラフを用いた実験を行い、適合率や Coverage, Unexpectedness といった指標を比較した。実験の結果、提案手法のうちの一つは適合率の向上を、もう一つは Coverage および Unexpectedness の向上をもたらすことが明らかとなった。

キーワード ソーシャルネットワークサービス, Twitter, 推薦システム, 時系列分析, ランダムウォーク

## 1 はじめに

近年のインターネットの普及に追従して、Facebook<sup>1</sup>やTwitter<sup>2</sup>, Instagram<sup>3</sup>といった、ソーシャルネットワークサービス(SNS)の利用が拡大している。SNSは、共通した興味や背景を持つ他者と友人関係を構築するため、あるいは現実の友人とのより円滑なコミュニケーションを図るために用いられる。一般的なSNSにおいては、フォローと呼ばれる行為により、別のユーザの投稿が自身のタイムラインに表示されるようになる。フォローはあるユーザから別のユーザへの一方的な働きかけであるが、相互的にフォローしている状態になれば、友人関係が構築されたと考えてよい。SNS上で友人関係を構築するためには、フォローが必要不可欠である。

あるユーザが別のユーザをフォローするためには、言うまでもなくその別のユーザを発見しなければならない。この発見のためには、いくつかの手段が用意されている。第一に、SNSに掲載されている、他のユーザの投稿を自分をフォローしているユーザに向けて掲示する機能を使うことである。これは、Twitterにおいてはリツイートと、Facebookにおいてはシェアと呼ばれる。他のユーザの投稿を自分の投稿として再掲することで、自分をフォローしているユーザに投稿を推薦することができる。この機能は、ユーザが自分の知らないユーザに出会う手段を提供する。第二に、ハッシュタグや検索機能を用いて、未知のユーザの投稿に出会うことである。ハッシュタグはTwitterやFacebookに実装されている機能で、投稿内に挿入することで、同一のハッシュタグを挿入した全ての投稿を閲覧することがで

きる。このような機能は、未知のユーザへの出会いを促進する。第三に、SNSがユーザ推薦システムを提供している場合がある。この機能を用いることで、ユーザはサービスから直接推薦を受けることができる。

実際に適用されている推薦システムの例に、文献[1]を挙げることができる。文献[1]によれば、Twitter社がユーザ推薦のために用いているアルゴリズムに、以下のものがあるとされている。

(1) 当該ユーザをスタート地点とするランダムウォークを実行し、通過したユーザのみをノード集合にとる部分グラフ(Circle of Trustと呼ばれる)を形成する。

(2) 部分グラフにSALSA[2]というアルゴリズムを適用して、得られたスコアを元に推薦する。

ただし、ここではSNSのフォロー関係を表現するグラフを考えている。ノードを各ユーザ、エッジをあるユーザから別のユーザへのフォローを表現するものとしてみなし、エッジは有向辺として表現される。SALSA[2]はR. LempelとS. Moranによって開発されたウェブページのランキングのための手法であり、HITS[3]を改良したアルゴリズムである。SALSAでは、ノードが「ハブ」と「オーソリティ」に分割されているような二部グラフを考え、ハブ側のノードにはハブ度と呼ばれるスコアを、オーソリティ側のノードにはオーソリティ度と呼ばれるスコアを与える。スコアを与える際には、良いハブは良いオーソリティへのリンクを有しており、良いオーソリティは良いハブへのリンクを有しているという規則に従ってスコアを再帰的に付与していく。この再帰的な付与はHITSと同じ考え方であるが、SALSAがHITSと異なるのは、SALSAがランダムウォークを用いて確率的にスコアを付与する点にある。[1]においては、Circle of Trustのユーザから、通過した回数が多かった500のユーザをハブ集合に、Circle of Trustのユーザがフォローして

1 : <https://www.facebook.com/>

2 : <https://twitter.com/>

3 : <https://www.instagram.com/>

いるユーザをオーソリティ集合にとり、SALSA を適用する。

文献 [1] においては、ユーザ推薦が扱う情報はユーザのグラフ構造のデータのみである。しかし、グラフの構造の情報以外にも、推薦に利用できると考えられる情報はある。一例として、各ユーザの投稿内容が挙げられる。前者、すなわちグラフ構造の情報をを用いるものはグラフベースの推薦と呼ばれ、後者、すなわちユーザの投稿内容の情報をを用いるものはコンテンツベースの推薦と呼ばれる。文献 [4] では、アイテムの説明の内容、およびユーザーの興味に基づいてユーザーにアイテムを推薦するシステムについて説明が与えられており、「コンテンツベースの推薦システムは、ウェブページ、ニュース記事、レストラン、テレビ番組、セール品の推薦など、様々な分野で利用されている」と言及されている。このように、推薦には一般的に、グラフ構造の情報、およびコンテンツの情報がよく用いられる。しかし、これらの情報以外にも、推薦に用いることができる情報は存在する。

SNS におけるユーザのネットワークは、ユーザがあるユーザをフォローする、あるいはフォローしていたユーザをアンフォローするといったユーザの働きかけにより、刻一刻と変化している。あるユーザがいつそれぞれのユーザをフォローしたか、どれだけの期間フォローしているか、等の情報は、グラフ構造が時間経過に応じて変化するという SNS の特性を強く反映している。よって、SNS におけるユーザ推薦では、時間的情報を用いることで性能の向上が期待できるのではないかと考えられる。本研究では、時間情報を加味した推薦システムを研究対象に扱う。SNS における時間情報を用いたユーザ推薦の手法を提案し、提案手法を評価するためにに行った実験の結果について報告する。

## 2 関連研究

本節では、時間情報を用いた推薦手法についての関連研究を挙げるとともに、推薦の評価に用いるべき指標を、関連研究に触れつつ示す。

### 2.1 時間的リンク予測

関連研究として、時間的リンク予測の研究を挙げることができる。時間的リンク予測とは、時刻 1 から  $T$  までのグラフのリンクデータが与えられたとき、時刻  $T+1$  でのリンクを予測する問題である。推薦とリンク予測とは、リンクが将来的に生成される確率を考慮する点において共通している。文献 [5] では時系列データとして与えられるグラフデータのリンクを予測する手法が述べられている。時刻  $t$  におけるグラフのデータを  $Z_t$ 、その推定値を  $\hat{Z}_t$  とおくと、以下のように表現される三つの手法が挙げられている。

- $\hat{Z}_t$  を、直近の  $n$  データの平均とする。すなわち、

$$\hat{Z}_t = \frac{Z_{t-1} + Z_{t-2} + \cdots + Z_{t-n}}{n}$$

この手法は Moving Average と呼ばれる。

- $\hat{Z}_t$  を、全データの平均とする。すなわち、

$$\hat{Z}_t = \frac{Z_{t-1} + Z_{t-2} + \cdots + Z_{t-T}}{T}$$

この手法は Average と呼ばれる。

- $\hat{Z}_t$  を、過去の値の加重平均を取ることで予測する。

$$\hat{Z}_t = \alpha Z_{t-1} + (1 - \alpha) \widehat{Z}_{t-1}$$

3 番目の手法は Simple Exponential Smoothing (SES) と呼ばれ、以下のように書き換えられる。

$$\hat{Z}_t = \alpha Z_{t-1} + \alpha(1 - \alpha)Z_{t-2} + \cdots + \alpha(1 - \alpha)^{T-1}Z_{t-T}$$

$\alpha$  は減衰のための係数であり、 $0 < \alpha < 1$  を満たす。SES はすなわち、グラフを集約する際に、過去に遡ったデータであればあるほど、その情報としての価値を下げる手法である。

SES をユーザ推薦に用いることを考える。あるユーザに推薦すべきユーザは、将来的にそのユーザがフォローする可能性の高いユーザである、という仮定のもとでは、リンク予測問題はユーザ推薦問題と等価になる。この仮定の是非については、次節で扱う。SNS の利用者の興味や関心は絶えず変化するので、過去のグラフ構造データとより現在に近い時刻のグラフ構造データとでは、後者により重きを置くべきである。よって、Moving Average や Average に比べて、SES はより SNS のユーザ推薦として適切な手法であると言える。

### 2.2 ユーザ推薦とリンク予測

前節では、ユーザ推薦とリンク予測は等価であるとみなした。これは、推薦のターゲットユーザが将来的にフォローする可能性の高いユーザが、推薦システムが推薦すべきユーザである、という仮定のもとに成り立っている。この仮定は正しいとは言いつれない。なぜなら、ターゲットユーザが将来的にフォローする可能性が高いのであれば、そのユーザを推薦することの価値は少ないからである。もしターゲットユーザがあるユーザ  $u$  を今後フォローする確率が 100% であれば、そのユーザを推薦することに意味はない。ここに、ユーザ推薦とリンク予測との差異を考えることができる。リンク予測はリンクの生起確率を予測することのみが興味の対象である。一方でユーザ推薦は、推薦によってユーザの満足度を高めるという、より高次元的な目標を有している。

リンク予測の際に扱われるリンクの生起確率は様々な要因によって決定づけられるが、ここでは主として二つの要因を考える。ユーザ  $a$  から  $b$  へのリンクの生起確率は、第一に、 $a$  にとって  $b$  がどれだけ見つけやすいユーザであるか、第二に、 $a$  が  $b$  の投稿内容にどれだけ興味があるか、この二つの要因によって決定づけられる。 $a$  が  $b$  の投稿内容に興味を持つ可能性が高かったとしても、 $a$  が  $b$  を見つけることができなければ、 $a$  から  $b$  にリンクは生起しない。リンク予測問題の扱うリンク生起確率は、この二つの要因を同時に扱っている。一方で、ユーザ推薦では、後者、すなわち  $a$  が  $b$  の投稿内容にどれだけ興味があるかが重要である。ユーザ推薦では、 $a$  にとっての  $b$  の見つけやすさよりも、 $b$  の投稿内容に対する  $a$  の興味に重きを置くべきである。また、発見が困難なユーザを推薦することに価値があるため、同程度の興味を抱く可能性のある 2 人のユーザがいれば、推薦システムは見つけにくいユーザの方を推薦すべきである。

以上の議論から、リンク予測問題とユーザ推薦問題とは、別々

の問題として捉えるべきである。ユーザ推薦システムが生起確率の高いリンクを推薦することは必ずしも良いことではなく、ユーザ推薦システムの評価に際して、その精度のみを指標に用いることは適切ではないと言える。[6] はいくつかの推薦システムの評価尺度を提示しており、それらを以下に示す。なお、[6] はアイテム推薦システムの研究であり、以下の説明においてアイテムという用語が登場するのはこのためである。また、[6] は実験において、映画とそれぞれに対するユーザの評価値のデータセットを用いており、評価という用語はこの評価値を指している。

- Unexpectedness. 推薦システムが提示したアイテムのうち、ユーザが知らなかったアイテムの割合。ユーザがあるアイテムを未知か既知かについてを直接調べることはできないので、[6] ではこの未知か既知かの判定を推定している。
- Serendipity. 推薦システムが提示したアイテムのうち、Unexpectedness に含まれ、かつユーザによって一定以上の評価を与えられたアイテムの割合。
- Coverage. 推薦システムが各ユーザに一度でも推薦したもののアイテムの総数。

Coverage を指標として用いることの背景には、集中バイアスという問題がある。協調フィルタリングを用いるような一般的な推薦システムは、過去の売り上げや評価からアイテムを推薦する。そのため、過去のデータが少ないアイテムは、たとえそのアイテムがどれだけ良いものであったとしても、推薦対象に加わりにくい。結果的には、推薦システムが推薦するアイテムの総数が少なくなり、ユーザとアイテムとのマッチングの質の低下に繋がる [7]。Coverage が小さければ小さいほど、集中バイアスが起きていると言える。逆に Coverage が大きければ、推薦システムは多様な推薦をしていることになり、これは好ましい傾向である。本研究では、推薦システムの評価に、精度だけでなくこれらのいくつかの指標を用いることで、推薦システムを総合的に評価する。

### 3 提案手法

既存手法である SES をユーザ推薦に用いることは、以下のようになり単純化される。

- (1) グラフの時系列データを単一のグラフに集約する。
  - (2) 集約により得られたグラフから、推薦リストを得る。
- SES では、時系列データを、過去のデータを減衰させながら総和をとることによって単一の表現に集約する。一方で、前述の手法の順序を入れ替えることで、以下のような手法を考えることもできる。

- (1) グラフの時系列データそれぞれから推薦リストを得る。
- (2) 得られた推薦リストの集合から、単一の推薦リストを得る。

本研究で提案する手法は、この流れを汲むものである。すなわち、各時刻におけるグラフから推薦リストを得て、それらのリストを集約して全体での推薦リストを作成する。時刻  $t$  におけるグラフ  $G_t$  から得られる推薦リストを  $L_t$  とおけば、提案手法の

核となるアルゴリズムは、 $L_1, L_2, \dots, L_T$  を最終的な推薦リスト  $L$  に写像するアルゴリズムとなる。最もシンプルな手法は、 $L_1, L_2, \dots, L_T$  の和集合をとることに類似する考えである。各  $L_t$  中のユーザには、推薦のスコア、すなわちどれだけそのユーザを推薦すべきであるかを表現した値が紐づいているはずである。 $t = 1$  から  $t = T$  までのスコアの総和をとり、その値が大きいものから順に  $k$  ユーザを選択することで、リストの和集合をとることができる。ここで、 $k$  は推薦システムがターゲットユーザに推薦するユーザ数を表す固定値である。しかしこの手法は、前節で述べた、SNS においては現在に近い情報を重視すべきであるという考察に反する。この考察に基づけば、過去のグラフから得られる推薦スコアを減衰させ、スコアの総和をとる手法を考えることができる。本研究で提案する手法の一つは、この手法である。

二つ目の提案手法は、以下の仮定に基づくものである。ターゲットユーザに対して長期間推薦対象となっているユーザがいて、もしそのユーザのことをターゲットユーザが前から知っていたのであれば、これ以上推薦を行ってもターゲットユーザがそのユーザをフォローする確率は低いと考えられるので、推薦すべきではない。推薦対象になっているユーザは、ターゲットユーザがフォローする確率が高いと計算されたユーザである。それにもかかわらずターゲットユーザがそれらのユーザをフォローしないことには、以下の二つの可能性を考えることができる。

- ターゲットユーザがそのユーザのことを知らないで、フォローすることが本質的に不可能な場合。
  - ターゲットユーザはそのユーザのことを知っているが、何らかの事情によりそのユーザをフォローせずにいる場合。
- グラフ  $G_t$  から得られる推薦リストは、実際にターゲットユーザに推薦されたユーザのリストでなく、グラフの状態が  $G_t$  である場合にターゲットユーザに推薦されるべきユーザのリストである。 $L_t$  に含まれるユーザが実際に推薦されたとは限らないので、 $L_t$  に含まれるユーザの存在を、ターゲットユーザが知らない可能性がある。もしそのユーザを知らないのであれば、そのユーザは推薦されるに足る。それ以外の場合、すなわちそのユーザをターゲットユーザが知っているのであれば、そのユーザは長期的に推薦されるべきユーザで、かつターゲットユーザはそのユーザの存在を知っているにもかかわらずフォローをしていないユーザであるので、これ以上の推薦を続ける価値は薄い。
- 提案手法の基本方針は以下のようなものである。

- 各ユーザ  $u$  が初めて推薦リストに登場した時刻を  $t_1$ 、最後に登場した時刻を  $t_2$  とする。時刻  $T$  におけるユーザは、 $t_1$  が  $T$  から遠ければ遠いほど推薦の価値が低くなるはずである。これは、長期的に推薦されていて、かつターゲットユーザがフォローしていないユーザを推薦する価値が低いという前述の議論を反映している。また、 $t_2$  が  $T$  から近ければ近いほど推薦の価値が高くなるはずである。これは、そのユーザが推薦リストに登場した時期が時刻  $T$  に近ければ近いほど強く推薦するべきであるという発想に基づいている。推薦のスコアは、 $T - t_1, T - t_2$  と両者とも反比例すると考えるのが自然である。よって、最終

的な推薦のスコアを  $\frac{1}{T-t_1} + \frac{1}{T-t_2}$  と表現する。

- 上記のスコアに、ユーザ  $u$  をターゲットユーザが知っている確率  $h_u$  を加味する。

$t$  が 1 から  $T-1$  までの値をとるのであれば、 $\frac{1}{T-t_1}$  と  $\frac{1}{T-t_2}$  はともに 0 より大きく 1 以下の値をとる。 $h_u$  が 0 以上 1 以下の値に正規化されていれば、これら三つの値はすべて  $[0,1]$  区間に正規化されていることとなるので、本研究では、三つの値をそのまま加算して最終的なスコアとする。

$h_u$  をどう定義するかについては、様々な手法を考えることができる。最もシンプルなのは、ターゲットユーザがフォローしている、あるいはフォローされているユーザの  $h_u$  の値を 1 とし、それ以外のユーザの  $h_u$  の値を 0 とすることである。しかし推薦においては、推薦対象となるユーザはターゲットユーザがフォローしていないユーザであり、このようなシンプルな定義はターゲットユーザを推薦対象のユーザがフォローしているか否かの差別化を行っているのみにとどまる。

本研究で提案する手法では、 $h_u$  を、ターゲットユーザからナイーブなランダムウォークを繰り返して得られるスコアと定義する。この考え方は、ターゲットユーザからスタートするランダムウォークが、ユーザの見つけやすさを反映しているという直観に基づく。ただし、調べたいのはターゲットユーザの周辺の領域であるので、一定確率  $a$  でスタート地点へと戻ってくるようにすべきである。これは Random walk with restart [8] として知られる手法である。Random walk with restart を適用しつつ遷移を一定回数繰り返す、最終的なスコアは通過した回数に比例する値として定義する。

提案する手法は、以下のように表現される。これは次節で述べる本研究における三つ目の手法である。時刻  $t$  におけるグラフの表現  $G_t$  に SALSA を適用し、各ユーザのスコアを得る。各ユーザ  $u$  が初めて推薦リストの上位  $k$  件に登場した時刻を  $t_{1,u}$ 、最後に登場した時刻を  $t_{2,u}$  とする。また、Random walk with restart により得られる各ユーザ  $u$  のスコアを  $h_u$  とする。最終的な推薦スコア  $S_u$  は、以下のように与えられる。

$$S_u = \frac{1}{T-t_1} + \frac{1}{T-t_2} + \frac{1}{h_u}$$

## 4 実 験

### 4.1 実験の流れ

データには、代表的な SNS の一つである Twitter のフォローグラフを用いることとする。一定間隔の時刻ごとにグラフを取得し、グラフ  $G_t$  を得る。 $G_t$  はユーザ間の関係を表す重みつきグラフで、あるユーザとそのユーザがフォローしているユーザは、重みが 1 の有向辺で結ばれている。各時刻でのフォローグラフ全体を取得することは時間的観点から難しいため、フォローグラフの一部を取得し、そのサブグラフに対して各手法を適用し評価を行うこととする。本実験では、あるユーザから距離が 2 以内のユーザを取得し、プライベートアカウントを除いた全アカウントをノードにとったグラフをサブグラフに用いた。2021 年 1 月中に取得した 5 時刻のデータのうち、前の 4 回を推薦リ

ストを得るための学習用データとし、最後の 1 回を適合率の計測のためのテストデータとした。

前節で述べた三つの提案手法について、それぞれ以下の手法を適用する。

- 手法 1: グラフの集約.  $G_t$  を以下の式に従って単一のグラフ  $G$  に集約する。

$$G = \alpha G_{T-1} + \alpha(1-\alpha)G_{T-2} + \dots + \alpha(1-\alpha)^{T-2}G_1$$

得られたグラフ  $G$  は、エッジに重みがついた有向グラフである。 $G$  に対して SALSA を適用し、各ユーザの推薦スコアを得る。最終的な推薦リストは、推薦スコアの上位  $k$  件である。

- 手法 2: 推薦リストの集約. 各  $G_t$  に SALSA を適用し、各ユーザのスコアを得る。グラフ  $G_t$  から得られたユーザ  $u$  のスコアを  $S_{t,u}$  とすれば、最終的な  $u$  の推薦スコアは以下の式で表される。

$$S_u = \alpha S_{T-1,u} + \alpha(1-\alpha)S_{T-2,u} + \dots + \alpha(1-\alpha)^{T-2}S_{1,u}$$

- 手法 3: 見つけにくさを加味した推薦リストの集約. 内容は前節で述べた通りである。式  $S_u = \frac{1}{T-t_1} + \frac{1}{T-t_2} + \frac{1}{h_u}$  にしたがって、ユーザごとの推薦スコアを計算する。

推薦リストの件数  $k$ 、グラフや推薦リストの減衰係数  $\alpha$ 、SALSA のランダムジャンプ率  $r$ 、SALSA のランダムウォークのステップ数  $N_s$ 、 $h_u$  の計算の際のランダムウォークにおけるジャンプ率  $a$  およびステップ数  $N_h$  は、ハイパーパラメータとして与える必要がある。今回は、 $k = 100$ 、 $\alpha = a = 0.5$ 、 $r = 0.3$ 、 $N_s = 1000$ 、 $N_h = 100000$  とした。 $h_u$  は前節で述べた通り Random walk with restart によって定義する。より具体的には、ユーザ  $u$  に対して、ランダムウォークで通過した回数に 1 を足した値を  $h_u$  とする。1 を足すのは、 $u$  を通過しなかった場合に  $\frac{1}{h_u}$  が定義不可能になることを回避するためである。

### 4.2 評 価

本研究の実験では、以上の実験により得られた推薦リストに対して、以下の尺度を計算する。

- 適合率. 時刻  $T$  の後に実際にユーザがフォローしたユーザを、推薦リストでどれだけ推薦できていたか。
- Coverage. 推薦システムが各ユーザに一度でも推薦したことのあるユーザの総数。
- Unexpectedness. 推薦システムが提示したユーザのうち、ターゲットユーザが知らなかったユーザの割合。

Unexpectedness に関しては、ターゲットユーザが知らなかったユーザの割合を直接得ることはできない。ここではその推定値として  $h_u$  を用いる。 $h_u$  はターゲットユーザから見た各ユーザ  $u$  の見つけやすさを推定した値であるので、推薦リストのユーザ  $u$  に対する  $\frac{1}{h_u}$  の総和を Unexpectedness として与えることが自然な定義である。

適合率の適切な評価のためには、時刻  $T$  (学習用データの末尾) から  $T+1$  (テストデータ) にかけて新たに一定数以上のユーザをフォローしたユーザに着目する必要がある。一方で、Coverage の評価のためには、出来るだけ近接性の高いユーザ群をターゲッ

トユーザとするべきである。何故なら、Coverage は各ターゲットユーザに対して推薦するユーザのリストにどれだけ重複があるかを表現する値であるが、互いに距離の離れたターゲットユーザ群への推薦リストは元より重複が少ないため、近接性の低いターゲットユーザ群に対して計算された Coverage は指標としての価値が低いからである。これら二つの条件を同時に満たすターゲットユーザ群を見つけることは難しい。そこで、本実験では、適合率を計算するのに適したターゲットユーザ群と、Coverage を計算するのに適したターゲットユーザ群それぞれについて評価する。より具体的には、以下の実験 1, 2 を行うこととする。

- 実験 1. 時刻  $T$  と  $T+1$  の間に、新たに 100 ユーザをフォローしたユーザをターゲットユーザ群とする。新規フォロー数を 100 ユーザと定めているのは、推薦リストの数が  $k = 100$  であることに起因する。ただし、新規に 100 ユーザをフォローしたユーザ自体は数多く存在したので、このうちフォローしているユーザの数が少ないユーザから 10 ユーザ取得し、この 10 ユーザをターゲットユーザ群とした。

- 実験 2. あるユーザから距離 1 だけ離れた位置にいるユーザをランダムで 20 ユーザ取得し、ターゲットユーザ群とした。このユーザ群内のユーザは、時刻  $T$  と  $T+1$  の間に新規に他ユーザをフォローしたとは限らず、仮にフォローしていたとしても数ユーザであるため、適合率の計算には不適切なユーザ群である。一方で、十分な近接性を有したユーザ群であるため、Coverage の評価に適したユーザ群であるといえる。

Unexpectedness については実験 1, 2 の両方で計算し、評価を行う。

## 4.3 実験結果

### 4.3.1 実験 1

新たに 100 ユーザをフォローした 10 ユーザについて、手法 1, 2, 3 それぞれについて推薦リストを得て、適合率および Unexpectedness を計算した。実験結果は表 1 の通りになった。

表 1 実験 1 の結果			
	手法 1	手法 2	手法 3
適合率	10.5	16.2	2.3
Unexpectedness	817.92	736.48	1000.00

### 4.3.2 実験 2

20 ユーザについて、手法 1, 2, 3 それぞれについて推薦リストを得て、Coverage および Unexpectedness を計算した。実験結果は表 2 の通りになった。

表 2 実験 2 の結果			
	手法 1	手法 2	手法 3
Coverage	1753	1827	1995
Unexpectedness	1741.35	1152.53	2000.00

## 4.4 考察

表 1 の通り、手法 2 による推薦は手法 1 と比較して高い適合率が算出された。一方で、実験 1 および実験 2 の両方において、Unexpectedness は手法 1 と比較して低い値となった。手法 2 による推薦は、既存手法と比べて高い精度を獲得できるものの、意外性に欠けた推薦になることが明らかになった。

手法 3 による推薦は、手法 1 および手法 2 と比較して、かなり低い適合率が算出された。しかし、Coverage および Unexpectedness については他の 2 手法を凌駕している。二つの実験における Unexpectedness の値を見るに、手法 3 における推薦リスト中のユーザは、全て  $h_u$  が 1、すなわち Random walk with restart で 1 回も通過しなかったユーザとなっていることがわかる。 $h_u$  が、ターゲットユーザがどれだけ他のユーザのことを知っているかを表現する値であると仮定すれば、手法 3 による推薦はターゲットユーザにとって未知のユーザを推薦する手法であると考えられる。

節 3 で述べた通り、適合率が高ければ高いほどその推薦が優秀であるとは限らない。また、Coverage や Unexpectedness の高さが推薦全体としての性能の高さにある程度関与していることは事実であるが、これらの指標が高ければ高いほど推薦が優秀なものであるとも断定できない。というのも、全ユーザからランダムに  $k$  ユーザを取得して推薦するシステムにおいては、Coverage や Unexpectedness は必然的に高い値になるからである。手法 1 と比較して、手法 2 は適合率が、手法 3 は Coverage や Unexpectedness が優れた値になったものの、これらの事実によって推薦の性能が向上したと断定するのは早計である。

各手法が保持しなければならないデータ量については、手法 2 および 3 が手法 1 に比べて優れているといえる。既存手法である手法 1 では、各時刻におけるグラフを恒常的に保持していなければならない。これは、Twitter などのノード数が大きいネットワークにおいては難しいことである。一方、手法 2 および 3 では、各ユーザに紐づいた推薦リストを保持するだけでよい。保持すべきデータ量が少なくなるという点では、手法 2 および 3 は手法 1 に比べて優れている。

## 5 おわりに

本研究では、SNS における時間情報を用いたユーザ推薦の手法を提案した。既存手法および二つの提案手法について二つの実験を行い、適合率、Coverage、Unexpectedness を算出した。実験の結果、提案した手法はそれぞれ、適合率および Coverage と Unexpectedness の向上をもたらすことが明らかになった。

今後の課題をいくつか挙げる。まず、本研究の実験で用いたグラフの時系列データは、1ヶ月内で収集したものである。より長期間の時系列において提案手法が三つの指標の向上をもたらすかどうかは未知数である。今後は、時系列の時刻の幅をより大きくして同様の実験を行うこととする。

手法 2 における適合率、および手法 3 における Coverage、Unexpectedness がなぜ既存手法と比較して大きい値となったかについても不明である。性能の向上をもたらす理由が明らか

になっていない以上, 今回の実験で偶然このような結果が得られただけである可能性や, 性能の向上が手法の差以外の側面に起因しているといった可能性を否定できない. 今後は, 実験におけるハイパーパラメータを変化させて, 指標の向上が何に起因しているかについて探っていくことを試みる.

## 6 謝 辞

本研究は, JST CREST (JPMJCR16E3), JSPS 科研費 18H03245 の支援を受けたものである.

## 文 献

- [1] P. Gupta, A. Goel, J. Lin, A. Sharma, D. Wang, and R. Zadeh, Wtf: the who to follow service at twitter, Proceedings of the 22nd international conference on World Wide Web (WWW '13), pages 505–514, 2013.
- [2] R. Lempel and S. Moran, The Stochastic Approach for Link-Structure Analysis (SALSA) and the TKC Effect, Proceedings of the Ninth International World Wide Web Conference (WWW9), pages 387–401, 2000.
- [3] Jon M. Kleinberg, Authoritative sources in a hyperlinked environment, Proceedings of the 9th ACMSIAM Symposium on Discrete Algorithms, pages 668– 677, 1998.
- [4] M.J. Pazzani and D. Billsus, Content-based recommendation systems, The Adaptive Web, pages 325–341, 2007.
- [5] P. R. D. S. Soares and R. B. C. Prudencio, Time series based link prediction, Proc. Int. Joint Conf. Neural Netw., pages. 1–7, 2012.
- [6] P. Adamopoulos , A. Tuzhilin , On unexpectedness in recommender systems: or how to expect the unexpected, Workshop on Novelty and Diversity in Recommender Systems, at the 5th ACM International Conference on Recommender Systems, pages. 11–18, 2011.
- [7] D. Fleder and K. Hosanagar, Blockbuster culture ’ s next rise or fall: The impact of recommender systems on sales diversity. Manage. Science, 55(5), pages. 697–712, 2009.
- [8] H. Tong, C. Faloutsos, and J. Pan, Fast random walk with restart and its applications, ICDM, pages 613–622, 2006.