

# 災害時における行動促進ツイートの有益度を算出する手法の提案

熊本 忠彦<sup>†</sup>

<sup>†</sup> 千葉工業大学 情報科学部 情報ネットワーク学科 〒275-0016 千葉県習志野市津田沼 2-17-1

E-mail: [†kumamoto@net.it-chiba.ac.jp](mailto:†kumamoto@net.it-chiba.ac.jp)

あらまし 深刻な災害が発生したとき、災害に関する様々な情報が発信され、SNS（特に Twitter）上を流通する。中でも、人々に行動すること（あるいは行動しないこと）を促すような情報は行動促進情報と呼ばれており、多くの人々に影響をもたらすことが知られている。しかしながら、その流通量は莫大なうえ、不特定多数の人々によって発信された情報は有益な情報ばかりとは限らない。そこで本稿では、Twitter を対象に、地震災害時における行動促進ツイート（行動促進情報を含むツイート）の有益度を「3（とても有益）、2（多少有益）、1（あまり有益でない）、0（全く有益でない）」という4段階スケールに準じた実数として算出する手法を提案する。すなわち、この提案手法を用いれば、行動促進ツイートの有益度を定量的に扱えるようになり、ランキング表示といったことも可能になる。なお、地震災害時に実際に発信された行動促進ツイートをを用いた性能評価実験によれば、学習データ（ツイート 1,400 件）に対する誤差（RMSE: Root-Mean-Square Error）は 0.432 であり、未知データに対する誤差（5 分割交差検定による平均 RMSE）は 0.497 であった。これにより、未知データに対しても 0.5 以内の誤差に収まりうることを示された。

キーワード 地震、行動促進情報、Twitter、相関分析、回帰分析

## 1 はじめに

災害大国である日本では、毎年のように、地震や台風、豪雨といった様々な災害が発生している。このような災害時、Twitter [1] には災害に関する様々な情報が時々刻々と投稿されており、うまく活用すれば即時性・地域性の高い情報収集を実現できることが確認されているが、その一方で膨大な数のツイートの中から災害に対して有益な情報を抽出するのは容易でないという問題も生じている [2]。

一方、災害時には、見た人に行動すること（あるいは逆に行動しないこと）を促すような情報を含むツイート（行動促進ツイート [3] [4] [5] [6] [7] と呼ぶ）が数多く投稿されることが知られており [8]、人々に有益な情報をもたらすという側面がある一方で、あまり有益でない情報や不利益を生じさせるような情報が含まれていることも多い。特に災害時のユーザは、平常時よりこのような行動促進情報を信じやすくなるため、行動促進ツイートの有益度を定量的に示すことで情報の取捨選択を支援する必要がある。

そこで本稿では、地震災害時における行動促進ツイートを対象に、ツイートの有益度を算出する手法を設計し、提案する。具体的には、以下の手順で提案手法を設計する。(1) 災害の種類を表す言葉（今回は「地震」）を含むツイートを収集し、行動促進ツイートと思うか否かを 5 人の作業者に判定してもらう [5] [6]。(2) この判定結果に基づいて行動促進ツイートを決定し、抽出する。(3) それぞれの行動促進ツイートに対し、災害時に有益な情報が含まれているか否かを「とても有益 (3 点)、多少有益 (2 点)、あまり有益でない (1 点)、全く有益でない (0 点)」の 4 段階で 10 人の作業者に判定してもらう。(4) この

判定結果から平均値を求め、当該ツイートの有益度とする。(5) すべての行動促進ツイートをベクトル化し、ツイートベクトルを生成する。すなわち、すべての行動促進ツイートから抽出された特徴量の異なり形を構成要素、当該特徴量のツイート内における出現頻度をその構成要素の値とするベクトルをツイートごとに生成する。なお、本稿では、活用形に関する情報の有効性を調べるために、原形、品詞名、品詞細分類名、活用形名から成るタイプ A の特徴量と活用形名を除いたタイプ B の特徴量の 2 種類を導入し、検証する。(6) ツイートベクトルの構成要素である各特徴量のツイートごとの出現頻度と各ツイートの有益度との間で相関分析を行うことで、相関係数を求め、その特徴量の重みとする。このとき、出現頻度 0 の要素も含めて相関係数を求める場合と出現頻度 0 の要素を除外して相関係数を求める場合の 2 通りについても検証する。(7) それぞれの行動促進ツイートから特徴量を抽出し、抽出された特徴量の重みの和をそのツイートの算出値とする。(8) この算出値を説明変数、有益度を目的変数とする回帰分析を行い、ツイートの算出値を有益度に変換するための式（回帰式）を得る。このとき、回帰モデルとしては直線、2 次関数、3 次関数、4 次関数、5 次関数の 5 種類を検証する。

ここで、本稿の以下の構成について述べる。まず、2 章で関連研究について述べ、関連研究との関係性を明らかにすることで提案手法の新規性を示す。3 章で地震災害時に発信された行動促進ツイートの収集と有益度の取得について述べる。4 章で行動促進ツイートの有益度算出手法を設計し、提案する。5 章で提案手法の性能評価を行い、学習データだけでなく未知データに対しても有効であることを示す。最後に、6 章で本稿のまとめと今後の課題について述べる。

## 2 関連研究

災害時における行動促進ツイートから有益度等の情報を抽出しようという研究は見当たらない。そこで本稿では、関連研究として、災害時における行動促進ツイートの抽出に関する研究やツイートからの情報抽出に関する研究、ツイートの信憑性に関する研究を取り上げ、提案手法との関係性を明らかにすることで提案手法の新規性を示す。

### 2.1 災害時における行動促進ツイートの抽出

災害時に発信されたツイートから行動促進ツイートを抽出しようという研究 [5] [6] [7] がある。例えば、見塚らは、2018 年 9 月に発生した北海道胆振東部地震 [9] の際に発信されたツイートを対象に、ルールベースの手法、SVM (Support Vector Machine) ベースの手法、LSTM (Long Short-Term Memory) ベースの手法の 3 つを提案し、比較することで、LSTM ベースの手法が地震災害時の行動促進ツイート抽出に最も適していることを示した [5]。一方、米田らは、この LSTM ベースの手法を地震 (2018 年 9 月の北海道胆振東部地震) に加え、大雨 (2018 年 7 月の西日本豪雨 [10]) や台風 (2018 年の台風。但し、台風 21 号から 25 号を除く)、熱中症にも適用してみて、いずれの場合でも LSTM ベースの手法が最も適していることを示した [6]。さらに、米田らは、2019 年の台風 15 号 [11] を対象に BERT (Bidirectional Encoder Representations from Transformers) ベースの手法を提案し、LSTM ベースの手法より高精度な結果が得られることを示している [7]。このとき、LSTM ベースの手法では 0.9064 (適合率 0.9418, 再現率 0.8734) であった F 値が BERT ベースの手法では 0.9372 (適合率 0.9305, 再現率 0.9440) まで向上しており、十分実用的な精度が実現されているものと考えられる。

著者らの提案手法では、災害に関する行動促進ツイートを高精度に抽出できることが前提となっている。米田らの手法 [7] は台風を対象にその有効性が検証されているが、文献 [6] に示された結果より台風以外の災害に対しても十分高い精度であることが期待できる。こういった手法を提案手法に導入することで、災害に関する行動促進ツイートを抽出し、その有益度を可視化するリアルタイムサービスを実現できるものと考えている。

### 2.2 災害時におけるツイートからの情報抽出

災害時に発信されたツイートから様々な情報を抽出しようという研究がある [12] [13]。例えば、Ashktorab らは、地震、ハリケーン、津波、竜巻といった様々な災害を対象に、ツイートからインフラ被害や死傷者に関する情報を抽出するシステム Tweedr を提案している [12]。北島らは、東日本大震災 [14] のときのツイートを対象に、具体的な地名や建物名など避難情報として活用可能な情報を含んでいるか否かを判定する手法を提案している [13]。

Ashktorab らの手法 [12] が抽出する情報は災害救助者向けの情報であり、北島らの手法 [13] が抽出する情報は避難準備者向けの情報と言える。そのため、いずれの手法でも具体的な情報

の抽出に焦点が当てられており、その情報を参考にすべきか否かの判断はユーザに任されている。

これらの手法に対し、著者らの提案手法は、抽出された行動促進ツイートがどのくらい有益かを定量的に示すことで、ユーザによる情報の取捨選択を支援するための枠組みである点が異なっている。

### 2.3 ツイートの信憑性

ツイートの信憑性に関する研究 [15] [16] [17] [18] がある。例えば、藤本らは、道路管理の役に立つ交通現象に関するツイート取得を目的としているが、このようなツイートに対しては他のユーザの反応が乏しいことから、リツイートや返信といった他のユーザの反応を利用した従来の信憑性評価手法 [19] [20] を適用するのは難しいと考え、過去の投稿傾向から分析できる習慣行動などを用いてツイート投稿者の信頼性を分析する手法を提案している [15] [16]。一方、宮部らは、東日本大震災が起きた直後に発信されたツイートを対象に、どのような流言 (情報の真偽を疑問視されたツイート) が深刻な影響を与えるかを有害性と有用性という観点で分析するとともに [17]、他のユーザによって発信された訂正情報に着目し、訂正情報に基づいて流言に関する情報を収集・提供するサービスを構築している [18]。

本研究では、災害時における行動促進ツイートの有益度を定量化しているが、有益度の高いツイートの中にもデマ情報を含むツイートが含まれている可能性がある。そこで、上述した手法などによりツイート内容あるいはツイート投稿者の信憑性を考慮しつつ、提案手法により行動促進ツイートの有益度を定量的に示すことで、情報の取捨選択をより効果的に支援することが可能になると考えられる。

## 3 行動促進ツイートの収集と有益度の取得

本章では、本研究に資する地震災害時における行動促進ツイートの収集とその有益度評価について述べる。

### 3.1 地震災害時における行動促進ツイートの収集

本稿では、見塚らが収集したツイートの一部 [5] を地震災害時における行動促進ツイートとして用いることにする。

文献 [5] によれば、見塚らは、2018 年 9 月 6 日に発生した北海道胆振東部地震 [9] の際に「地震」という語を含むツイートをランダムに 10,000 件収集した後、クラウドソーシング [21] によりそれぞれのツイートに行動促進情報が含まれているか否かを 5 人の作業者に判定してもらっている。このとき、見塚らは 5 人中 3 人以上が行動促進情報を含むと認定したツイートを行動促進ツイートと定義したが、本稿では確実性をより高めるために 5 人中 4 人以上が行動促進情報を含むと認定したツイートを行動促進ツイートとすることにした。結果、ツイート 10,000 件の中から 5 人が認定した 556 件と 4 人が認定した 924 件の計 1,480 件が行動促進ツイートとして抽出された。

### 3.2 行動促進ツイートの有益度評価

前節で抽出された行動促進ツイート 1,480 件からランダムに

表 1 有益度の高かったツイートと低かったツイートの例 (Twitter [1] 上で収集)

有益度	ツイート
2.8	【東北地方太平洋沖地震を経験して備えていた方が良かったもの】乾電池／乾電池式携帯充電器／懐中電灯／ラジオ／ホッカイロ／非常食／水／カセットコンロ／カセットコンロ用ガス／本／ボディシート／化粧落としシート／排泄が出来る丈夫な袋／現金／消毒薬／薬類／毛布／マスク／長靴
2.8	北海道にいる皆さんへこのあと 15 時頃から断水するそうです。今のうちに、あらゆる容器にお水を溜めておいてください！空きのあるペットボトル、ビン、魔法瓶、加湿器のタンクなど#北海道#地震
2.8	北海道でまだ、断水していない地域にお住まいの方、余震、断水に備えて、極力水を確保されて下さい！お風呂に水を溜めればトイレを流すのにも使えます！汚れを落とすにも使えます。熊本地震の時、私が住んでいた益城の場所では一ヶ月程断水しました。水はあるに越したことないです！！
0.1	ありがとうございます台風も地震も恐いですねもう何が起ころかわからないですね。気を付けましょう。
0.1	地震にも負けずにカレメシ！どうか余震にはお気をつけ下さい……！
0.0	「アースクエイク」は、文字通り「地震」という意味のカクテルだ。アルコール度数が 50 度近くあって、体が震えるほどキツいことからこの名前がついたらしい。僕たち日本人にとっては、しばらくはあまり出くわしたくないカクテルかもね。飲むときは気をつけよう。ポッ

1,400 件を抽出し、それぞれのツイートに含まれている行動促進情報が地震災害時にどの程度有益かをクラウドソーシング [21] により 10 人の作業者に判定してもらった。このとき、「とても有益 (3 点)、多少有益 (2 点)、あまり有益でない (1 点)、全く有益でない (0 点)」の 4 段階で判定してもらい、その平均値を各ツイートの有益度とした。

ここで、表 1 に有益度が高かったツイートと低かったツイートをそれぞれ 3 つずつ示す。表 1 に示したように、有益度が高いツイートには地震災害に関連する情報を含むものが多かったのに対し、有益度が低いツイートには無関係な内容のものが多かった。また、この表には示されていないが、○○ちゃんや□□さんなど特定個人へのメッセージと見られるツイートも多く観測された。

## 4 行動促進ツイートに対する有益度算出手法の提案

### 4.1 行動促進ツイートのベクトル化

本稿では、行動促進ツイートを定量化し、ベクトルとして表すことを考える。そこで本節では、ベクトルの構成要素を検討するとともに、行動促進ツイートからベクトルを生成するための手法を設計する。

まず、行動促進ツイートから抽出される特徴量として、ツイートを構成する各形態素の原形、品詞名、品詞細分類名、活用形名から成るタイプ A の特徴量と原形、品詞名、品詞細分類名の 3 つから成るタイプ B の特徴量の 2 種類を導入し、活用形に関する情報の有無が有益度の算出にどのような影響を及ぼすかを検証することにした。

次に、3.1 節で得た行動促進ツイート 1,400 件を汎用の日本語形態素解析システムである JUMAN [22] を用いて形態素解析することで、各ツイートを形態素に分解し、原形、品詞、品詞細分類、活用形に関する情報を付与した。このとき、各形態素を「原形-品詞名-品詞細分類名-活用形名」という形でシンボル化したタイプ A の特徴量と活用形名を除いて「原形-品詞名-品詞細分類名」という形でシンボル化したタイプ B の特徴量を定義し、各ツイートから抽出した。

表 2 相関係数の分布 (タイプ A, ZERO データありの場合)

相関係数 $r$	特徴量数	内訳 (品詞別特徴量数)	割合
$0.3 \leq r < 0.4$	6	名詞 4, 特殊 2	0.1%
$0.2 \leq r < 0.3$	14	名詞 5, 形容詞 3, 動詞 2, 助詞 2, 接頭辞 1, 接尾辞 1	0.2%
$0.1 \leq r < 0.2$	69	名詞 39, 形容詞 2, 動詞 8, 助詞 4, 接尾辞 11, 特殊 5	1.1%
$0.0 \leq r < 0.1$	3,126		50.5%
$-0.1 \leq r < 0.0$	2,953		47.7%
$-0.2 \leq r < -0.1$	20	名詞 4, 形容詞 1, 動詞 5, 感動詞 3, 助詞 1, 接頭辞 1, 接尾辞 2, 特殊 3	0.3%
$-0.3 \leq r < -0.2$	2	動詞 1, 助詞 1	0.0%
$-0.4 \leq r < -0.3$	1	名詞 1	0.0%
計	6,191		100%

次に、この方法により抽出された特徴量の異なり形をタイプごとに調べ、各ツイートから生成されるツイートベクトルの構成要素とした。結果、タイプ A では 6,191 個の特徴量が抽出され、タイプ B では 4,992 個の特徴量が抽出されたので、ツイートベクトルの構成要素数はタイプ A で 6,191 次元、タイプ B で 4,992 次元となった。但し、この構成要素数は、未定義語以外の全品詞 (名詞、形容詞、動詞、副詞、感動詞、助詞、助動詞、判定詞、接頭辞、接尾辞、指示詞、接続詞、連体詞、特殊) を対象にした場合の数であり、対象とする品詞の種類や数によって変わる。なお、未定義語には半角の英数字や記号が多く観測されるため、本稿では対象外とした。

最後に、ツイートから抽出される各特徴量の出現頻度をツイートごとに数え、対応する構成要素の値とした。結果、行動促進ツイートに出現しうる特徴量を構成要素、当該特徴量のツイート内における出現頻度をその構成要素の値とするベクトル (本稿ではツイートベクトルと呼ぶ) をツイートごとに生成することができるようになった。

### 4.2 ツイートベクトルを構成する特徴量の特性分析

本節では、ツイートベクトルの構成要素となる特徴量とツイートの有益度の関係を相関分析により調べ、各特徴量の特性

表 3 相関係数の分布 (タイプ A, ZERO データなしの場合)

相関係数 $r$	特徴量数	割合
$r = 1$	41	0.7%
$0.7 \leq r < 1$	20	0.3%
$0.4 \leq r < 0.7$	64	1.0%
$0.1 \leq r < 0.4$	220	3.6%
$-0.1 < r < 0.1$	187	3.0%
$-0.4 < r \leq -0.1$	150	2.4%
$-0.7 < r \leq -0.4$	41	0.7%
$-1 < r \leq -0.7$	29	0.5%
$r = -1$	30	0.5%
計算不可	5,409	87.4%
計	6,191	100%

を明らかにすることで、有益度の算出に有効な特徴量について検討する。

まず、ツイートベクトルの構成要素である各特徴量のツイートごとの出現頻度と 3.2 節において求められた各ツイートの有益度との間で相関分析を行い、相関係数を求めた。結果を表 2 にまとめる。但し、表 2 には相関係数の分布状況として該当する相関係数であったタイプ A の特徴量の種類数とその内訳 (品詞別の特徴量の種類数) および特徴量全体に占める割合 (%) が示されている。

表 2 によれば、タイプ A の特徴量では、すべての特徴量 (全部で 6,191 種類) の 98.2% にあたる 6,079 種類において相関係数が  $-0.10 \sim 0.10$  の間であり、有益度の算出にはあまり有効でないように見える。しかしながら、各特徴量のツイート内における出現頻度は、その 99.4% ( $= 8,614,977 / (6,191 \times 1,400) \times 100$ ) が 0 であり、1 以上の値を有しているデータは 0.6% に過ぎないため、相関係数が小さくなる傾向にあると言える。そこで、相関分析を行う際に出現頻度 0 のツイートを除外して相関係数を求めてみたところ、表 3 のような結果が得られた。

表 3 によれば、相関係数の絶対値が 0.7 以上となる特徴量が 120 種類 (全体の 1.9%) 存在している一方で、全特徴量の 87.4% にあたる 5,409 種類の特徴量において相関係数を求めることができなかったことがわかる。これは、全体の 99.4% にあたる 0 を除外したため、相関係数を計算する際のデータ数が極端に少なくなり、相関係数の絶対値が大きい特徴量や逆に計算不可になる (標準偏差が 0 になる) 特徴量が現れたものと考えられる。

以上のことを鑑みて、本稿では、各特徴量における相関係数の大きさについては、制限を設けず、すべての特徴量を用いることにするとともに、出現頻度 0 のツイートも含めて相関係数を求める場合 (ZERO データあり) と出現頻度 0 のツイートを除外して相関係数を求める場合 (ZERO データなし) の 2 通りについて検証してみることにする。

一方、表 2 の品詞別特徴量数を見てみると、相関係数が 0.10 以上もしくは  $-0.10$  未満である特徴量 (全部で 112 種類) には、名詞、形容詞、動詞、感動詞といった内容語が多く、全体の 69.6% を占めているけれども、助詞、接頭辞、接尾辞、特殊といった機能語も 30.4% と少なくない数が存在しているのがわ

表 4 相関係数の絶対値が比較的大きい特徴量 (タイプ A)

相関係数	出現頻度	特徴量 (タイプ A)
0.35	280	震度-名詞-普通名詞-なし
0.32	208	【-特殊-括弧始-なし
0.32	208	】-特殊-括弧終-なし
0.32	1,937	地震-名詞-普通名詞-なし
0.31	301	注意-名詞-サ変名詞-なし
0.30	387	情報-名詞-普通名詞-なし
0.29	153	速報-名詞-サ変名詞-なし
0.28	80	最大だ-形容詞-なし-語幹
0.27	1,730	が-助詞-格助詞-なし
0.27	170	場合-名詞-副詞の名詞-なし
0.26	65	報-名詞-普通名詞-なし
0.26	62	深い-形容詞-なし-語幹
0.24	78	強い-形容詞-なし-基本形
0.23	137	県-接尾辞-名詞性特殊接尾辞-なし
0.23	1,901	に-助詞-格助詞-なし
0.22	673	する-動詞-なし-タ系連用テ形
0.21	168	発生-名詞-サ変名詞-なし
0.21	77	第-接頭辞-名詞接頭辞-なし
0.20	123	津波-名詞-普通名詞-なし
0.20	112	揺れる-動詞-なし-基本連用形
-0.20	160	つける-動詞-なし-タ系連用テ形
-0.24	282	ね-助詞-終助詞-なし
-0.33	345	気-名詞-普通名詞-なし

かる。そこで本稿では、全品詞を特徴量として用いる場合と内容語のみを特徴量として用いる場合の 2 通りを検討してみることにする。なお、感動詞は通常内容語として扱われないが、「おはよう」や「こんにちは」、「ありがとう」や「おめでとう」など単体で用いられる感動詞もあることから、本稿では内容語として扱うことにする。

ここで、相関係数の絶対値が 0.20 以上であるタイプ A の特徴量 (全部で 23 種類) を表 4 にまとめ、それぞれの特徴量の元となった形態素がツイートにおいてどのように用いられているかを調べてみた。結果、以下のようなことが分かった。

まず、相関係数が 0.20 以上である特徴量のうち、「震度」や「地震」、「注意」、「情報」、「速報」、「発生」、「津波」、「最大」、「深さ (形容詞「深い」の語幹 + 接尾辞「さ）」、「強い」、「揺れ (動詞「揺れる」の基本連用形)」といった語は、地震災害に関連する語であり、地震が発生した際の情報提供や注意喚起を行う際に用いられていた。また、こういった語が用いられているツイートでは「第 5 報」のような文言が付加されていることも多く、結果、接頭辞「第」や名詞「報」も比較的多く観測された。同様に、格助詞の「が」や「に」は、「地震がありました」や「揺れが強い地震」あるいは「地震による強い揺れ」や「情報に注意」のように、地震災害に関連する語とともに用いられていることが多かった。一方、「して (動詞「する」のタ系連用テ形)」は、サ変名詞の後に続く形で用いられることが多いが、今回用いた行動促進ツイートでは「注意して (147 件)」や「確認して (30 件)」、「行動して (29 件)」のような用いられ方をしていた。「場合」は、「揺れが強い場合は」や「手足を挟

表 5 学習データに対する自由度修正済み決定係数 (1)

(a) 全品詞, ZERO データありの場合

特微量 タイプ	回帰モデル				
	直線	2 次関数	3 次関数	4 次関数	5 次関数
A	0.512	0.585	0.595	0.600	0.600
B	0.510	0.568	0.578	0.582	0.581

(b) 全品詞, ZERO データなしの場合

特微量 タイプ	回帰モデル				
	直線	2 次関数	3 次関数	4 次関数	5 次関数
A	0.231	0.230	0.247	0.249	0.256
B	0.227	0.227	0.241	0.243	0.247

まれた場合」,「コンロを使用している場合は」など行動を促す際の条件を示すために用いられていることが多かった。特殊の「【】と「」」は,「【地震情報】」や「【通電火災防止に向けて】」のように,ツイートの冒頭部分においてタイトル風に用いられている事例が多く見受けられた。接尾辞の「県」は震源地や各地の震度を示す際に県名を示すために用いられていた。

反面,相関係数が  $-0.20$  以下の特微量のうち,「気」と「つけて (動詞「つける」のタ系連用テ形)」は,「気をつけてください」というフレーズ,すなわち他者を慮ってはいるけれども有益な行動促進情報を含まないフレーズから抽出されており,有益度の低いツイートでは比較的多く観測された。また,助詞の「ね」は,同意を求める場合や何かを確認する際に文末で用いられる終助詞 [23] であり,「気をつけてください」との組み合わせで「気をつけてくださいね」という用いられ方をしていたのに加え,「何が起こるかわからないですね」や「怖いですね」のように同意を求めるために用いられている事例が多かった。いずれにせよ,このような用法で終助詞の「ね」が用いられているときは,有益な行動促進情報が含まれていないことが多いと言える。

#### 4.3 有益度算出手法の設計方針

本節では,行動促進ツイートの有益度を算出する手法の設計方針について述べる。

まず,4.2 節と同様に,ツイートベクトルの構成要素である各特微量のツイートごとの出現頻度と 3.2 節において求められた各ツイートの有益度との間で相関分析を行い,相関係数を求めた。このとき,出現頻度 0 のツイートも含めて相関係数を求める場合 (ZERO データあり) と出現頻度 0 のツイートを除外して相関係数を求める場合 (ZERO データなし) の 2 通りについて求めてみた。結果は,すでに表 2 と表 3 に示してあるとおりである。

さて,本稿では,各特微量のツイートごとの出現頻度と有益度との相関係数をその特微量の重みと捉え,それぞれの行動促進ツイートから抽出される特微量の重みの和をそのツイートの算出値とすることを考える。しかしながら,この算出値は,有益度に設定した「3 (とても有益), 2 (多少有益), 1 (あまり有益でない), 0 (全く有益でない)」という 4 段階スケールに準ずるものではないので,算出値を説明変数,有益度を目的変数とする回帰分析を行うことで,この 4 段階スケールに合わせ

表 6 学習データに対する自由度修正済み決定係数 (2)

(a) 内容語, ZERO データありの場合

特微量 タイプ	回帰モデル				
	直線	2 次関数	3 次関数	4 次関数	5 次関数
A	0.462	0.607	0.607	0.633	0.642
B	0.466	0.582	0.582	0.609	0.614

ることにする。したがって,この回帰分析の結果得られる回帰式を用いれば,ツイートから抽出される特微量の重みの和を有益度に変換することが可能になる。

#### 4.4 回帰分析によるスケール調整

本節では,3.1 節で得たツイートを対象に,前節で設計した手法による算出値を説明変数,3.2 節で求めた有益度を目的変数とする回帰分析を行う。但し,特微量のタイプとしては活用形名を含むタイプ A と活用形名を含まないタイプ B の 2 種類を,回帰モデルとしては直線,2 次関数,3 次関数,4 次関数,5 次関数の 5 種類を採用し,すべての組み合わせを検証する。

まず,未定義語以外の全品詞 (名詞,形容詞,動詞,副詞,感動詞,助詞,助動詞,判定詞,接頭辞,接尾辞,指示詞,接続詞,連体詞,特殊) から特微量を抽出する場合を対象に,ZERO データありの場合と ZERO データなしの場合のそれぞれにおいて回帰分析を行った。このときの自由度修正済み決定係数を表 5 にまとめる。なお,自由度修正済み決定係数は,得られた回帰式が学習データ (全ツイート 1,400 件) にどのくらい当てはまっているかを見るための指標であり,概ね 0.5 以上であれば,良好な結果とされているので,本稿では,この指標を用いて回帰分析の結果を評価する。

表 5 によれば,ZERO データありの場合には,すべての組み合わせにおいて自由度修正済み決定係数が 0.5 以上となっているのに対して,ZERO データなしの場合には,すべての組み合わせにおいて 0.3 より小さく,大きな差があることがわかる。よって,本稿では,相関係数を求める際に出現頻度 0 のデータを削除せずそのまま用いることにする。

次に,ツイートから抽出する特微量の品詞について検討する。未定義語以外の全品詞を対象にしたときの自由度修正済み決定係数は表 5 の (a) に示したとおりなので,ここでは内容語 (名詞,形容詞,動詞,副詞,感動詞) から構成される特微量の重みを用いて回帰分析を行い,自由度修正済み決定係数を求めた。結果を表 6 にまとめる。

表 5 の (a) と表 6 を比べてみると,自由度修正済み決定係数は,回帰モデルが「直線」のときのみ全品詞を対象にした方が大きい,他の回帰モデルでは内容語を対象にした方が大きかった。特に,タイプ A の特微量を用いた場合は,回帰モデルとして「4 次関数」を用いた場合で 5.4%,「5 次関数」を用いた場合で 7.0%,自由度修正済み決定係数が改善している。よって,本稿では,ツイートから抽出する特微量の品詞として内容語 (名詞,形容詞,動詞,副詞,感動詞) のみを対象とし,機能語 (助詞,助動詞,判定詞,接頭辞,接尾辞,指示詞,接続詞,連体詞,特殊) を除外することにする。

表 7 形容詞「最大だ」「深い」「強い」および動詞「つける」に対する  
タイプ A とタイプ B の相関係数

(a) タイプ A の場合の相関係数		
特徴量 (タイプ A)	相関係数	抽出数
最大だ-形容詞-なし-語幹	0.28	80
最大だ-形容詞-なし-ダ列タ系連用テ形	0.03	2
最大だ-形容詞-なし-ダ列特殊連体形	0.02	2
深い-形容詞-なし-語幹	0.26	62
強い-形容詞-なし-基本形	0.24	78
強い-形容詞-なし-タ形	0.10	16
強い-形容詞-なし-語幹	0.02	1
強い-形容詞-なし-基本連用形	-0.01	6
つける-動詞-なし-未然形	0.05	1
つける-動詞-なし-基本形	0.02	2
つける-動詞-なし-タ形	-0.03	4
つける-動詞-なし-意志形	-0.06	3
つける-動詞-なし-基本連用形	-0.15	72
つける-動詞-なし-タ系連用テ形	-0.20	160

(b) タイプ B の場合の相関係数		
特徴量 (タイプ B)	相関係数	抽出数
最大だ-形容詞-なし	0.28	84
深い-形容詞-なし	0.26	62
強い-形容詞-なし	0.25	101
つける-動詞-なし	-0.26	242




図 1 回帰分析の様子 (タイプ A の特徴量, 5 次関数の場合)

次に, ツイートから抽出する特徴量に活用形名が含まれる場合 (タイプ A) と含まれない場合 (タイプ B) について検討する. 具体的には, 表 6 に示したタイプ A とタイプ B の自由度修正済み決定係数を比べてみる. すると, 「直線」以外の回帰モデルではタイプ A の自由度修正済み決定係数の方が大きく, 0.6 を超えているのがわかる. そもそも活用形名の有無が問題となる品詞は, 内容語では動詞と形容詞のみなので, この 2 種類の品詞において活用形名の有無が相関係数にどのような影響を与えているのかを調べてみた. 表 4 に示された動詞・形容詞のうち, 正の相関係数が大きかった「最大だ」「深い」「強い」と負の相関係数が大きかった「つける」を例に, それぞれの形態素に関連して抽出されるすべての特徴量とその相関係数を表 7 に示す. 但し, 表 7(a) はタイプ A の場合の相関係数を示し,

表 8 回帰モデル別の回帰式 (タイプ A の特徴量)

回帰モデル	回帰式 ( $x$ : ツイートの算出値 (特徴量の重みの和))
直線	$0.230357x + 1.182093$
2 次関数	$-0.042489x^2 + 0.496842x + 1.077504$
3 次関数	$0.001032x^3 - 0.053143x^2 + 0.516139x + 1.081060$
4 次関数	$0.002021x^4 - 0.028722x^3 + 0.059177x^2 + 0.464957x + 1.008049$
5 次関数	$-0.000444x^5 + 0.010086x^4 - 0.071673x^3 + 0.112039x^2 + 0.520361x + 0.967399$
(提案手法)	但し, 小数点以下第 7 位を四捨五入して表示した

表 9 学習データに対する特徴量タイプ別・回帰モデル別の RMSE

特徴量 タイプ	回帰モデル				
	直線	2 次関数	3 次関数	4 次関数	5 次関数
A	0.531	0.454	0.453	0.438	0.432
B	0.529	0.468	0.468	0.452	0.449

表 7(b) はタイプ B の場合の相関係数を示している.

表 7 によれば, 「最大だ」の語幹や「深い」の語幹のように抽出数が偏っている場合, その活用形 (この例では語幹) を含むタイプ A の特徴量の相関係数と活用形を考慮しないタイプ B の特徴量の相関係数はほぼ同じになるが, それ以外の活用形を含むタイプ A の特徴量の相関係数とは乖離しているのがわかる. また, 「強い」の語幹と基本連用形や「つける」の基本連用形とタ系連用テ形のように抽出数が二極化して偏っている場合も, その二極間の相関係数にはある程度の差が見られるし, それ以外の活用形に対してはタイプ A とタイプ B で小さくない差があることがわかる. よって, 現時点では, タイプ A の特徴量の方が有効と考えつつも, 両方の特徴量を用いて性能評価を行ってみることにする.

最後に, 今回検証したすべての組み合わせの中で自由度修正済み決定係数が最も大きかった組み合わせ (内容語, ZERO データあり, タイプ A の特徴量, 5 次関数) における回帰分析の様子を図 1 に示すとともに, そのときの回帰式を表 8 にまとめる. なお, 図 1 では青のプロットがツイートに対応しており, 赤の実線が回帰式 (5 次関数) を表している. また, 表 8 には, 参考として, 他の回帰モデルを用いた場合の回帰式も掲載している.

## 5 性能評価

### 5.1 学習データに対する精度評価

本節では, 学習データに対する精度を評価する.

まず, 3.1 節で得た行動促進ツイート (全ツイート 1,400 件) と 3.2 節で求めた有益度 (全ツイート 1,400 件分) を学習データとして用い, 4.3 節で設計した手法によって算出された各ツイートの値を説明変数, 対応する各ツイートの有益度を目的変数とする回帰分析を行った. このとき, 特徴量のタイプとしてはタイプ A とタイプ B の両方を, 回帰モデルとしては直線, 2 次関数, 3 次関数, 4 次関数, 5 次関数の 5 種類を採用した.

それぞれの特徴量タイプと回帰モデルの組み合わせにおいて,



表 10 5 分割交差検定の結果 (RMSE)

特微量 タイプ	回帰 モデル	未知データ扱いのデータセット					平均
		CV1	CV2	CV3	CV4	CV5	
A	4 次関数	0.516	0.487	0.526	0.505	0.486	0.504
	5 次関数	<u>0.509</u>	<u>0.482</u>	<u>0.510</u>	<u>0.503</u>	<u>0.480</u>	<u>0.497</u>
B	4 次関数	0.517	0.486	0.526	0.506	0.486	0.504
	5 次関数	0.515	0.485	0.512	0.506	0.487	0.501

表 11 5 分割交差検定の結果 (自由度修正済み決定係数)

特微量 タイプ	回帰 モデル	未知データ扱いのデータセット					平均
		CV1	CV2	CV3	CV4	CV5	
A	4 次関数	0.484	0.539	0.464	0.506	0.543	0.507
	5 次関数	<u>0.497</u>	<u>0.546</u>	<u>0.494</u>	<u>0.509</u>	<u>0.553</u>	<u>0.520</u>
B	4 次関数	0.483	0.540	0.464	0.504	0.536	0.505
	5 次関数	0.485	0.541	0.489	0.504	0.540	0.512

対応する回帰式を用いて算出した値と目的変数であった有益度との誤差を RMSE (Root-Mean-Square Error) を用いて評価した。結果を表 9 にまとめる。なお、RMSE は以下の式により求めた。

$$RMSE = \sqrt{\sum_{k=1}^N (x_k - y_k)^2 / N}$$

但し、 $k$  はツイート番号であり、 $N$  はツイート数を示す (ここでは  $N = 1,400$ )。  $x_k$  はツイート  $k$  から算出された有益度を示し、 $y_k$  は 3.2 節で求めたツイート  $k$  の有益度を示している。

表 9 によれば、タイプ別では、直線を用いた場合を除いて、タイプ A の特微量を用いたときの RMSE の方が小さいことがわかる。また、回帰モデル別では、どちらのタイプでも、5 次関数を用いたときの RMSE が最も小さいことがわかる。但し、2 番目に小さい 4 次関数を用いたときの RMSE との差はそれほど大きくない。このような結果は、表 6 に示した自由度修正済み決定係数から予想された結果とほぼ一致しており、自由度修正済み決定係数が大きくなればなるほど RMSE が小さくなることを示している。

## 5.2 5 分割交差検定に基づく未知データに対する精度評価

本節では、3.1 節で得た行動促進ツイート (全ツイート 1,400 件) を用いて 5 分割交差検定を行うことで、未知データ (ツイート 280 件  $\times$  5 回分) に対する精度を評価する。

まず、全ツイート (1,400 件) を 5 等分し、ツイート 280 件からなるデータセットを 5 つ作成した (CV1, CV2, ..., CV5 と呼ぶ)。このうちの任意の 4 つのデータセット (ツイート 1,120 件からなる学習データ) を用いて抽出しうる特微量の異なり形を調べ、ツイートベクトルの構成要素を定義するとともに、各ツイートから抽出した特微量の出現頻度をその構成要素の値とするツイートベクトル (ツイート 1,120 件分) を生成した。

次に、ツイートベクトルの構成要素である各特微量ごとに、その特微量のそれぞれのツイートにおける出現頻度と 3.2 節において求めた各ツイートの有益度との間で相関分析を行い、相関係数 (すなわち当該特微量の重み) を求めた。

さらに、それぞれのツイート (1,120 件のツイートからなる学習データ) から特微量を抽出し、抽出した特微量の重みの和をそのツイートの算出値とするとともに、この算出値を説明変数、対応するツイートの有益度を目的変数とする回帰分析を行うことで、回帰式を得た。このとき、ツイートから抽出する特微量としてタイプ A とタイプ B を用い、回帰モデルとして学習データに対する精度が他より良かった 4 次関数と 5 次関数を用いた。

最後に、残っている未使用のデータセット (ツイート 280 件からなる未知データ) を対象に、学習データに対して定義されたツイートベクトルの構成要素に基づいて各ツイートから特微量を抽出し、抽出した特微量の重みの和 (すなわちツイートの算出値) を求めた。この算出値を学習データに対して得られた回帰式に代入することで有益度を算出し、3.2 節において求めた各ツイートの有益度との RMSE を求めた。

5 分割交差検定なので、以上の手順を 5 回繰り返し、得られた 5 回分の RMSE の平均 (すなわち平均 RMSE) を求めた。以上の結果を表 10 にまとめるとともに、このときの自由度修正済み決定係数を表 11 に示す。なお、表 10 と表 11 において下線部は、それぞれの未知データに対して最も性能が良かった組み合わせを示している。

表 10 によれば、5 つの未知データに対する平均 RMSE が最も小さかったのは、タイプ A の特微量を抽出し、5 次関数を用いて回帰分析を行った場合であり、0.497 という値であった。また、それぞれの未知データに対する RMSE が最も小さかったのも、すべて「タイプ A の特微量を抽出し、5 次関数を用いて回帰分析」を行った場合であった。したがって、ツイートに含まれる内容語からタイプ A の特微量を抽出し、その重みの和を求め、5 次関数の回帰式に代入することで、ツイートの有益度を  $\pm 0.5$  の精度で算出することが可能になった。

## 6 ま と め

本稿では、地震災害時における行動促進ツイート (行動促進情報を含むツイート) を対象に、行動促進ツイートの有益度を「3 (とても有益)、2 (多少有益)、1 (あまり有益でない)、0 (全く有益でない)」という 4 段階スケールに準じた形で定量化する手法を提案した。すなわち、提案手法は、入力となる行動促進ツイートから特微量を抽出し、抽出されたすべての特微量の重みの和を事前に用意された回帰式に代入することで、そのツイートの有益度を 0~3 の 4 段階スケールに準じた実数として出力することができる。このとき、特微量はツイート内の内容語 (名詞、形容詞、動詞、副詞、感動詞) から「原形-品詞名-品詞細分類名-活用形名」という形で抽出され、それぞれの特微量の重みには学習データ内の各ツイートから抽出された当該特微量の出現頻度とアンケート調査によって事前に求められたそのツイートの有益度との相関係数が用いられる。また、特微量の重みの和を有益度に変換するための回帰式には、学習データ内の各ツイートから求められた特微量の重みの和を説明変数、アンケート調査によって事前に求められた各ツイートの有益度

を目的変数として行われた回帰分析の結果得られた 5 次関数が用いられる。

地震災害時に実際に発信された行動促進ツイートを用いた性能評価実験によれば、学習データ（全ツイート 1,400 件）に対する誤差（RMSE: Root-Mean-Square Error）は 0.432 であり、未知データに対する誤差（5 分割交差検定による平均 RMSE）は 0.497 であった。これにより、未知データに対しても十分小さな誤差に収まりうることを示された。

著者らは、本研究の最終的な目標として、ユーザの置かれた状況に応じてユーザが必要とする行動促進ツイートを推薦するシステムの開発を目指している。今回、行動促進ツイートの有益度を定量化する手法を提案したが、ユーザの置かれた状況は考慮していない。考慮すべき状況としては、災害発生前か発生中か発生後かといった「時間的な状況」、被災地か周辺地域か他地域かといった「空間的な状況」、ユーザが怖がっているか心配しているか不安を抱いているかといった「感情的な状況」の 3 種類を検討しており、それぞれの状況を考慮しつつ行動促進ツイートに含まれる情報とその有益度に応じて適切なツイートを推薦する仕組みを考案したいと考えている。

## 謝 辞

本研究の一部は、JSPS 科研費 19H04221, 20K12085 の助成によるものである。また、本研究で用いた地震災害に関するツイートデータと行動促進ツイートか否かの判定材料となるデータ（クラウドサービスによる作業の結果）は、甲南大学知能情報学部灘本研究室の見塚圭一氏が収集あるいは取得したものであり、同研究室の米田吉希氏がまとめたものを提供していただいた。ここに記して深く感謝の意を表する。

## 文 献

- [1] Twitter, <https://twitter.com/>, 2020 年 12 月 10 日閲覧。
- [2] 総務省報道資料「災害時における情報通信の在り方に関する調査結果（2012 年 3 月 7 日）」, [https://www.soumu.go.jp/menu\\_news/s-news/01tsushin02\\_02000036.html](https://www.soumu.go.jp/menu_news/s-news/01tsushin02_02000036.html), 2020 年 12 月 10 日閲覧。
- [3] 見塚圭一, 鈴木優, 灘本明代, 行動促進の根拠を含むツイートの抽出手法, 第 10 回データ工学と情報マネジメントに関するフォーラム (DEIM2018) 論文集, B5-2, 2018.
- [4] 見塚圭一, 鈴木優, 灘本明代, Twitter 上の行動促進ツイート抽出手法の比較検討, WebDB Forum 2018 (第 11 回 Web とデータベースに関するフォーラム), 信学技報, Vol. 118, No. 213 (DE2018-17), pp. 49-54, 2018.
- [5] 見塚圭一, 米田吉希, 鈴木優, 灘本明代, 災害時の行動促進ツイート抽出手法, 第 11 回データ工学と情報マネジメントに関するフォーラム (DEIM2019) 論文集, I7-4, 2019.
- [6] 米田吉希, 見塚圭一, 鈴木優, 灘本明代, 機械学習を用いた災害時行動促進情報抽出手法の比較検討, WebDB Forum 2019 論文集 (第 12 回 Web とデータベースに関するフォーラム), pp. 61-64, 2019.
- [7] 米田吉希, 鈴木優, 灘本明代, 深層学習を用いた大規模災害の行動促進情報の分析, 第 12 回データ工学と情報マネジメントに関するフォーラム (DEIM2020) 論文集, C8-2, 2020.
- [8] Akiyo Nadamoto, Mai Miyabe, and Eiji Aramaki, Analysis of Microblog Rumors and Correction Texts for Disaster Situation, Proc. of the 15th International Conference on Information Integration and Web-based Applications & Services,

- pp. 44-52, 2013.
- [9] Wikipedia「北海道胆振東部地震」, <https://ja.wikipedia.org/wiki/北海道胆振東部地震>, 2020 年 12 月 9 日閲覧。
- [10] 内閣府, 令和元年版防災白書 第 1 章 平成 30 年の災害, [http://www.bousai.go.jp/kaigirep/hakusho/h31/honbun/0b\\_1s\\_01\\_01.html](http://www.bousai.go.jp/kaigirep/hakusho/h31/honbun/0b_1s_01_01.html), 2020 年 12 月 22 日閲覧。
- [11] Wikipedia「令和元年房総半島台風」, <https://ja.wikipedia.org/wiki/令和元年房総半島台風>, 2020 年 12 月 22 日閲覧。
- [12] Zahra Ashktorab, Christopher Brown, Manojit Nandi, and Aron Culotta, Tweedr: Mining Twitter to Inform Disaster Response, Proc. of the 11th International ISCRAM Conference, 5 pages, Pennsylvania, USA, 2014.
- [13] 北島良三, 上村龍太郎, 内田理, 鳥海不二夫, ニューラルネットワークを用いた Tweet データの分類に関する研究, 第 29 回人工知能学会全国大会論文集, Vol. JSAI2015, No. 2BS-NFC-02a-2, 4 pages, 2015.
- [14] Wikipedia「東日本大震災」, <https://ja.wikipedia.org/wiki/東日本大震災>, 2020 年 12 月 22 日閲覧。
- [15] 藤本雄紀, 今井龍一, 中村健二, 田中成典, 有馬伸広, 荒川貴之, 信憑性の高い記事を投稿するマイクロブログユーザの特定手法に関する研究, 土木学会論文集 F3 (土木情報学), Vol. 73, No. 2, pp. I.259-I.267, 20017.
- [16] 藤本雄紀, 今井龍一, 中村健二, 田中成典, 有馬伸広, 荒川貴之, 道路利用の実態を投稿するマイクロブログユーザの信頼性分析手法に関する研究, 情報処理学会論文誌, Vol. 59, No. 10, pp. 1853-1865, 2018.
- [17] 宮部真衣, 田中弥生, 西畑祥, 灘本明代, 荒巻英治, マイクロブログにおける流言の影響の分析, 自然言語処理, Vol. 20, No. 3, pp. 485-511, 2013.
- [18] 宮部真衣, 灘本明代, 荒巻英治, 人間による訂正情報に着目した流言拡散防止サービスの構築, 情報処理学会論文誌, Vol. 55, No. 1, pp. 563-573, 2014.
- [19] 大和田裕亮, 岡崎直観, 乾健太郎, 石塚満, 返信・非公式リツイートで表明される論述関係の認識, 情報処理学会第 75 回全国大会講演論文集, No. 4Q-5, pp. 2-171-2-172, 2013.
- [20] 渡邊建太, 山田剛一, 絹川博之, 訂正投稿の傾向を利用したデマ訂正ツイートの抽出, 第 13 回情報科学技術フォーラム講演論文集, Issue 2, No. E-009, pp. 223-224, 2014.
- [21] クラウドワークス, <https://crowdworks.jp/>, 2020 年 12 月 9 日閲覧。
- [22] 黒橋・CHU・村協研究室, 日本語形態素解析システム JUMAN, <http://nlp.ist.i.kyoto-u.ac.jp/?JUMAN>, (2020 年 12 月 2 日閲覧)
- [23] 益岡隆志, 田窪行則, 基礎日本語文法, くろしお出版, 東京, 1991.