

SNS 広告におけるインフルエンサー推薦のための「いいね」数予測

山崎 康之介[†] 牛尼剛聡[‡]

[†]九州大学芸術工学部 〒 815-8540 福岡県福岡市南区塩原 4-9-1

[‡]九州大学芸術工学研究院 〒 815-8540 福岡県福岡市南区塩原 4-9-1

E-mail: [†]yamasaki.kounosuke.569@s.kyushu-u.ac.jp, [‡]ushiana@design.kyushu-u.ac.jp

あらまし 近年、企業広告においてインフルエンサーマーケティングが注目されている。SNS を利用したインフルエンサーマーケティングを行うためには、インフルエンサー候補となる多数の SNS ユーザの中から、適切なインフルエンサーを選択することが重要である。しかし、広告内容に基づいてその効果を予測し、広告に適切なインフルエンサーを定量的に評価する手法は確立していない。また、Twitter におけるインフルエンサーのデータは、一般的なユーザと大きく異なるという問題も存在する。これらの課題を踏まえ、本稿ではインフルエンサー選別の支援を目指し、対象のユーザの過去ツイートのみを学習データとして利用した、インフルエンサーと広告内容（テキスト）から、Twitter で獲得できる「いいね」数を予測する深層学習モデルを提案する。

キーワード インフルエンサー、広告、Twitter、推薦、深層学習

1. はじめに

インターネットの普及に伴って、広告におけるオンライン広告の利用が増加している。代表的なオンライン広告の一つとして、SNS 上での広告がある。SNS 上での広告にはいくつかの形態があり、Twitter Ads¹のように SNS が提供する広告システムを利用するもの、企業のアカунトによって広告を行うもの² (図 1)、インフルエンサーが企業に代わって広告を行うもの³ (図 2) などが存在する。インフルエンサーとは、一般的なユーザよりもフォロワーが多く、影響力が大きいと考えられる SNS ユーザである。インフルエンサーを利用した広告は、インフルエンサーマーケティングと呼ばれ、近年注目を浴びている広告形態である。インフルエンサーマーケティングが注目される理由には、インフルエンサーは多くのフォロワーを有するために情報をより迅速かつ広範囲に広められることや、親近感を持つ人からの情報は受け入れられやすい[1]など、企業自身が広告を発信するよりも宣伝効果が高いことが挙げられる。

SNS は誰もが利用できる情報空間であり、利用者数の規模が大きいためにインフルエンサーと考えられるユーザが多く存在することから、企業が広告に適切なインフルエンサーを選ぶにあたり、選別の指標が重要となる。指標の一つとなりうるインフルエンサーの影響力についてモデル化を行う研究[2][3]もいくつか存在するが、それぞれが影響力を異なる観点から定義しており、広告効果の目安として適切で有ることが検証されていない。また、これらの研究での影響力は、対象とする広告内容（テキスト）を考慮していないが、



図 1 企業による
広告ツイートの例



図 2 インフルエンサーによる
広告ツイートの例

影響力は広告内容に依存して異なると考えられる。そこで、本稿では、適切なインフルエンサー選択の指標として、オンライン広告の効果指標として最も一般的なクリック率に近い指標であり、Twitter⁴において公開されているデータである「いいね」数を採用し、「いいね」数を予測するモデルを提案する。

Twitter において「いいね」数を予測する際の問題点として、予測を行うためには学習データセットが必要であるが、インフルエンサーに関するデータは、例えばフォロワー数の値など、一般的なユーザとは大きく異なっているため、一般的なユーザを対象とした学習データセットでは予測精度が悪化してしまう可能性があることが挙げられる。また、そのような差異をなくすために、適切なデータだけを抽出した学習データセ

¹ <https://ads.twitter.com/>

² https://twitter.com/KATETOKYO_PR/status/1235476274342023169

³ <https://twitter.com/K89782/status/1209046642827001856>

⁴ <https://twitter.com/>

ットを構築したり、何らかの工夫を行ったりするためには、事前に大規模なデータセットを用意しなければならない。これらの問題点を解決するために、本研究では、対象のユーザの過去ツイートのみを学習データとして採用し、インフルエンサー選別支援のための、広告内容（テキスト）を踏まえた「いいね」数予測を行う深層学習モデルを提案する。

2. インフルエンサーの定義

ここでは、本研究におけるインフルエンサーについての定義を行う。これは、一般に「インフルエンサー」という用語が広い意味合いで使われることが多いため、一般的な意味との齟齬が生じるのを防ぐためである。

山本[4]によれば、他者に影響を及ぼす消費者を“influencer”あるいは“influential”と呼び、古典的な研究においては4人以上の友人に直接的に影響を及ぼした消費者を“influential”と定義したり[5]、ある分野において専門知識を持っているとみなされている人を“influencer”と定義する[6]ことが述べられているが、本稿では本研究の目的に沿って、Twitterにおいて、実際に企業から広告の依頼を受けて、図2のように、自身のツイートにて広告活動を行なっているユーザをインフルエンサーと定義する。

本研究では、このようなインフルエンサーを対象として、「いいね」数を予測するが、例えば、Twitter以外のメディアで特定のツイートに言及するなどの外部要因による「いいね」数への一時的な影響は、Twitterのデータからのみでは予測が難しくなってしまう。そこで現段階においては、条件を簡単にするために、外部要因による影響が懸念されるYouTube⁵等配信プラットフォームで配信を行なっていることがプロフィールにて確認できたユーザは対象から除外する。

3. 関連研究

本節では、Twitter上での「いいね」数の予測に関連する研究として、リツイート数の予測に関する研究と、オンライン広告のクリック数の予測に関する研究について言及する。

3.1. リツイート数の予測に関する研究

Canら[7]は、様々なユーザによって投稿された多数のツイートをデータセットとして、回帰モデルによってリツイート数を予測する手法を提案している。

この手法では、説明変数としてハッシュタグの数と

いったツイート内容そのものに関する特徴量に加えて、フォロワー数やフレンド数（フォローしているユーザの数）といったユーザに関する特徴量を使用し、目的変数であるリツイート数を予測している。ユーザに関する特徴量に加えられている理由としては、リツイート数がユーザの違いにも影響されることを考慮したものであると考えられる。しかし、本研究で予測を行う対象はインフルエンサーのツイートに関する特徴量であり、ランダムにサンプリングしたツイートからなる学習データセットでは、フォロワー数などユーザに関する特徴量が予測対象のデータの分布と大きく異なってしまう。学習データセットについても予測対象のデータと同様のデータで構築することが考えられるが、フォロワー数が3,000を超えるユーザはTwitter上の1%程度であるとするデータ⁶もあり、さらにその中からインフルエンサーの定義を満たすデータを学習データとして十分な量を確保するのは難しい。この解決策として本研究では、学習データが予測対象のデータと大きく異ならないよう、本人の過去のツイートを学習データセットとして、回帰モデルによる予測を行う。

3.2. 深層学習によるクリック数予測

近年、高次元データに対する機械学習において顕著な成果を上げている深層学習を利用した回帰モデルが活発に研究されている。岩崎[8]は、深層学習を利用することでFacebook Ads⁷で配信された広告のクリック数を予測する手法を提案している。広告の情報からクリック数を予測するには、数値的な特徴量の他に、画像やテキストを特徴量として利用することが考えられるため、深層学習を用いることで効果的に画像やテキストの特徴を抽出することが期待できる。

本研究においても、深層学習を利用することで、広告内容の一つであるテキストを踏まえた「いいね」数の予測を行う。

4. 提案手法

本研究の目標である、インフルエンサーのツイートに対する広告内容（テキスト）を踏まえた「いいね」数の予測を実現するための手法として、予測対象とするインフルエンサーの過去のツイートを学習データとして利用した深層学習モデルを提案する。

4.1. 特徴量

インフルエンサーが投稿した個々のツイートに対して、表1に示す特徴量を考え、それらを利用して「い

⁵ <https://www.youtube.com/>

⁶ <https://www.oreilly.com/content/tweets-loud-and-quiet/>

⁷ <https://www.facebook.com/business/products/ads>

いいね」数を予測する。

number は、インフルエンサーが投稿したツイートに関する投稿日時に基づいた通し番号である。過去と現在ではフォロワー数が異なり、「いいね」数にも影響があると考えられる。しかし、それぞれのツイートが行われた時点でのフォロワー数を取得できないため、投稿したツイートの順番を特徴量とする。

possiblyPR は、広告ツイートかどうかを表す特徴量である。この特徴量は、広告を行う際にステルスマーケティングを防ぐ目的でよく利用されるハッシュタグ（#PR, #gifted, #sponsored, #タイアップ, #提供, #ad 等）が含まれるかで判定する。

text は、ツイートに含まれるテキストである。ツイートに含まれるテキストに形態素解析を行うことで、動詞、名詞、形容詞をキーワードとして抽出し、各単語を 200 次元のベクトルに変換した。n 個の単語をベクトル化した場合、text は $n \times 200$ 行列となる。なお、形態素解析には Mecab⁸を利用し、辞書には新語や固有表現に対応できる mecab-ipadic-NEologd⁹を用いる。また、各単語のベクトル化には Wikipedia Entity¹⁰を用いて事前学習させた Word2Vec[9]を用いる。

4.2. 深層学習モデル

「いいね」数を予測するための機械学習モデルには、深層学習モデルを利用する。具体的には、図 3 に示す構造のニューラルネットワークである。

まず、Basic に分類される text 以外の特徴量は、標準化を行った後、2 層の全結合層へ入力する。

次に、Text (text) に関しても同様に、2 層の全結合層へ入力する。この時、text は $n \times 200$ 行列であるため、全結合層では 200 次元のデータとして 1 単語ずつ計算が行われ、すべて同じ重みが適用される。全結合層の後、Sum 層にて各次元ごとに n 個の和をとることで、テキストの特徴を抽出したものとすることができる。なお、注意点として、n はツイートごとに変わるが、ニューラルネットワークでは可変的な形状のデータは入力できないため、実際にはデータセット内で n が最大値となる text と形状が一致するように、その他全ての text で 0 埋めを行い、全結合層の入力時に 0 を無視するような mask 処理を行なう。

この様に、キーワードの分散表現を同じ重みで学習させる手法では、一般的なテキストの特徴抽出手法である RNN や LSTM よりも学習すべきパラメータを大幅に抑えることができるため、少ない学習データにおいても、効果的に特徴を抽出することが期待できる。最後に、Basic と Text がそれぞれの全結合層を経て出

表 1 提案手法で作成する特徴量

	変数名	内容	型
Basic	number	投稿された順番	numeric
	isQuoteStatus	引用ツイートかどうか	binary
	photoCount	写真の枚数	numeric
	videoCount	動画の数	numeric
	hashtagCount	ハッシュタグの数	numeric
	possiblyPR	広告ツイートかどうか	binary
	characterCount	文字数	numeric
Text	text	テキストを表すベクトル	numeric(n, 200)

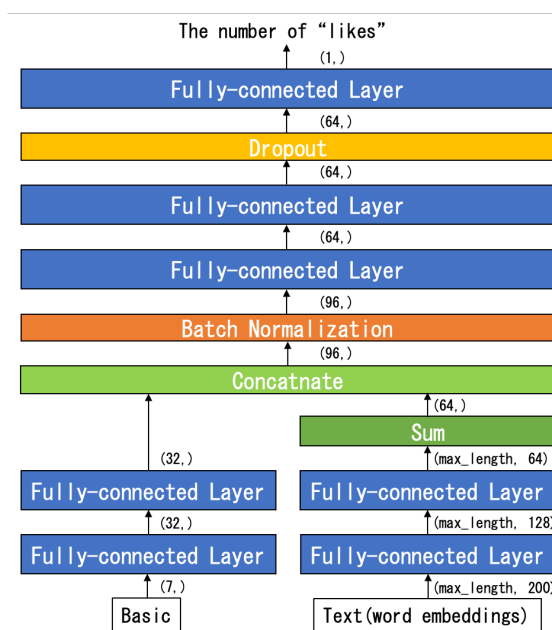


図 3 ニューラルネットワークの構造

力される値を Concatenate 層にて連結させ、スケールの違いを小さくするために Batch Normalization を行う。これを新たな特徴量として、さらに全結合層へ入力することで、最終的な「いいね」数の予測値を得る。

モデルの学習には、インフルエンサー毎にインフルエンサーが投稿したデータのみを用いる。また、学習データが少ないことに起因する過学習を避けるために、層の中のノードのうちのいくつかを無効にして学習を行い、ネットワークの自由度を強制的に小さくして過学習を防ぐことのできる dropout[10]を導入し、dropout の割合は 50%とする。

4.3. 外れ値の処理

インフルエンサーのツイートデータセットには、しばしば、極端に大きな値の「いいね」数が存在する。これは、フォロワー数が多いインフルエンサーでは、

⁸ <https://taku910.github.io/mecab/>

⁹ <https://github.com/neologd/mecab-ipadic-neologd/>

¹⁰ http://www.cl.ecei.tohoku.ac.jp/~m-suzuki/jawiki_vector/

「バズる」と言われるような現象が起きやすいことが原因であると考えられる。しかしながら、このような値は、外れ値としてノイズになってしまうため、それぞれのインフルエンサーの学習データセットで算出された 90 パーセンタイルを超える「いいね」数は、全て 90 パーセンタイルで置換した。

5. 実験

本節では、提案手法の有効性を評価するために行った実験とその結果について述べる。5.1 節では、本研究で必要とするデータセットの取得方法と、詳細について述べる。5.2 節では、予備実験として、複数ユーザのデータを用いた場合と予測対象のユーザの過去ツイートのみを用いた場合との比較を行う。5.3 節では、提案手法の性能を検証する。

5.1. データセット

データセットを構築するために、インフルエンサーの定義を満足する 67 人のインフルエンサーについて Twitter API¹¹を用いてツイートを取得した。Twitter API の仕様上、1 アカウントにつき取得可能な投稿は最大 3,200 件である。さらにその中から、通常のツイートとは形態の異なる RT および Reply は除外した。また、本研究では、ツイート直後の「いいね」数は時間によって大幅に変化すると考えられるため、「いいね」数が安定した状態での数値を予測する。そのため、取得したツイートに対して、直近 2 週間以内に投稿されたものはまだ「いいね」数が安定していないと考え、データセットから除外した。これらの処理を加えたインフルエンサー 67 アカウントについてのデータセットの統計量を表 2 に示す。

取得したツイートのテキストに対しては、特徴量を抽出する上でデータを扱いやすくするために以下の前処理を行った。

- ・半角カタカナを全角へ変換
- ・数字、アルファベットを半角文字に統一
- ・スペースの除去
- ・メンション(@アカウント名)を空白へ置換
- ・URL を空白へ置換

5.2. 複数のユーザデータを用いた場合との比較

提案モデルによる予測を行う前に、一般的なユーザとはフォロワー数等の特徴の値が、大きく異なるインフルエンサーの「いいね」数を予測する場合において、Can ら[8]のように様々なユーザのツイートデータを学習データとして予測する手法（手法 1）と、対象のイ

表 2 データセットの統計量

	平均値	最大値	最小値
ツイート数	825.896	2125	33
いいね数	1961.243	523293	0
フォロワー数	104700.522	1288326	5038

表 3 手法 1 で作成した特徴量

	変数名	内容
User-Based	followersCount	フォロワーの数
	friendsCount	フォローしている数
	followersFriendsRatio	followersCountとfriendsCountの比率
	age	アカウント開設からの期間
	statusCount	総ツイート数
	favoritesCount	これまでに「いいね」した数
Content-Based	listedCount	公開リストに追加されている数
	month	投稿された月
	hour	投稿された時間
	weekday	投稿された曜日
	isQuoteStatus	引用ツイートかどうか
	photoCount	写真の枚数
	hashtagCount	ハッシュタグの数
	possiblyPR	広告ツイートかどうか




図 4 比較検証における予測結果

ンフルエンサーの過去のツイートのみを学習データとして予測する手法（手法 2）の比較検証を行う。

5.2.1. 実験手法

まず、手法 1 で利用する複数ユーザからなる学習データセットを構築するために、インフルエンサーの 1 人を選びそのフォロワーのうち 21,698 アカウントから合計 180,558 ツイート取得した。また、フォロワー数などユーザに関する情報は現在のものしか取得できないため、ツイートは 1 アカウントにつき 10 ツイートを上限として取得した。手法 2 の学習データセットには、5.1 節で述べたインフルエンサーのデータセッ

¹¹ <https://developer.twitter.com>

トのうち、テスト用データを除いた、インフルエンサーそれぞれの過去のツイートを用いた。テスト用データは、手法 1, 2 共に、インフルエンサーのデータセットのうち、それぞれ最新 10 ツイート、合計 670 ツイートとした。

手法 1 では、ユーザに関する特徴量については Can らを参考にし、表 3 に示す特徴量を作成した。User-Based に記載されているものがユーザに関する特徴量である。手法 2 では、表 3 で示すもののうち User-Based の特徴量を除き、number を追加したものを作成した。

予測は、提案モデルではなく、Can らに倣って RandomForestRegressor¹²によって行い、平均二乗誤差 (MSE) で評価した。

5.2.2. 結果と考察

結果は、図 4 に示すように、手法 2 の方が MSE が小さくなり、過去のツイートのみを学習データとする手法の方が有効であることが示された。これは、関連研究でも述べたように、インフルエンサーの「いいね」数予測では学習データと検証用のデータの違いが大きいことが原因であると考えられる。

5.3. 提案手法の評価

5.3.1. 実験手法

提案手法の実験では、インフルエンサーのデータセットのうち、最新 5% に当たるデータをテスト用データ、それ以外を学習データとして、深層学習モデルによって「いいね」数の予測を行った。

深層学習モデルの学習に当たっては、最適化手法に Adam[11]、損失関数に MSE を用いた。また、それぞれのモデルの学習は検証用データが 20epoch 連続で損失関数が改善しない時点で終了するようにした。

性能を評価するために、提案手法から予測される「いいね」数 (pred_of_proposal) を、各インフルエンサーの学習データセットにあるツイートのうち、全体の「いいね」数の平均 (mean_of_all) と、最新 10 件の「いいね」数の平均 (mean_of_latest) をベースラインとして比較し、予測精度の検証を行った。

精度の評価指標には MSE を用いた。さらに、MSE を比較するための Improve という指標を取り入れた。MSE1 に対する MSE2 の Improve は以下の式で算出され、MSE1 からどれだけ改善されているかを表す。

$$\text{Improve} = \frac{\text{MSE1} - \text{MSE2}}{\text{MSE1}} \cdot 100\%$$

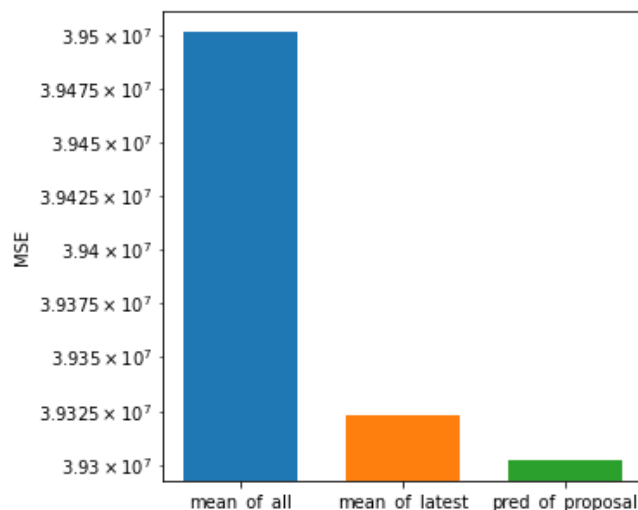


図 5 ベースラインとの比較結果




図 6 mean_of_all に対する Improve




図 7 mean_of_latest に対する Improve

5.3.2. 結果と考察

図 5 は、2,738 の全検証用データで算出された、それぞれの MSE を示したものである。このヒストグラムからわかるように、提案手法は mean_of_all, mean_of_latest よりも精度よく予測できており、本研究

¹² <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>

で提案した特徴量やニューラルネットワークが有効であったことがわかる。また、`mean_of_all`で誤差が大きかったのは、ユーザはツイート数が増えると共に、フォロワー数も伸び、結果として獲得できる「いいね」数が増えていることが原因であると考えられる。なお、図5のヒストグラムでは0から 3.93×10^7 までは対数スケールの軸となっていることに注意されたい。

次に、インフルエンサーごとの検証用データで算出される67つのMSEの比較を行う。これは、獲得する「いいね」数の大きさはインフルエンサーによって異なるため、全体のMSEでは特定のインフルエンサーの結果に影響されやすい問題点があるからである。また、深層学習モデルの学習は、インフルエンサーごとに行うため、モデルの汎化性能についても確認することができる。

図6は、`mean_of_all`に対する`pred_of_proposal`のImproveである。全体のMSEでも大幅に`mean_of_all`を上回っていたように、インフルエンサーごとで見ても、ほとんどのインフルエンサーで精度が改善されていることがわかる。

図7は、`mean_of_latest`に対する`pred_of_proposal`のImproveである。こちらも同様に、ほとんどのインフルエンサーでは、精度が上回っていた。しかしながら、下位6名のデータでは、Improveが-100%を下回っており、精度が大幅に低下していた。インフルエンサーのデータを増やせば、このような傾向がさらに強く見られる可能性もあり、改善の余地があると言える。なお、図6, 7の値は降順に並び替えており、図6, 7間でインフルエンサーの順番は必ずしも一致しない。

6. まとめ

本稿では、広告に適切なインフルエンサーの選別支援を目標に、対象のインフルエンサーの過去ツイートを学習データとして、広告内容（テキスト）を踏まえた「いいね」数の予測手法を提案した。

予備実験では、インフルエンサーの「いいね」数予測に関しては、本人の過去ツイートを学習データとすることの有用性が示された。

提案手法の性能評価では、「いいね」数の平均をベースラインとして比較を行い、検証用データ全体のMSEでは、精度を上回ることができた。インフルエンサーごとに算出されたMSEでも、ほとんどのユーザでベースラインを上回ることができた一方、一部のユーザでは、大幅に下回っており、問題点も確認された。

今後は、関連研究でも扱われているように、画像を特徴量として追加することや、何らかの工夫によって学習データを増やすこと、その他どのような点に改善

の余地があるか丁寧な検証を重ねることによって、さらに予測精度の向上を図りたい。また、近年注目されているAttention機構[12]の応用などによる予測モデルへの説明性の付与についても検討する予定である。

謝辞

本研究はJSPS科研費19H04219の助成を受けたものです。

参考文献

- [1] Weigned A., “Data for the people -How to make our post-privacy and economy work for you-”, Basic Books, 土方奈美 訳.『アマゾンミクス -データ・サイエンティストはこう考える -』, 第3章 そのつながりが経済を動かす, pp. 109-164, 文藝春秋, 2017.
- [2] 岡本拓馬, 松本和幸, 吉田稔, 北研二, “影響力の範囲を考慮した Twitter における影響力推定手法”, 情報科学技術フォーラム講演論文集, 14(2), pp. 227-228, 2015.
- [3] 荒澤孔明, 服部峻, “SNS の行動ログに基づくインフルエンサー推定の個人化”, WebDB Forum 2019 論文集, Vol. 2019, pp. 53-56, 2019.
- [4] 山本晶, “インターネット上の行動履歴データとインフルエンサー”, マーケティングジャーナル, 34(2), pp. 34-46, 2014.
- [5] Merton, R. K., “Social Theory and Social Structure revised and enlarged edition”, New York: Free Press, 1957.
- [6] Eliashberg J., Shugan S., “Film Critics: Influencers or Predictors?”, Journal of Marketing, 61, pp. 68-78, 1997.
- [7] Can, Ethem F., Hüseyin Oktay, R. Manmatha, “Predicting retweet count using visual cues”, Proceedings of the 22nd ACM international conference on Information & Knowledge Management 2013.
- [8] 岩崎祐貴, “深層学習による Facebook 広告の CTR 予測.” 人工知能学会 全国大会論文集 第32回全国大会 (2018). 一般社団法人 人工知能学会, 2018.
- [9] Kai Chen Greg S Corrado Jeff Dean Tomas Mikolov, Ilya Sutskever, “distributed representations of words and phrases and their compositionality”, Proc. NIPS, pp. 3111-3119, 2013.
- [10] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, Ruslan Salakhutdinov, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting”, The Journal of Machine Learning Research, Volume 15 Issue 1, pp. 1929-1958, 2014.
- [11] Diederik P. Kingma, Jimmy Ba., “adam: A method for stochastic optimization”, International Conference on Learning Representations, 2014.
- [12] Vaswani, Ashish, et al. “Attention is all you need.” Advances in neural information processing systems. 2017.